INTRODUÇÃO À BIOINFORMÁTICA · PPGED / IME

Aula 7

Bioinformática Estrutural

Visualização molecular · Modelagem por homologia · Docking · Dinâmica molecular

3 horas

Teoria · intervalo · prática · integração

COMO VAMOS USAR AS TRÊS HORAS

Mapa da aula

Momento	Tempo	O que acontece
1 — Teoria	00:00 – 01:15	Por que a forma importa; o PDB; visualização; predição; docking; dinâmica molecular
Intervalo	01:15 – 01:25	10 minutos
2 — Prática	01:25 – 02:40	Navegador e Colab: PDB → modelo previsto → docking validado → trajetória
3 — Integração	02:40 – 03:00	Costura teoria↔prática, erros comuns, o artigo final, exercícios

Em cada momento você vai **executar, observar e interpretar**. Não é preciso saber programar: o código está pronto e comentado.

O FIO CONDUTOR

Uma única enzima liga toda a aula: a *acetilcolinesterase*

O que ela faz

Desliga o impulso nervoso degradando a acetilcolina na sinapse. Está entre as enzimas mais rápidas conhecidas.

Se for inibida

A acetilcolina acumula e o músculo não relaxa: crise colinérgica. É o mecanismo de letalidade dos agentes neurotóxicos.

Na medida certa

Inibição parcial é terapia para Alzheimer — é o que faz a donepezila, o ligante que vamos dockar hoje.

Trabalhamos do lado **defensivo e terapêutico** do problema: antídotos, profilaxia, detecção e descontaminação.

01

Momento 1 — Teoria

75 minutos. Dos conceitos às ferramentas: por que a forma importa, de onde vêm as estruturas, como prevê-las, como encaixar um ligante e como pôr a proteína em movimento.

1.1 POR QUE A ESTRUTURA 3D IMPORTA

Sequência → Estrutura → Função

A sequência determina como a cadeia se dobra; o formato dobrado cria bolsões, fendas e superfícies; e é a **geometria mais a química** desses bolsões que define o que a proteína faz e com quem interage.

> **Analogia de engenharia:** saber a lista de peças de um motor não permite prever o torque. É preciso saber **como as peças estão montadas**.

Onde

uma molécula pequena se liga?

Quão forte

é essa ligação?

Por que

uma mutação quebra a função?

Como

ela se move: rígida ou respira?

1.1 POR QUE ISSO INTERESSA À ENGENHARIA DE DEFESA

Todo problema de defesa aqui é uma pergunta de geometria

Problema de defesa	Pergunta estrutural
Agentes neurotóxicos organofosforados	Como o agente ataca a serina catalítica da acetilcolinesterase?
Antídotos e reativadores (oximas)	Que molécula entra na garganta estreita e remove o fosfato?
Profilaxia e bioscavengers	A butirilcolinesterase pode sequestrar o agente antes do alvo?
Detecção e biossensores	Que anticorpo ou aptâmero reconhece a toxina com especificidade?
Biodefesa: toxinas (ricina, botulínica)	Onde está o sítio catalítico e que inibidor o bloqueia?
Enzimas de descontaminação	Como melhorar por engenharia uma fosfotriesterase?

Todas as linhas desta tabela têm estrutura pública no PDB

O DETALHE QUE DECIDE TUDO

~20 Å

de garganta estreita até o sítio ativo

Para referência: uma ligação carbono-carbono mede cerca de 1,5 Å.

O sítio ativo da AChE fica no fundo de um túnel

A garganta é forrada de aminoácidos **aromáticos** (triptofano, tirosina, fenilalanina). Qualquer molécula candidata precisa **caber** e **descer** por esse túnel.

> **Dois pontos de ancoragem**
>
> **TRP86** no fundo da garganta e **TRP286** na entrada (sítio periférico). Uma molécula que toca os dois extremos ganha afinidade por ocupar todo o túnel — é o caso da donepezila.

1.2 DE ONDE VÊM AS ESTRUTURAS

O Protein Data Bank

O **PDB** é o repositório público mundial de estruturas 3D de macromoléculas. É para a estrutura o que o GenBank é para a sequência — e, como ele, é a fonte de dados da nossa prática.

1971

ano de criação — um dos bancos de dados científicos mais antigos em operação

> 200 mil

estruturas depositadas, todas de acesso livre e sem cadastro

4 caracteres

o código de cada estrutura — **4EY7**, **1EVE** — e é ele que você cita no artigo

Bancos complementares: PubChem e ChEMBL (ligantes, o segundo com bioatividade medida) · UniProt (ficha funcional) · AlphaFold DB (estruturas previstas).

Três técnicas, três graus de confiança

Técnica	O que é	Limite prático
Cristalografia de raios X	A proteína é cristalizada e o padrão de difração é convertido num mapa de densidade eletrônica, onde os átomos são encaixados	85–90% do PDB. Exige cristalizar. A proteína fica congelada em uma conformação
Criomicroscopia eletrônica	Milhares de imagens de partículas individuais congeladas são combinadas num mapa 3D	Revolucionou complexos grandes: ribossomos, vírus. Já chega a nível atômico
RMN	Resolve a estrutura em solução e entrega um conjunto de modelos	Proteínas pequenas. Vantagem: mostra a flexibilidade

A técnica não é detalhe bibliográfico: ela determina **o que você pode afirmar** com a estrutura na mão.

A 4EY7, da nossa prática, é raios X

1.2 CONTROLE DE QUALIDADE

Três números para olhar antes de usar qualquer estrutura

1 · RESOLUÇÃO

Em ångström. Quanto **menor**, melhor.

- < 1,5 Å — excelente
- 1,5–2,5 Å — padrão para docking
- 2,5–3,5 Å — cadeias laterais incertas
- > 3,5 Å — não use sem justificar

2 · R-FREE

Concordância do modelo com dados **não usados** no ajuste.

É a validação cruzada da cristalografia — a mesma lógica de separar treino e teste. Bom: < 0,25.

3 · B-FACTOR

Um número **por átomo**: quanto ele treme ou está mal definido.

B alto = região flexível ou pouco confiável. Dá para colorir a estrutura por ele.

Armadilha clássica: baixar uma estrutura de 3,8 Å, fazer docking e reportar a afinidade com três casas decimais. O dado de entrada não sustenta essa precisão.

Nossa estrutura: 4EY7 — raios X, 2,35 Å, R-free 0,211

O QUARTO NÚMERO, QUE QUASE TODO MUNDO ESQUECE

Quantas cópias da proteína há dentro do arquivo?

Um arquivo do PDB contém a **unidade assimétrica** do cristal — que pode ter 1, 2, 4 ou mais cópias da mesma proteína, identificadas por **cadeias**: A, B, C...

A 4EY7 tem DUAS acetilcolinesterases — e duas donepezilas

Se você extrair "o ligante" sem filtrar a cadeia, pega **as duas** cópias. O centro que você calcular cai no meio do caminho entre os dois sítios ativos — provavelmente no solvente ou no miolo da proteína.

O docking roda. Não dá erro nenhum. E o resultado é lixo.

É o tipo de erro que não aparece como mensagem de erro, e sim como um número plausível e errado. Na prática de hoje vamos filtrar a cadeia A **explicitamente** — e conferir.

1.2 FORMATOS DE ARQUIVO

Quatro extensões e uma linha de texto

Extensão	O que é
.pdb	Clássico, texto de colunas de largura fixa. Legível a olho nu
.cif	Padrão oficial desde 2014. Sem limite de tamanho, mais metadados
.pdbqt	Do AutoDock: PDB + cargas (Q) + tipos de átomo (T) + torções. É o que o docking consome
.sdf / .mol2	Moléculas pequenas (ligantes), vindas do PubChem

Anatomia de uma linha .pdb

```
ATOM 145 CA SER A 203
12.345 67.890 10.111
1.00 18.52 C
```

tipo · nº átomo · átomo · **resíduo (col. 18-20)** · **cadeia (col. 22)** · nº resíduo · x y z · ocupação · B-factor · elemento

ATOM = átomo da proteína · **HETATM** = ligante, água ou íon

A posição das colunas é **fixa**. É por isso que, na prática, vamos filtrar o arquivo **por posição de coluna** — e não procurando um texto em qualquer lugar da linha.

1.3 VISUALIZAÇÃO MOLECULAR

Visualizar não é enfeite: é controle de qualidade

Erros grosseiros — cadeia faltando, ligante no lugar errado, duas cópias da proteína — aparecem em 10 segundos na tela e passariam despercebidos no arquivo de texto.

Mol*

Roda **dentro do navegador**; é o visualizador oficial do site do PDB. Código aberto, zero instalação.

É o que usaremos na prática.

PyMOL

O mais usado em publicações. Tem versão de código aberto. Controlado por **linha de comando própria** — logo, reprodutível e automatizável.

Para figuras de artigo.

UCSF ChimeraX

Sucessor do Chimera. Gratuito para uso acadêmico, excelente com crio-EM, mapas de densidade e estruturas enormes.

Para análises pesadas e vídeos.

O vocabulário das representações

Cartoon — o enovelamento, o mapa geral · **Sticks** — as ligações químicas, para o ligante e o sítio ativo · **Surface** — o volume ocupado; **é a única forma de ver uma cavidade**, e é assim que a garganta da AChE fica visível.

1.4 QUANDO NÃO EXISTE ESTRUTURA

Modelagem por homologia

Há centenas de milhões de sequências conhecidas e cerca de 200 mil estruturas. **Para a maioria das proteínas não há estrutura resolvida.** A premissa que salva: a estrutura é mais conservada pela evolução do que a sequência.

Os quatro passos

1. **Buscar molde:** BLAST da sua sequência contra o PDB
2. **Alinhar** alvo e molde — **é aqui que os erros nascem**
3. **Construir:** copiar o esqueleto e refazer alças e cadeias laterais
4. **Validar:** GMQE, QMEANDisCo, Ramachandran

A regra da identidade

Identidade	Qualidade
> 50%	Muito bom, como média resolução
30–50%	Útil, erros em alças e cadeias laterais
< 30%	Zona crepuscular — alto risco

SWISS-MODEL — servidor web do Instituto Suíço de Bioinformática: cole a sequência e ele faz tudo. **MODELLER** — linha de comando, mais controle, motor de muitos servidores.

Um alinhamento deslocado produz um modelo errado com aparência perfeita

1.4 PREDIÇÃO POR APRENDIZADO PROFUNDO

AlphaFold

Como funciona, em uma frase: o método monta um **alinhamento múltiplo de milhares de sequências homólogas** e aprende que **pares de posições que mutam juntos ao longo da evolução provavelmente estão próximos no espaço 3D**. Essas restrições de contato são convertidas em coordenadas por uma rede neural.

AlphaFold DB

Mais de 200 milhões de modelos prontos, todo o proteoma humano incluído. Para a maioria das proteínas, **é só baixar**.

ColabFold

Roda AlphaFold2 de graça no Google Colab, em minutos. A porta de entrada para **sequências novas** — uma proteína que você sequenciou.

Boltz · Chai-1 · AF3

Geração seguinte: preveem também complexos com ligantes, DNA e RNA. Boltz e Chai são **abertos**.

Em 2024 o Prêmio Nobel de Química foi atribuído a trabalhos nessa área — David Baker pelo desenho de proteínas, Demis Hassabis e John Jumper pela predição de estrutura.

1.4 LER A CONFIANÇA DE UM MODELO PREVISTO

pLDDT e PAE

pLDDT

Confiança **local**, de 0 a 100, resíduo por resíduo.

- > 90 — muito alta
- 70–90 — boa, esqueleto confiável
- 50–70 — baixa
- < 50 — **provavelmente região desordenada**: não é erro, é proteína sem forma fixa

PAE

Confiança na **posição relativa** entre dois trechos, em ångström, como uma matriz.

- Blocos de PAE baixo — domínios rígidos, bem posicionados entre si
- PAE alto entre dois blocos — o modelo **não sabe a orientação relativa** entre esses domínios

A pegadinha do B-factor

Nos modelos do AlphaFold, o campo do B-factor do arquivo PDB foi **reaproveitado para guardar o pLDDT**. Colorir por B-factor mostra a confiança — azul confiável, laranja não. Mas a interpretação **se inverte**: no cristal, B alto é ruim; no modelo previsto, valor alto é bom. Aplicar a regra da cristalografia a um modelo previsto leva à conclusão oposta à correta.

1.4 LIMITAÇÕES HONESTAS

O que o AlphaFold *não* faz

Prevê **uma** conformação, o estado mais populado. Não prevê o movimento nem estados alternativos.

Não prevê, por si só, **ligantes, íons, cofatores** nem modificações pós-traducionais.

Não prevê de forma confiável o efeito de uma **mutação pontual** na estabilidade.

Cadeias laterais do sítio ativo podem estar em **rotâmeros errados** — e isso **degrada o docking**.

A decisão prática

Existe estrutura experimental de boa resolução, com ligante parecido com o seu, do organismo certo? **Use a experimental.** Não existe? Use AlphaFold ou homologia — e **declare isso claramente na metodologia** do seu artigo.

1.5 DOCKING MOLECULAR

Duas perguntas sobre um par proteína–molécula

PERGUNTA 1

Pose

Em que **posição e orientação** o ligante se encaixa no sítio? Qual conformação ele assume lá dentro?

PERGUNTA 2

Score

Qual a **estimativa de energia** dessa interação, em kcal/mol? Valores negativos são favoráveis.

Analogia: é um problema de encaixe de peças com tolerância *e* com química — encontrar a chave certa para uma fechadura, sabendo que tanto a chave quanto a fechadura são um pouco flexíveis.

1.5 COMO QUALQUER PROGRAMA DE DOCKING FUNCIONA

Duas engrenagens — e as ferramentas abertas

1 · Algoritmo de busca

Explora 3 translações + 3 rotações + um ângulo por **ligação rotacionável**. A donepezila tem 6 — ou seja, um espaço de **12 dimensões**. Por isso a busca é estocástica (Monte Carlo, algoritmos genéticos), **não** exaustiva.

2 · Função de pontuação

Estima a energia de cada pose somando termos: repulsão estérica, van der Waals, ligações de hidrogênio, efeito hidrofóbico, eletrostática e penalidade de entropia conformacional.

Ferramenta aberta	Característica
AutoDock Vina	O mais usado do mundo. Rápido, código aberto, precisão boa. É o que usaremos (versão 1.2.5)
AutoDock4 / ADT	Geração anterior, mais configurável e mais lenta; ADT é a interface gráfica clássica de preparação
Smina · GNINA	Forks do Vina: o primeiro permite customizar a pontuação, o segundo faz rescoring por rede neural
Open Babel	Canivete suíço de conversão de formatos; adiciona hidrogênios e calcula cargas
Meeko · RDKit	Preparação de ligante recomendada pelos próprios autores do Vina — melhor que o Open Babel nesse papel

Todas livres ou gratuitas para uso acadêmico

1.5 O FLUXO DE TRABALHO

Seis passos, sempre nesta ordem

1 · Receptor	baixar do PDB → escolher **uma** cadeia → remover águas e ligantes → adicionar hidrogênios → gerar .pdbqt com cargas
2 · Ligante	baixar do PubChem → gerar conformação 3D → protonação em pH 7,4 → marcar torções → gerar .pdbqt
3 · Caixa	definir centro e dimensões da região onde o programa vai procurar
4 · Rodar	*exhaustiveness*, *num_modes*, *energy_range*, **seed**
5 · Validar	**redocking → RMSD.** O passo que todo mundo pula e o avaliador cobra
6 · Analisar	visualizar a pose e mapear as interações com os resíduos do sítio

1.5 OS PARÂMETROS QUE VOCÊ VAI AJUSTAR

A caixa decide *onde*; o esforço decide *quanto*

A caixa de busca

Dirigido: caixa de 20–25 Å centrada no sítio ativo conhecido. Mais rápido e mais confiável — é o padrão.

Cego: caixa cobrindo a proteína inteira, quando o sítio é desconhecido. Muito mais ruidoso.

Como achar o centro: se o cristal já traz um ligante no sítio, basta o **centro geométrico desse ligante** — de **uma única cadeia**. É o que faremos.

Regra da aresta: maior dimensão do ligante + cerca de 8 Å.

exhaustiveness

Quantas buscas independentes. Padrão 8; 16 ou 32 dão resultados mais reprodutíveis e são mais lentos.

num_modes · energy_range

Quantas poses retornar (padrão 9) e a diferença máxima de energia entre elas.

seed

A semente do gerador aleatório. **Docking é estocástico:** fixá-la é o que torna o seu resultado reproduzível por outra pessoa.

1.5 VALIDAÇÃO

Retire o ligante do cristal e peça ao programa que o recoloque

< 2,0 Å

de RMSD entre a pose prevista e a pose real = **protocolo validado**

2–3 Å — parcialmente correto: orientação certa, detalhes errados

> 3 Å — o protocolo não serve para esse alvo: revise preparação, caixa e protonação

Sem esse passo, um score de −9,5 kcal/mol **não significa nada**.

A armadilha lógica: o redocking valida o **protocolo**, não o **score**. Um RMSD de 0,3 Å prova que o seu pipeline encontra a pose certa quando ela existe; não prova que o número em kcal/mol corresponde à afinidade medida. São duas afirmações diferentes.

1.5 LIMITAÇÕES — LEIA DUAS VEZES

Cinco coisas que o docking não faz

1 · Score ≠ afinidade

A correlação com Ki e IC50 medidos é modesta. Docking **classifica e prioriza**; não mede afinidade.

2 · Receptor rígido

Na realidade a proteína se adapta ao ligante (*induced fit*). Explica muitos falsos negativos.

3 · A água é ignorada

Solvente implícito — mas há casos em que uma molécula de água faz a ponte essencial entre ligante e proteína.

4 · Protonação importa muito

Um nitrogênio protonado ou não em pH 7,4 muda toda a eletrostática. **A maioria dos dockings ruins começa numa preparação ruim, não no algoritmo.**

5 · Entropia e dessolvatação

Tratadas de forma muito aproximada pela função de pontuação.

Em resumo

Docking é um **filtro barato e rápido** no topo de um funil. A confirmação vem da dinâmica molecular, dos métodos de energia livre e, no fim, do laboratório.

Os itens 2 e 3 são exatamente o que a dinâmica molecular vem corrigir

1.6 DINÂMICA MOLECULAR

Docking entrega uma fotografia. A proteína real é um filme.

A dinâmica molecular calcula esse filme resolvendo **F = ma** para cada átomo, em passos de cerca de 2 femtossegundos, repetidamente, milhões de vezes.

O campo de força

As forças não vêm da mecânica quântica — seria caro demais. Vêm de equações clássicas simples: **molas** para ligações e ângulos, **cossenos** para torções, **Lennard-Jones + Coulomb** para o resto, com milhares de parâmetros ajustados.

Famílias: AMBER, CHARMM, OPLS-AA, GROMOS.

O ponto frágil

Os campos de força foram parametrizados para aminoácidos, ácidos nucleicos e água. **O seu ligante não estava na lista.**

Para ele usam-se extensões — GAFF, CGenFF — e **parametrizar um ligante novo é uma das maiores fontes de erro em MD.**

O protocolo

preparar → solvatar → neutralizar com íons → minimizar energia → equilibrar NVT (310 K) → equilibrar NPT (1 bar) → **produção** → análise

1.6 AS ANÁLISES QUE VOCÊ VAI REPORTAR

Cinco métricas e como lê-las

Métrica	O que mede	Como ler
RMSD × tempo	Afastamento da estrutura inicial	Deve subir e estabilizar num platô. Subida contínua = não convergiu ou há transição conformacional real
RMSF por resíduo	Flexibilidade de cada resíduo	Picos em alças e terminais. Sítio ativo rígido é bom sinal
Raio de giro	Compactação global	Estável = enovelamento mantido. Crescendo = abrindo ou desenovelando
Ligações de H ligante–proteína	Persistência do complexo	Contatos mantidos em mais de 70% do tempo são os determinantes reais da ligação
SASA	Área exposta ao solvente	Queda = enterramento do ligante no sítio

GROMACS — livre, otimizado, padrão acadêmico · **OpenMM** — Python, excelente em GPU, roda no Colab

NAMD e **AMBER** — suítes consagradas · **MDAnalysis / MDTraj** — bibliotecas Python para **analisar** a trajetória

No Bloco D usaremos MDAnalysis sobre uma trajetória pública pré-calculada

1.6 O CUSTO COMPUTACIONAL, SEM ROMANTISMO

Por que ninguém simula o que gostaria

50–150 mil

átomos num sistema típico de proteína com água explícita

100–500 ns

por dia, numa GPU moderna

µs – ms

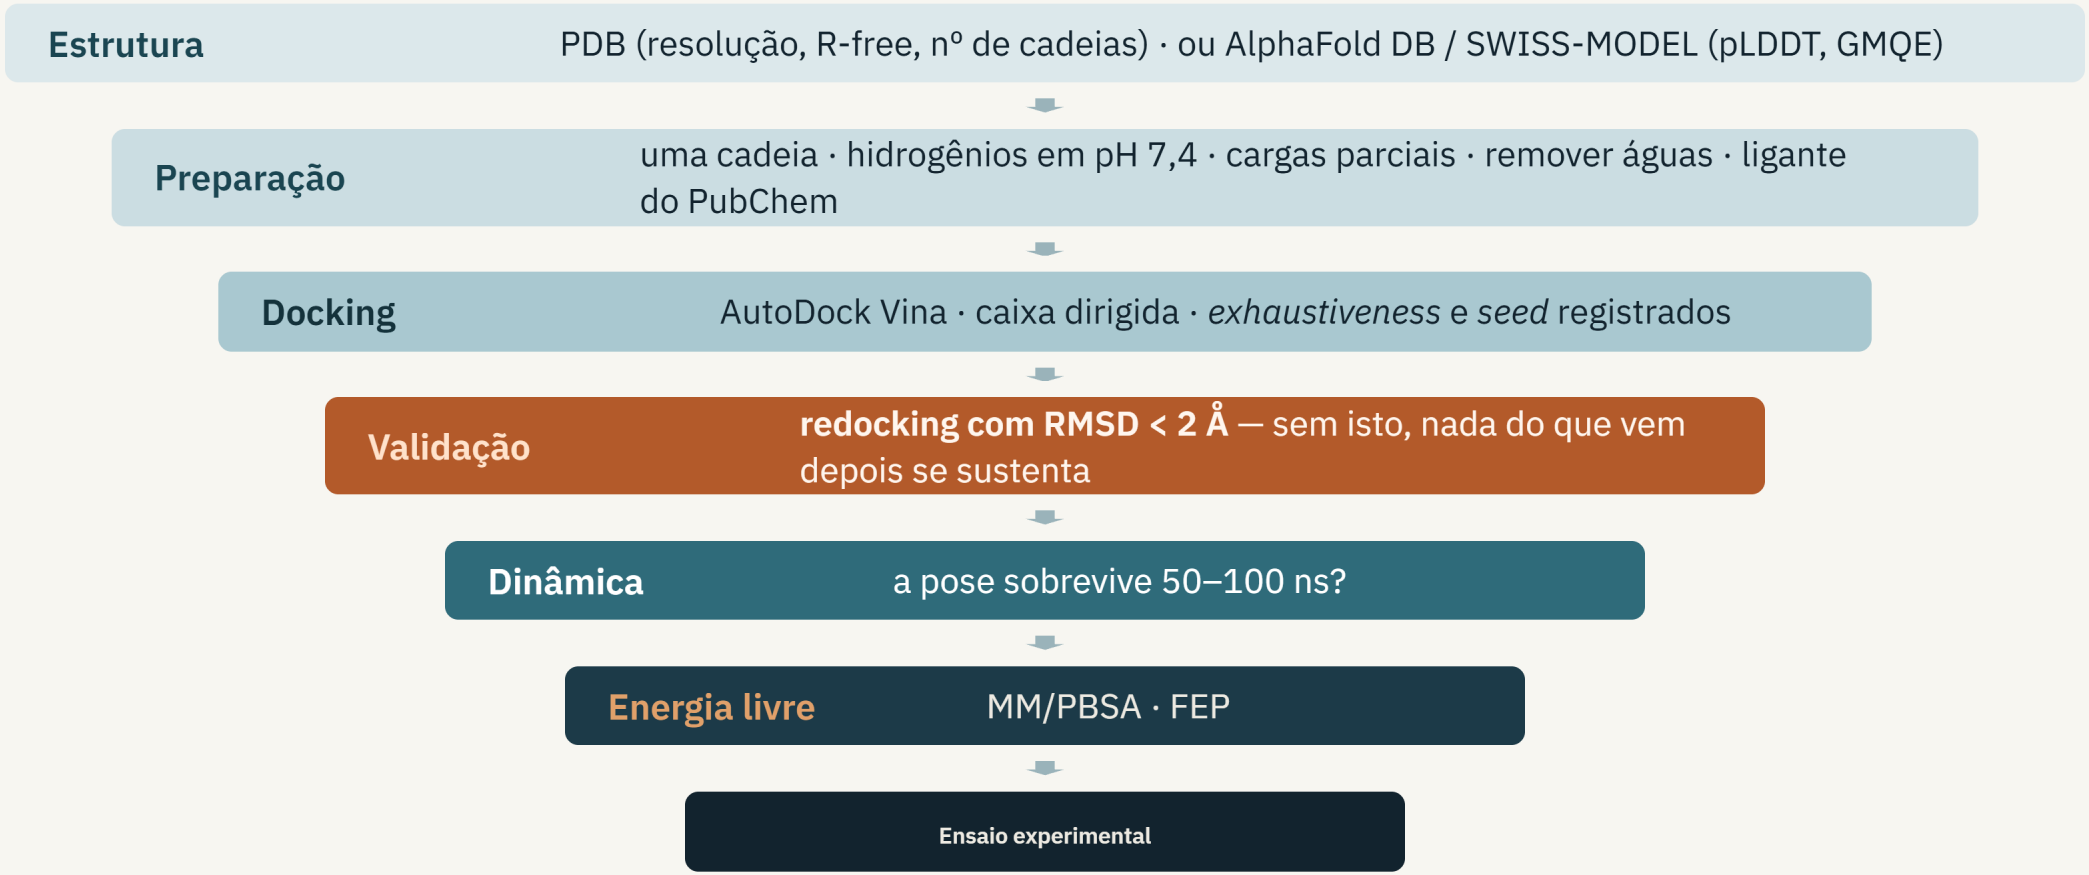
é a escala dos eventos biológicos interessantes: abertura de canal, dissociação de ligante

Fora de alcance de rotina

três ordens de grandeza separam o que se simula do que se quer observar

Portanto: **uma MD de 100 ns não prova afinidade.** Ela testa a **estabilidade** da pose que o docking propôs. É assim — e só assim — que você deve escrever no artigo.

Cada etapa é um filtro: menos candidatos, mais custo por candidato



A bioinformática estrutural não substitui o experimento — ela decide **quais** experimentos valem o dinheiro.

10 min

Intervalo

Antes de voltar, deixe pronto

Um notebook novo aberto no Google Colab · a aba do **rcsb.org** carregada · login na conta Google feito

02

Momento 2 — Prática

75 minutos. **Todos os dados são públicos. Todo o software é livre.** Alvo: acetilcolinesterase humana, PDB **4EY7** — raios X, 2,35 Å, R-free 0,211, duas cadeias, ligante E20 (donepezila).

Bloco	Tempo	Ferramenta
A — Explorar a estrutura	12 min	RCSB PDB + Mol* (só navegador)
B — Modelo previsto	15 min	AlphaFold DB + SWISS-MODEL + Biopython
C — Docking e validação	33 min	AutoDock Vina + Open Babel + RDKit
D — Trajetória de MD	15 min	MDAnalysis sobre trajetória pública

Todas as células de código desta prática **foram executadas e verificadas antes da aula**, e cada bloco traz o número esperado. Se o seu resultado divergir muito, algo deu errado na preparação — não siga adiante.

BLOCO A · 12 MIN Só navegador. Sem código.

Explorando a 4EY7 no Mol*

Anote da página de resumo

- Método experimental e **resolução**
- **R-free**
- Organismo
- **Quantas cadeias de polímero existem** — o item crítico
- Os ligantes: procure o código **E20**

No visualizador 3D

- **Conte as cópias** da proteína na tela (colora por cadeia)
- Mude para **Cartoon**: ache hélices e folhas
- Ative **Surface** e use o **corte** para ver o túnel por dentro
- Selecione **uma** E20 e clique em *Focus*
- Mostre as **interações** com os resíduos vizinhos

Perguntas de checagem

A donepezila está na superfície ou enterrada?

Quantos resíduos aromáticos você vê ao redor dela?

Localize **TRP86** (fundo) e **TRP286** (entrada). Por que tocar os dois extremos daria um inibidor potente?

Olhando as duas cópias: se você calculasse o **ponto médio** entre as duas donepezilas, ele cairia dentro de um sítio ativo? **Guarde a resposta.**

rcsb.org → buscar 4EY7 → 3D View

BLOCO B · 15 MIN AlphaFold DB · Biopython · SWISS-MODEL

Previsão contra realidade

B1 · AlphaFold DB

Busque **P22303**. Observe o modelo colorido por **pLDDT**: núcleo azul, terminais e alças laranja. Abra o gráfico **PAE** e identifique os blocos. Baixe o .pdb.

Note: vem um **monômero**, sem glicanos, sem ligante, sem águas.

B2 · Sobreposição

No Colab, com Biopython: pareamos os Cα pelo número do resíduo e calculamos o RMSD do esqueleto contra a cadeia A da 4EY7.

Esperado: 1 a 2 Å. O enovelamento global está certo.

B3 · SWISS-MODEL

Demonstração ao vivo: o docente cola uma sequência sem estrutura e mostra a seleção de molde, o **GMQE** e o **QMEANDisCo**.

Você repete isso no exercício 1, com a proteína da sua pesquisa.

A discussão que vale a aula

Se o enovelamento está certo, por que ainda é arriscado dockar no modelo do AlphaFold? Porque as cadeias laterais do sítio podem estar em rotâmeros do estado *apo*, a garganta pode estar fechada, e faltam a água e o íon estruturais. **Um RMSD global de 1 Å conviver com um sítio ativo inutilizável não é contradição — é a regra.**

alphafold.ebi.ac.uk · swissmodel.expasy.org

BLOCO C · PASSO 1 Preparar o receptor — e conferir

Filtrar por coluna, não por texto

```
# receptor: só a cadeia A, só proteína — coluna 22 = cadeia
!awk '/^ATOM/ && substr($0,22,1)=="A"' 4EY7.pdb > receptor_limpo.pdb

# ligante de referência: E20 da cadeia A APENAS — col. 18-20 = resíduo
!awk '/^HETATM/ && substr($0,18,3)=="E20" && substr($0,22,1)=="A"' \
    4EY7.pdb > ligante_cristal.pdb
```

28 átomos — correto

A donepezila é $C_{24}H_{29}NO_3$: 24 C + 1 N + 3 O = **28 átomos pesados**. É o que o cristal traz.

~56 átomos — pare

Você pegou **as duas cadeias**. O centro da caixa vai sair errado e o docking rodará sem reclamar. Volte ao filtro.

Removemos as águas porque o Vina usa solvente implícito, o ligante para não entupir o sítio, e a cadeia B porque **um receptor é uma proteína**.

Conferência de 5 segundos que separa um docking válido de um resultado sem sentido

BLOCO C · A ARMADILHA DAS FLAGS

Duas opções que custam horas

```
!obabel -ipdb receptor_limpo.pdb -opdbqt -O receptor.pdbqt \
        -xr -p 7.4 --partialcharge gasteiger
```

Opção	O que faz de verdade
-xr	Escreve o receptor como molécula rígida, sem árvore de torções. Obrigatório
-p 7.4	Adiciona hidrogênios conforme a protonação esperada em pH 7,4
--partialcharge gasteiger	Calcula as cargas parciais. Sem ela, o arquivo sai com todas as cargas = 0,000 e a eletrostática do docking desaparece
(sem -xh)	O padrão remove os hidrogênios apolares e mantém os polares — o modelo de átomos unidos que o Vina espera

-xh não é "só hidrogênios polares"

No Open Babel 3 significa *preserve hydrogens*: mantém **todos**, inclusive os apolares que o Vina não quer.

-d apaga todos os hidrogênios

Combinada com **-p 7.4**, desfaz o que acabou de ser feito: os nitrogênios doadores viram aceptores (tipo NA).

O teste controlado

Mesmo receptor: com **-xr -p 7.4** → **509 hidrogênios polares**. Com **-xr -xh -d** → **zero**.

O arquivo "funciona" nos dois casos — só um deles está certo

BLOCO C · PASSOS 2 E 3 O ligante e a caixa de busca

De um texto a uma molécula 3D

```
# SMILES copiado do PubChem (CID 3152)
mol = Chem.MolFromSmiles(smiles)
mol = Chem.AddHs(mol)
AllChem.EmbedMolecule(mol, randomSeed=42)
AllChem.MMFFOptimizeMolecule(mol)
```

SMILES é a notação em texto de uma molécula. O **RDKit** a transforma em coordenadas 3D e otimiza a geometria; o **Open Babel** adiciona as cargas e marca as torções que o Vina poderá girar.

Confira a fórmula: $C_{24}H_{29}NO_3$, massa 379,5 g/mol, **6 ligações rotacionáveis**. Um SMILES colado errado produz uma molécula parecida que roda sem erro.

O centro da caixa

É o **centro geométrico** do ligante cristalográfico — lido das colunas fixas 31-38, 39-46 e 47-54.

A célula imprime o número de átomos lidos. Deve ser 28.

O tamanho: 22 × 22 × 22 Å

Grande o bastante para o ligante girar livremente, pequena o bastante para não desperdiçar busca.

Regra da aresta: maior dimensão do ligante + cerca de 8 Å.

Na vida real, prefira o Meeko (com RDKit) à preparação de ligante pelo Open Babel

BLOCO C · PASSOS 4 E 5 Rodar e validar

Cerca de um minuto por ligante

```
!./vina --receptor receptor.pdbqt --ligand ligante.pdbqt \
  --center_x {cx} --center_y {cy} --center_z {cz} \
  --size_x 22 --size_y 22 --size_z 22 \
  --exhaustiveness 16 --num_modes 9 --seed 42 \
  --out poses.pdbqt
```

```
# redocking
!obabel -ipdbqt poses.pdbqt \
  -opdb -O pose_melhor.pdb -f 1 -l 1
!obrms ligante_cristal.pdb \
  pose_melhor.pdb
```

Lendo a tabela de saída

mode 1 é a melhor pose segundo o score. As colunas de RMSD medem a distância **entre as poses** — não em relação ao cristal. Um valor grande entre os modos 1 e 2 significa duas soluções geometricamente distintas: vale olhar as duas.

RMSD 0,26 Å

foi o que este mesmo pipeline obteve no caso-teste de referência verificado antes da aula. **O protocolo funciona.**

Se o seu redocking der mais de 2 Å, o problema está na **sua** preparação — muito provavelmente no centro da caixa ou nas cargas do receptor.

O obrms pareia os átomos por grafo antes de calcular o RMSD — um RMSD “ingênuo” erraria

BLOCO C · PASSO 6 Triagem comparativa

Três inibidores da mesma enzima

Ligante	Torções	Afinidade	Comentário
Donepezila	6	—	alta afinidade, ocupa toda a garganta
Galantamina	—	—	mais fraco, molécula rígida
Tacrina	—	—	pequena e plana, liga no fundo da garganta

A ordem do score reproduz a ordem experimental de potência?

Pista: o score do Vina tem um **viés conhecido a favor de moléculas maiores** — mais átomos significam mais termos favoráveis de van der Waals. Comparar o score bruto de uma molécula de 28 átomos com uma de 15 é comparar coisas diferentes. Daí existirem métricas normalizadas pelo tamanho, como a **ligand efficiency** = −ΔG ÷ nº de átomos pesados.

Para o trabalho final: os dois scripts da disciplina

convert_to_pdbqt.py — converte pastas inteiras de .sdf, .mol2, .pdb e .cif para PDBQT, detectando ligante ou receptor, com Meeko + RDKit · **vina_docking.py** — roda o Vina em lote no produto **todos os ligantes × todas as proteínas**, com um único config.txt, retomada automática e saída em CSV.

BLOCO D · 15 MIN MDAnalysis sobre trajetória pública

Analisar uma trajetória pronta

Uma simulação de verdade não cabe em 15 minutos: o complexo AChE–donepezila solvatado tem ~100 mil átomos e 100 ns levariam horas de GPU. Vamos então **ler os gráficos** — que é a habilidade transferível.

O conjunto de dados

A trajetória de referência que **acompanha a própria biblioteca MDAnalysis**: a **adenilato quinase** de *E. coli* (estrutura 4AKE). Público, citável e já instalado — ninguém baixa nada.

3.341 átomos · 214 resíduos · 98 quadros · 97 ps

Por que a AdK e não a AChE?

Porque ela faz, em 1 ns, algo que a AChE não faria: **abre os seus domínios de forma visível**.

É um dos exemplos didáticos mais usados do mundo justamente porque mostra, em poucos quadros, a diferença entre **"o sistema não convergiu"** e **"está acontecendo uma transição conformacional real"** — a interpretação mais difícil e mais cobrada em MD.

Nota metodológica obrigatória: o alinhamento da trajetória vem **antes** do RMSF. Sem alinhar, você mede o movimento da proteína **como corpo rígido pela caixa de simulação** — translação e rotação globais — e não a flexibilidade interna. Os números saem grandes, plausíveis, e não querem dizer nada.

Três gráficos: RMSD × tempo · raio de giro · RMSF por resíduo

BLOCO D · A INTERPRETAÇÃO

O RMSD não faz platô. Isso é falha ou é função?

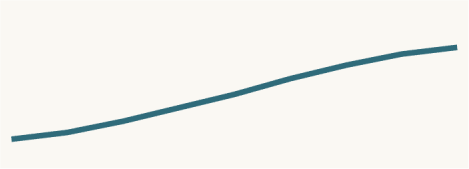
1 · RMSD × tempo



Sobe continuamente até **~6,8 Å** e **não** estabiliza.

Em um complexo equilibrado isso significaria “não convergiu, simulação inútil”.

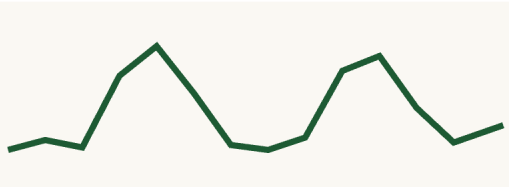
2 · Raio de giro



Cresce de **16,7 Å** para **19,6 Å**.

A proteína ficou **mais aberta**, mas manteve a estrutura secundária: é **abertura de domínios**, não desenovelamento.

3 · RMSF por resíduo



Média **1,9 Å**, máximo **5,7 Å** perto do **resíduo 149**.

Os picos se concentram nos domínios móveis; o **núcleo permanece rígido**.

A lição transferível: a leitura correta de uma trajetória nunca vem de um gráfico só. O RMSD disse que algo grande aconteceu; o raio de giro disse *o que* aconteceu; o RMSF disse *onde*. É esse trio que você usaria para argumentar que o seu sítio ativo é estável enquanto a periferia respira.

Curvas esquemáticas — a forma é a dos valores obtidos na execução de verificação

03

Momento 3 — Integração e fechamento

20 minutos. Costurar cada conceito ao que apareceu na tela, listar os erros que custam uma banca, e transformar isso em método para o artigo final.

3.1 COSTURANDO TEORIA E PRÁTICA

Cada conceito, pelo que você viu na tela

Na teoria falamos de...	Na prática você viu...
Resolução e R-free	4EY7 a 2,35 Å, R-free 0,211 — boa o bastante para docking
Unidade assimétrica e cadeias	A 4EY7 tem duas AChE; filtrar a cadeia A foi o que salvou o centro da caixa
Colunas de largura fixa do PDB	Por que filtramos por posição de coluna e não procurando um texto
B-factor	No cristal é mobilidade; no AlphaFold o mesmo campo guarda o pLDDT — e a interpretação se inverte
A garganta aromática	A cavidade revelada pela representação de superfície com corte
Modelagem ≠ experimento	Enovelamento correto (RMSD 1–2 Å), mas cadeias laterais do sítio incertas
Protonação e cargas	-p 7.4 e --partialcharge gasteiger; sem eles, receptor sem doadores de H e com carga zero
Ligações rotacionáveis	As 6 torções marcadas no PDBQT e giradas pelo Vina durante a busca
Função de pontuação	A coluna affinity — uma estimativa, não uma medida — e seu viés a favor de moléculas grandes
Validação	O redocking de 0,26 Å; sem ele, o número não tem valor
Receptor rígido	A razão de passarmos para MD: deixar a proteína responder ao ligante
Convergência	O RMSD que não fez platô — e o Rg que mostrou abertura de domínio, não falha
Referencial de análise	O alinhamento antes do RMSF: sem ele mede-se o movimento da caixa, não da proteína

Duas perguntas para discussão estão no roteiro, ao fim desta seção

3.2 OS OITO ERROS MAIS COMUNS

Quase todos produzem saída plausível

1. Esquecer de remover as águas — ou removê-las quando uma é estrutural e essencial
2. **Não filtrar a cadeia** — duas cópias no receptor, ou o centro calculado entre dois ligantes
3. Ignorar a protonação em pH 7,4 — ou anulá-la com uma opção contraditória
4. Gerar o receptor **sem cargas parciais** — todas zero — e não perceber
5. Caixa mal posicionada ou pequena demais: o ligante não cabe e o score “explode”
6. Estrutura de baixa resolução ou do **organismo errado**
7. **Não validar** com redocking — ou validar e tratar o redocking como se ele tivesse validado o *score*
8. Reportar o score como afinidade medida, e não registrar versões, sementes e parâmetros

Nenhum deles interrompe o programa. É por isso que o método é sempre o mesmo: **uma checagem numérica barata depois de cada passo.**

Os dois destacados são os que vimos acontecer hoje

3.3 O QUE LEVAR PARA O ARTIGO FINAL

Integrar duas técnicas — e descrever o método de forma reproduzível

Combinações naturais com esta aula

+ Sequências (Aula 2) — homólogos por BLAST, resíduos conservados que formam o sítio ativo em 3D

+ Transcriptômica (Aula 4) — um gene superexpresso vira o alvo; prever a estrutura e dockar candidatos

+ Proteômica (Aula 5) — mapear uma modificação pós-traducional na estrutura: sítio ativo, interface ou alça?

+ Epigenômica (Aula 6) — DNMT1, HDACs e EZH2 têm estrutura no PDB: feche o ciclo dockando numa delas

+ Filogenia (Aula 8) — comparar o sítio ativo entre espécies e discutir seletividade

+ Vias e redes (Aula 9) — situar o alvo numa via do KEGG ou numa rede do STRING

Checklist de metodologia

- Código PDB ou fonte do modelo + resolução e R-free (ou pLDDT/GMQE)
- **Qual cadeia** foi usada e o que foi removido
- Preparação do receptor: hidrogênios, pH, método de cargas, software **e versão**
- Origem do ligante: CID, SMILES, gerador de conformação
- Centro e dimensões da caixa
- *exhaustiveness*, *num_modes*, *seed*, nº de réplicas
- **Validação por redocking com RMSD reportado**
- Se houve MD: campo de força, modelo de água, íons, tempo, convergência e **se a trajetória foi alinhada**
- Figuras com escala, legenda e resíduos indicados

O checklist completo está no roteiro, em formato de caixas para marcar

3.4 EXERCÍCIOS · ENTREGA ATÉ A AULA 8

Quatro obrigatórios, dois desafios

1 Uma proteína da **sua** linha de pesquisa: há estrutura no PDB? Registre código, método, resolução, R-free **e número de cadeias**. Se não houver, gere no SWISS-MODEL e busque no AlphaFold DB, e compare GMQE/QMEANDisCo com o pLDDT. Meia página justificando qual usaria.

2 Refaça o docking com *exhaustiveness* **8, 16 e 32**, três vezes cada, variando a semente. Média e desvio-padrão da melhor afinidade. A partir de qual valor o resultado estabiliza? O que isso diz sobre reportar um único número com duas casas decimais?

3 Docking de **galantamina e tacrina**: compare a ordem dos scores com os IC50 publicados no **ChEMBL**. A ordem bate? Discuta as causas de divergência e calcule a *ligand efficiency* de cada um.

4 **Diagnóstico:** refaça o passo da preparação **de propósito sem filtrar a cadeia**. Relate quantos átomos o ligante "cristalográfico" passou a ter, para onde foi o centro da caixa, a afinidade reportada e o RMSD do redocking. **Este exercício existe para você ver com os próprios olhos um resultado errado que não dá erro.**

5 **Desafio:** com o **vina_docking.py**, dockar 20 ligantes do PubChem contra a 4EY7 **e** contra a butirilcolinesterase (PDB 1P0I). Discuta a seletividade — o que isso significa para um *bioscavenger*?

6 **Desafio:** na trajetória do Bloco D, conte as ligações de hidrogênio intramoleculares ao longo do tempo e verifique se a estrutura secundária se mantém durante a abertura. Confirma ou refuta a leitura de "abertura, não desenovelamento"?

Enunciados completos, com os comandos, no roteiro da aula

PARA LEVAR DA AULA 7

A bioinformática estrutural não substitui o experimento — ela decide *quais* experimentos valem o dinheiro.

O método

Cada etapa é um filtro. E depois de cada passo, uma **checagem numérica barata** — porque os erros que custam são os que produzem saída plausível.

A honestidade

Score não é afinidade. Redocking valida o protocolo, não o score. MD testa estabilidade, não afinidade. Escrever assim é o que sustenta uma banca.

A próxima aula

Aula 8 — Filogenética e evolução molecular. Vamos comparar o mesmo sítio ativo entre espécies e discutir seletividade: por que um inibidor atinge o inseto e menos o mamífero.

Roteiro completo, código verificado, glossário e referências: material de apoio da disciplina. Todas as ferramentas usadas hoje são livres ou gratuitas para uso acadêmico.