INTRODUÇÃO À BIOINFORMÁTICA · PPGED / IME

Aula 8

Filogenética e Evolução Molecular

Reconstruindo a história evolutiva a partir de sequências — do alinhamento à árvore datada

Duração

3 horas · online síncrona

Docentes

Prof. Mariana Quezado e [seu nome]

O FIO CONDUTOR DE HOJE

Quando e por onde o vírus Zika chegou às Américas?

A epidemia de 2015–2016 foi reconhecida pelos casos. Mas **desde quando o vírus já circulava**, e qual foi a rota de entrada?

A resposta não veio de entrevistas. Veio de **ler e comparar os genomas** do vírus — e é isso que vamos refazer.

Epidemiologia molecular: 34 genomas públicos do GenBank · ferramentas de código aberto

Mapa da aula · 3 horas

00:00 – 01:15

1 · Teoria

Filogenia, homologia e alinhamento; métodos de árvore; modelos de substituição; suporte de ramo; relógio molecular.

01:25 – 02:40

2 · Prática

Hands-on no Colab com dados públicos e software livre: FASTA → alinhamento → árvore → datação.

02:40 – 03:00

3 · Integração

Costura teoria ↔ prática, erros comuns e como usar isto no artigo final.

Entre os momentos 1 e 2: **intervalo de 10 minutos** — use-o para deixar o Colab já instalado.

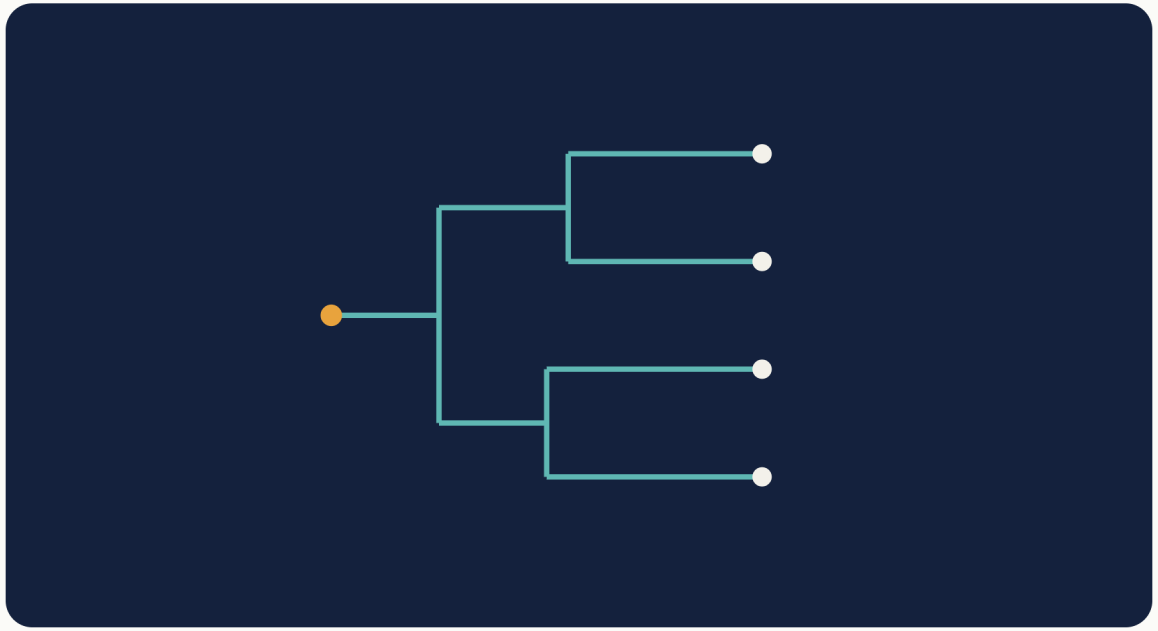
TEORIA · 1.1

O que é uma filogenia

Uma **árvore filogenética** é a hipótese de como um conjunto de sequências se relaciona pela evolução.

- **Pontas (folhas):** as sequências que observamos hoje.
- **Nós internos:** ancestrais comuns hipotéticos, não observados.
- **Comprimento do ramo:** quanto de mudança se acumulou.
- **Raiz:** a direção do tempo — onde fica o passado.

> Analogia: reconstruir a **árvore de versões** de um projeto a partir só dos arquivos finais, sem o histórico.



TEORIA · 1.1B

Como surge a diversidade

A **sistemática filogenética** busca compreender a **filogenia** — a história evolutiva da diversidade. Essa diversidade nasce de dois processos, e a árvore registra os dois.

Anagênese

Um caráter surge ou se modifica numa linhagem **ao longo do tempo** — é a fonte das novidades evolutivas.

Na árvore: o **comprimento dos ramos**.

Cladogênese

Uma linhagem **se divide em duas** que deixam de trocar genes (ex.: por uma barreira).

Na árvore: os **nós** (as ramificações).

No presente só enxergamos um **corte temporal** dessa história (Hennig, 1966): as pontas de hoje. A filogenética reconstrói o que veio antes — os nós e os ramos que não observamos.

TEORIA · 1.2

Homologia molecular

Homologia = semelhança por descendência de um ancestral comum. Toda a filogenética compara caracteres homólogos. Em nível molecular, há **duas formas** de dois genes serem homólogos — e só uma serve para reconstruir a história das espécies.

Ortólogos ✓

Genes separados por **especiação** (cladogênese). O mesmo gene em espécies diferentes.

Contam a história das **espécies** — é o que queremos.

Parálogos ⚠

Genes originados por **duplicação** dentro de um mesmo genoma.

Contam a história dos **genes**, não das espécies.



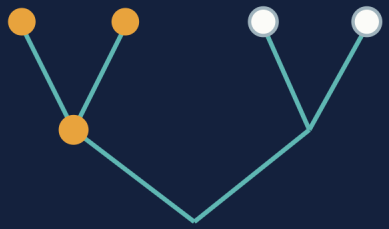
Misturar ortólogos e parálogos no mesmo alinhamento gera **parentescos falsos**. Por isso, no exercício final, o primeiro passo é garantir que suas sequências são realmente ortólogas.

TEORIA · 1.3

Caracteres e polarização

Cada caráter tem uma **série de transformação**: do estado mais antigo ao mais recente. O que indica parentesco não é qualquer semelhança — é a semelhança **derivada compartilhada**.

Plesiomorfia	estado **antigo** (ancestral)
Apomorfia	estado **novo** (derivado)
Sinapomorfia	apomorfia **compartilhada** → indica parentesco
Simplesiomorfia	plesiomorfia compartilhada → **não** indica
Autapomorfia	apomorfia exclusiva de um só táxon



● laranja = apomorfia · ○ = plesiomorfia. O nó laranja é a **sinapomorfia** que une os dois.

Como saber qual é a apomorfia? Pela **polarização**: o estado presente no **grupo externo** é o plesiomórfico. Isso é exatamente o **enraizamento** que faremos na prática.

TEORIA · 1.4

Homoplasia: o sinal falso

Homoplasia = estado semelhante adquirido de forma **independente**, não por herança de um ancestral comum. Parece sinapomorfia, mas engana: sugere um parentesco que não existe.

Convergência

Estados diferentes chegam a um resultado parecido em linhagens distintas. Ex.: asa de ave × asa de inseto.

Paralelismo

A mesma condição ancestral se modifica de forma idêntica em duas linhagens separadas.

Reversão

Um estado derivado volta a se parecer com o ancestral.

Como separar sinapomorfia de homoplasia? Pela **congruência**: sinapomorfias verdadeiras concordam entre si; homoplasias geram conflito. A **parcimônia** e o **bootstrap** são formas de lidar com esse conflito.

No nível **molecular**, a homoplasia mais comum é a **substituição múltipla no mesmo sítio** (uma base muda e depois volta). É para corrigir isso que existem os **modelos de substituição** — o próximo tópico.

TEORIA · 1.5

Que grupos a árvore define

Monofilético ✓

Um ancestral e **todos** os seus descendentes.

Definido por **sinapomorfias**. É o grupo "natural".

Parafilético

Um ancestral e **alguns** descendentes (exclui um ramo).

Baseado em simplesiomorfias. Ex.: "répteis" sem as aves.

Polifilético

Táxons **sem** um ancestral comum exclusivo.

Agrupados por homoplasias (semelhança enganosa).

Na prática de hoje, o **clado americano do Zika** é **monofilético** (bootstrap ≈ 92%): contém exatamente as 24 cepas americanas, e só elas. Em linguagem cladística, elas compartilham **sinapomorfias** — o que sustenta a hipótese de uma **introdução única** no continente.

TEORIA · 1.2

Antes de tudo: alinhar

Os genomas têm comprimentos diferentes. "A posição 2.500 de um" não é "a posição 2.500 de outro". O **alinhamento múltiplo (MSA)** insere lacunas até que cada **coluna** contenha posições **homólogas** — que vêm do mesmo ancestral.

SEM ALINHAR

ACGT**GAC**TTA
AC**GAC**TTAGG
ACGTTTA

Colunas desalinhadas: comparar isto é comparar coisas não homólogas.

DEPOIS DO MAFFT

ACGT**GAC**TTA--
AC--**GAC**TTAGG
ACGT--TTA--

Mesmo comprimento; cada coluna é uma posição evolutiva comparável.

⚠ Um alinhamento ruim gera uma árvore errada **com aparência perfeita**. É a etapa mais crítica e mais subestimada. Ferramenta de hoje: **MAFFT**.

TEORIA · 1.3

Quatro formas de construir a árvore

Método	Como funciona	Compromisso
Distância (NJ)	Matriz de distâncias entre pares → árvore	Muito rápido; perde informação
Parcimônia (MP)	Menor nº de passos (navalha de Occam)	Intuitivo; erra com ramos desiguais
Verossimilhança (ML)	Árvore que torna os dados mais prováveis, dado um modelo	Padrão atual · é o que usamos
Bayesiana (BI)	Distribuição de árvores + probabilidade posterior	Robusto; mais lento (BEAST)

jModelTest — escolhe o modelo evolutivo por verossimilhança

MEGA · PHYLIP · TOPALi — suítes clássicas (muitas, clicando)

IQ-TREE 2 — motor de ML reprodutível, roda na prática de hoje

TEORIA · 1.4

Modelos de substituição

Nem toda troca é igual: **transições** (A↔G, C↔T) são muito mais comuns que **transversões**. Ignorar isso subestima as mudanças em ramos longos. O modelo é a matriz de taxas que corrige esse viés.

JC69 — tudo igual (o mais ingênuo)

K2P — distingue transição/transversão

HKY · TN93 — + frequências de base desiguais

GTR — o mais geral: 6 taxas livres

Dois "temperos"

+I — uma fração de colunas **nunca** muda (sítios essenciais)

+G — as demais evoluem a velocidades diferentes (gama)

Como escolher? O **ModelFinder** (-m MFP) testa dezenas e decide pelo **BIC**, que pune complexidade em excesso.

Na prática, o ModelFinder escolhe **TN+F+I** para o Zika — e o "+I" traduz o que veremos: a maioria das colunas não varia. (O **jModelTest** é o equivalente clássico, usado à parte antes do MEGA/PHYLIP.)

TEORIA · 1.5

Quão confiável é cada ramo?

Uma árvore **sempre** sai — até de dados sem sinal. O **bootstrap** reamostra os sítios (colunas) do alinhamento gerando centenas de **pseudoréplicas**, reconstrói a árvore em cada uma e conta em que % delas cada agrupamento reaparece.

≥ 95%

Ramo bem sustentado — confiável

80–95%

Sustentação moderada

< 80%

Fraco — trate com cautela

Interpretação honesta: bootstrap alto = **os dados são consistentes** com aquele agrupamento, não que ele seja uma verdade absoluta. Ramos internos curtos com suporte baixo devem ser **relatados, não escondidos**. O IQ-TREE usa o **bootstrap ultrarrápido (UFBoot, -B 1000)**.

TEORIA · 1.6

Enraizar: onde fica o passado

A árvore de ML é **não enraizada**: mostra parentescos, mas não a direção do tempo. Enraizar define o ancestral de todos — e **muda todas as datas** dos nós.

Grupo externo (outgroup)

Inclui-se uma linhagem sabidamente mais distante; a raiz vai no ramo que a separa do resto. **Preferível** quando se tem um bom grupo externo.

Hoje: as cepas asiáticas (2013), as mais basais.

Ponto médio (midpoint)

Sem grupo externo, põe-se a raiz no meio do maior caminho entre duas pontas.

Aproximação: supõe taxas parecidas entre linhagens.

Uma raiz mal colocada produz datas sem sentido (às vezes "taxa negativa"). Por isso, na prática, você vai **testar o efeito de trocar a raiz** — e artigos sérios justificam o enraizamento.

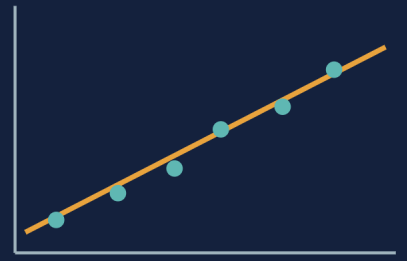
TEORIA · 1.7

O relógio molecular

Os ramos estão em **substituições por sítio**. Para dizer "quando", precisamos de **anos**.

> Se as mutações se acumulam a uma taxa ~constante, amostras **mais recentes** acumularam **mais substituições** desde a raiz.

- **Root-to-tip:** distância à raiz × data; o R^2 mede o sinal.
- **tMRCA:** a idade do ancestral comum de um clado.
- **Ferramentas:** TreeTime (rápido) · BEAST (bayesiano).



eixo x: data de coleta · eixo y: distância à raiz. A inclinação é a **taxa de evolução**.

Vírus de RNA, como o Zika: **~10^{-3}** substituições/sítio/ano.

PAUSA

Intervalo · 10 min

Aproveite para abrir o Colab e rodar a **primeira célula de instalação** do notebook **Aula08_Filogenetica_Pratica.ipynb** — ela leva 1–2 minutos.

PRÁTICA · VISÃO GERAL

O pipeline de hoje

34 genomas completos do vírus Zika (GenBank, 2013–2016), do tutorial público Nextstrain. Tudo no navegador, tudo em software livre.

A · Dados
Carregar e inspecionar
Biopython

▷

B · Alinhar
MSA dos genomas
MAFFT

▷

C · Árvore
ML + modelo + bootstrap
IQ-TREE 2

▷

D · Enraizar
Ler e testar monofilia
Biopython

▷

E · Datar
Relógio e tMRCA
TreeTime

Todas as células foram **executadas e verificadas** antes da aula (MAFFT 7.505 · IQ-TREE 2.3.6 · TreeTime 0.12.1). Se o seu número divergir muito, algo deu errado — pare e confira.

PRÁTICA · RESULTADOS REAIS

O que a análise devolveu

MODELO ESCOLHIDO

TN+F+I

ModelFinder, por BIC. O "+I" confirma: quase tudo conservado.

CLADO AMERICANO

24 / 24

Monofilético · bootstrap **≈ 92%**. Introdução única.

RELÓGIO MOLECULAR

$1{,}2 \cdot 10^{-3}$

subst./sítio/ano · $R^2 \approx 0{,}75$ (há sinal temporal)

tMRCA DAS CEPAS AMERICANAS

~ meados de 2014

Estimativa central ≈ maio/2014 · **IC 95% no 1º semestre de 2014**. Mais de um ano antes do reconhecimento oficial da epidemia.

A RESPOSTA DA PRÁTICA

O vírus circulou nas Américas por cerca de um ano antes de ser detectado

O ancestral comum de todas as cepas americanas data de ~meados de 2014 — antes do reconhecimento oficial em 2015. A combinação **genomas + datas + filogenética** enxergou uma circulação silenciosa que a vigilância tradicional não viu em tempo real. É a mesma conclusão dos estudos publicados sobre o surto.

Honestidade metodológica: 34 genomas são poucos; o IC é largo e as datas dependem do modelo e do enraizamento. A mensagem robusta é a **ordem de grandeza** — ~1 ano de circulação críptica. Reportar o intervalo, não só o número central, é parte da análise.

FECHAMENTO · 3.2

Os erros que o avaliador cobra

1. Confiar num **alinhamento ruim** sem olhar o MSA.
2. Não escolher o modelo — **deixe o ModelFinder** decidir.
3. Reportar a árvore **sem o suporte** de ramo.
4. Tratar bootstrap alto como **verdade absoluta**.
5. Falar de "ancestral" e datas com a árvore **mal enraizada**.
6. Datar **sem checar o sinal** de relógio (R^2).
7. Dar o tMRCA sem IC, e não registrar **versões e seed**.
8. Nunca **testar o protocolo** com um caso conhecido, nem repetir em outra ferramenta.

Métodos com reamostragem são estocásticos: sem **--seed** e sem o modelo anotados, ninguém repete o seu resultado.

FECHAMENTO · 3.3

Levando para o artigo final

O trabalho final integra **ao menos duas técnicas** da disciplina. A filogenética combina naturalmente com:

+ Sequências (Aula 2)

Homólogos por BLAST → árvore; separar parentesco real de contaminação.

+ Estrutural (Aula 7)

Resíduos conservados na árvore → mapeá-los no sítio ativo 3D.

+ Filogeografia

Origem e dispersão de um patógeno a partir de genomas datados.

Checklist de métodos — o que não pode faltar

- Fonte das sequências + acessos + datas
- Alinhador e **versão**; trimming, se houve
- Método (ML/BI), programa e versão
- Modelo e como foi escolhido (BIC)
- Tipo e nº de réplicas de suporte
- **Seed** e enraizamento (qual, por quê)
- Datação: taxa, R^2 e **tMRCA com IC**
- Figura com escala, suportes e clados

SÍNTESE

Sequências viram história — e, com datas, viram calendário

O caminho que percorremos

alinhar → inferir por ML → escolher o modelo → medir o suporte → enraizar → datar. Cada passo, uma decisão que o artigo precisa justificar.

Ferramentas livres

MAFFT · jModelTest · IQ-TREE 2 · MEGA · PHYLIP · TOPALi · MrBayes / BEAST · TreeTime · Jalview · iTOL. Dados: GenBank / Nextstrain.

Exercícios no roteiro · entrega até a próxima aula
Notebook: **Aula08_Filogenetica_Pratica.ipynb**