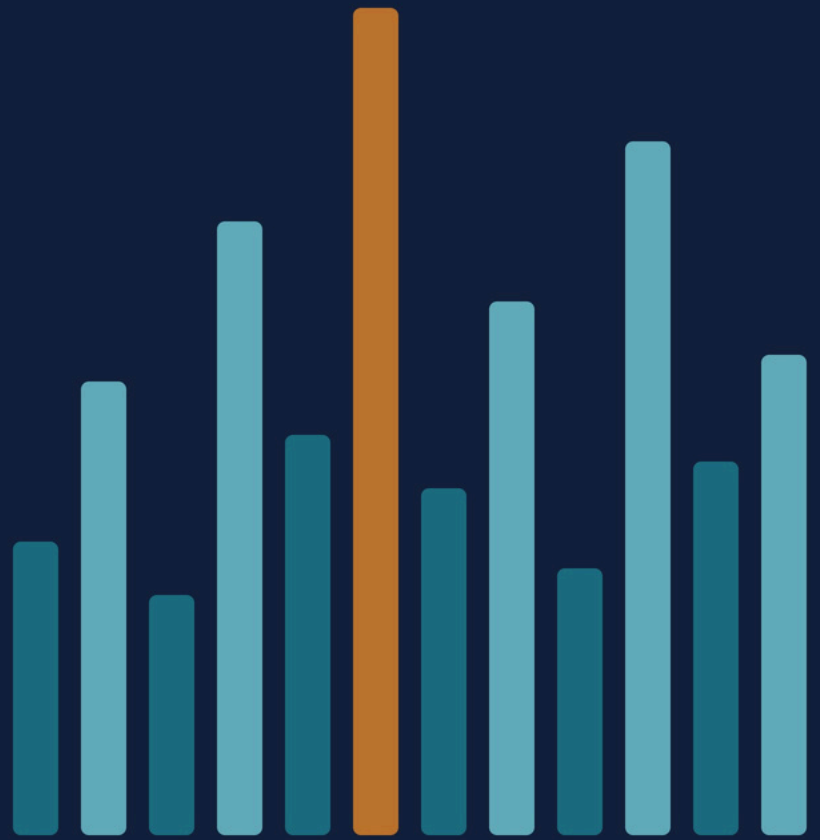
INTRODUÇÃO À BIOINFORMÁTICA · PPGED / IME

Aula 4

Transcriptômica

RNA-seq e análise de expressão diferencial: do tubo de ensaio à lista de genes que mudaram



Duração

2 horas · online síncrona

Docentes

Mariana Quezado e Roberto Filho

MAPA DA AULA · 2 HORAS

Três momentos e um intervalo

0:05 – 0:55

1 · Teoria

Transcriptoma, RNA-seq, ferramentas e estatística em quatro blocos

0:55 – 1:05

Intervalo

Deixe o Colab instalando os pacotes

1:05 – 1:50

2 · Prática

DESeq2 no Google Colab com dados reais de células humanas

1:50 – 2:00

3 · Conexão

Cada célula ligada a um conceito, e fechamento

Ferramentas de hoje: **HISAT2 · STAR · Trinity · Ensembl · DESeq2 · edgeR**. Na prática, só o navegador.

FIO CONDUTOR DA AULA

“Como sair de um tubo com células e chegar a uma lista confiável dos genes que mudaram de atividade?”

Cada bloco da teoria responde a um pedaço desta pergunta. A prática percorre o trecho final, da tabela de contagens à lista de genes.

MOMENTO 1 · 0:05 – 0:55

Teoria

1 · Por que o transcriptoma
2 · Do tubo de ensaio aos dados
3 · Mapear ou montar
4 · Da contagem à descoberta

BLOCO 1 · UMA PERGUNTA PARA COMEÇAR

Todas as suas células têm o mesmo DNA. Por que um neurônio é tão diferente de uma célula do fígado?

A resposta não está no DNA que a célula *tem*, mas nas partes dele que ela está *usando*.

BLOCO 1 · POR QUE O TRANSCRIPTOMA

A analogia da biblioteca de manuais

GENOMA

A biblioteca completa da fábrica

Todo o DNA do organismo. É o mesmo em todas as células e quase não muda ao longo da vida.

TRANSCRIPTOMA

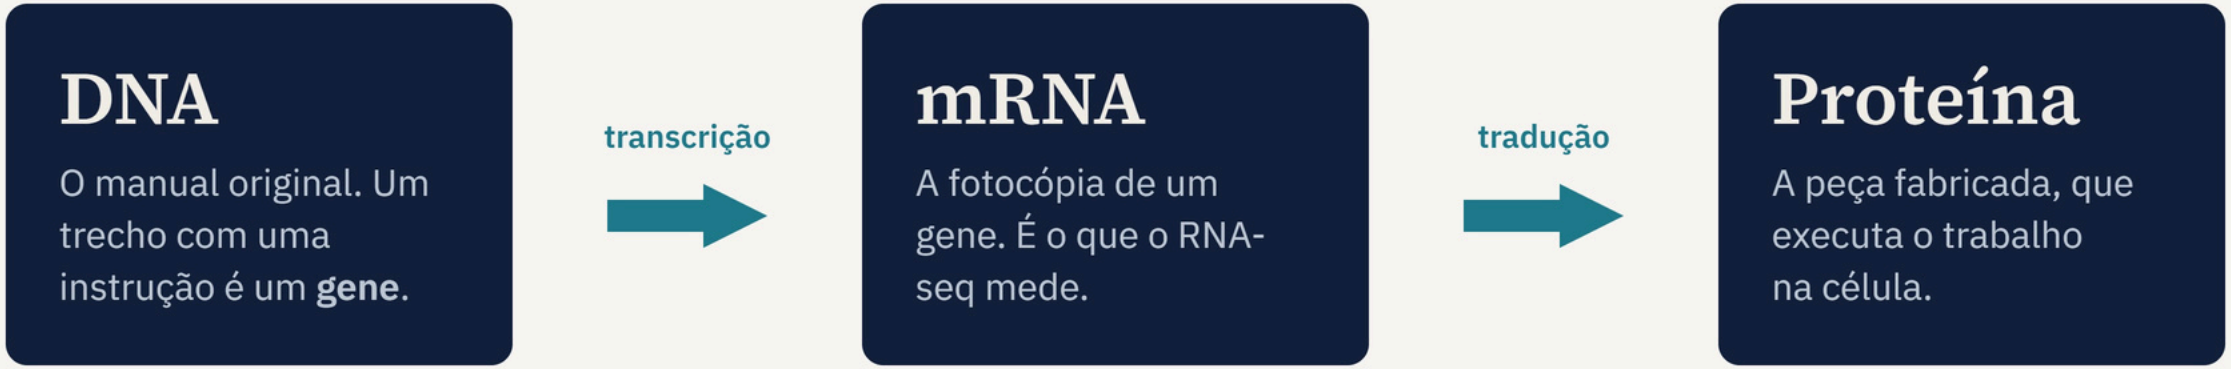
As fotocópias em uso agora

Os manuais que estão sendo copiados e levados ao chão de fábrica neste momento. Muda o tempo todo.

Mesma biblioteca, cópias diferentes, funções diferentes.

BLOCO 1 · POR QUE O TRANSCRIPTOMA

O dogma central: do DNA à proteína



Cada gene é como uma lâmpada com regulador de intensidade: apagada, fraca ou acesa no máximo. **Medir o mRNA é fotografar esse painel.**

BLOCO 1 · POR QUE O TRANSCRIPTOMA

Por que isso interessa à Engenharia de Defesa

Agentes químicos e toxinas

Quais genes de proteção a célula ativa, e com que intensidade. Ajuda a entender o mecanismo de ação e a buscar contramedidas.

Patógenos

Quais genes uma bactéria liga ao infectar um hospedeiro. Aponta alvos para medicamentos, vacinas e testes de diagnóstico.

Radiação

Genes de reparo do DNA que mudam com a exposição podem servir como **biomarcadores** para triagem após um incidente.

A lógica é sempre a mesma: comparar quem foi exposto com quem não foi e descobrir o que mudou.

BLOCO 2 · DO TUBO DE ENSAIO AOS DADOS

O mapa de um experimento de RNA-seq



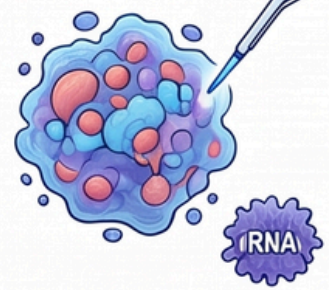
Em azul-escuro, as etapas que vocês executam na prática de hoje. As anteriores são vistas na teoria e em demonstração.

Fluxo de Funcionamento da Análise e Montagem do Transcriptoma (RNA-Seq)

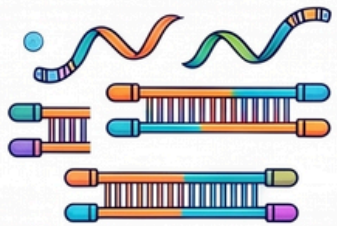
Etapa Laboratorial (Bancada e Sequenciamento)

Etapa Computacional (Bioinformática e Análise)





rRNA

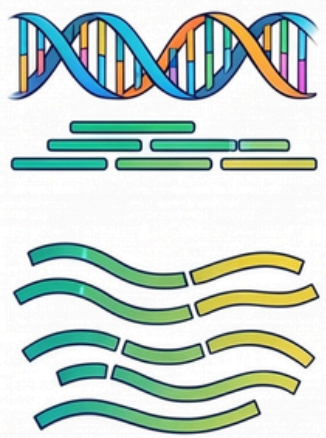


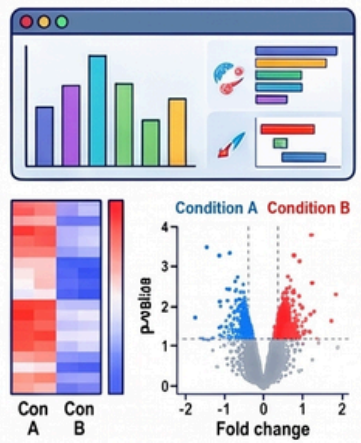


Leituras Brutas (Reads)



Genoma de Referência





Extração, Purificação e Enriquecimento do RNA

O RNA total é isolado e os RNAs ribossômicos (rRNA) são removidos.

Fragmentação e Construção da Biblioteca de cDNA

O RNA é fragmentado, convertido em cDNA e ligado a adaptadores e identificadores.

Amplificação e Sequenciamento de Alto Rendimento

A biblioteca é amplificada e sequenciada, gerando milhões de leituras brutas (reads).

Controle de Qualidade e Filtragem (Trimming)

Softwares removem adaptadores e bases de baixa qualidade, gerando leituras limpas.

Alinhamento e Montagem do Transcriptoma

As leituras são alinhadas ao genoma de referência ou remontadas para reconstruir transcritos.

Quantificação e Análise de Expressão Diferencial

Mede-se a abundância dos transcritos para quantificar alterações estatísticas entre condições.

Gemini Notebook

BLOCO 2 · DO TUBO DE ENSAIO AOS DADOS

Do RNA ao arquivo FASTQ

RNA → cDNA

O RNA é frágil e o sequenciador lê DNA. A enzima **transcriptase reversa** faz uma cópia estável: o cDNA.

Leitura (read)

Trecho curto de 50 a 150 letras lido pela máquina. Uma amostra gera dezenas de milhões.

Arquivo FASTQ

Guarda cada leitura e a qualidade de cada letra. Já visto na Aula 2.

UM REGISTRO FASTQ = 4 LINHAS

`@leitura_001`
nome da leitura

`ACGTTGCAAGTCCGATTGCA`
a sequência

`+`
separador

`IIIIIHHHGGFFF###IIII`
qualidade de cada letra; # = baixa confiança

O princípio da medição e as réplicas

Mais atividade, mais leituras

Um gene muito ativo tem muitas cópias de mRNA, e por isso muitas leituras vêm dele.



Contar leituras é medir expressão gênica.

Réplicas biológicas

≥ 3

réplicas por condição, no mínimo. Ninguém aprova um material com um único ensaio de tração.

Atenção: réplica biológica é outra amostra, de outro organismo ou cultura. Sequenciar o mesmo tubo duas vezes não conta.

BLOCO 3 · MAPEAR OU MONTAR

De onde veio cada leitura? Um quebra-cabeça

CAMINHO A · COM A FOTO DA CAIXA

Mapeamento no genoma de referência

O organismo já tem o genoma sequenciado: humano, camundongo, *E. coli*. Basta achar o lugar de cada peça na foto.

HISAT2 · STAR

CAMINHO B · SEM A FOTO

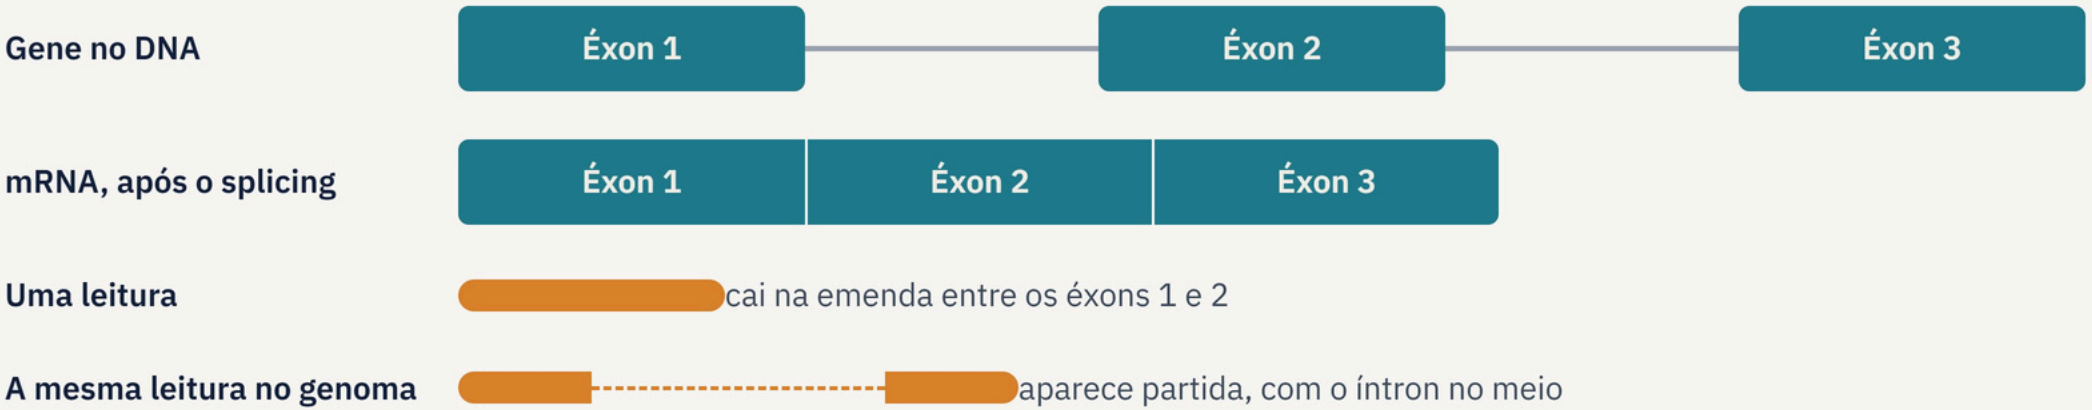
Montagem *de novo*, do zero

O organismo é pouco estudado: um microrganismo do solo, uma planta nativa da Amazônia. As peças são encaixadas umas nas outras.

Trinity + BLAST

BLOCO 3 · MAPEAR OU MONTAR

Éxons, íntrons e o desafio do RNA



Os alinhadores da Aula 2, BWA e Bowtie2, não foram feitos para leituras partidas.

O RNA exige alinhadores que “saltam” íntrons: HISAT2 e STAR.

BLOCO 3 · CAMINHO A, MAPEAMENTO

HISAT2 e STAR: mesma tarefa, custos diferentes

Critério	HISAT2	STAR
O que faz	Alinha leituras saltando íntrons	A mesma tarefa
Ponto forte	Rápido e econômico	Muito rápido e preciso
Memória (genoma humano)	≈ 8 GB	≈ 32 GB
Saída	Arquivo SAM/BAM	Arquivo SAM/BAM
Quando usar	Computador modesto	Servidor ou cluster

Ambos usam um **índice** do genoma, como o índice remissivo de um livro técnico.

O SAM/BAM diz onde caiu cada leitura. É manipulado com o SAMtools (Aula 2).

BLOCO 3 · CAMINHO A, MAPEAMENTO

Ensembl e a tabela de contagens

Do **Ensembl**, portal público do EMBL-EBI, baixamos:

Genoma (FASTA)

A foto da caixa: a sequência de cada cromossomo.

Anotação (GTF)

O mapa dos genes: onde começa e termina cada gene e cada éxon.

contagem



featureCounts ou HTSeq

EXEMPLO REAL · DOADOR N61311

Gene (Ensembl)	Controle	Tratado
ENSG00000000003	679	448
ENSG00000000005	0	0
ENSG00000000419	467	515

Cada número: quantas leituras caíram naquele gene, naquela amostra. Cada gene tem um código estável, como **FKBP5 = ENSG00000096060**.

BLOCO 3 · CAMINHO B, MONTAGEM DE NOVO

Trinity: reconstruir o texto a partir das tiras

Muitas cópias do mesmo manual foram picotadas, então as tiras se sobrepõem. Encaixando as sobreposições, o Trinity reconstrói os transcritos sem nunca ter visto o original.

1 · INCHWORM

Lagarta

Junta leituras em sequências mais longas.

2 · CHRYSALIS

Casulo

Agrupa as sequências que vêm do mesmo gene.

3 · BUTTERFLY

Borboleta

Resolve as variações e entrega os transcritos.

Saída: transcritos em FASTA, ainda sem nome. São identificados com o BLAST (Aula 2).

Custo: muita memória e de horas a dias de execução, em servidor ou nuvem.

BLOCO 3 · MAPEAR OU MONTAR

Como escolher a ferramenta: duas perguntas



BLOCO 4 · DA CONTAGEM À DESCOBERTA

Por que não basta comparar as contagens?

1

Profundidade diferente

Uma amostra com o dobro de leituras faz todos os genes parecerem duas vezes mais ativos.

Como comparar consumo de combustível sem dividir pela distância.

Solução: normalizar

2

Variação biológica

Réplicas nunca dão o mesmo número. A diferença precisa ser maior que esse ruído natural.

Como separar sinal de ruído em uma medição.

Solução: estimar o ruído de cada gene

3

Milhares de testes

Testar 20 mil genes com $p < 0,05$ gera cerca de mil falsos positivos só por acaso.

Quanto mais testes, mais acertos por sorte.

Solução: p-valor ajustado (padj)

BLOCO 4 · DA CONTAGEM À DESCOBERTA

As quatro medidas que vocês vão ler

Medida	O que significa	Como ler
log2FoldChange	Quanto o gene mudou, em log de base 2	+1 = dobrou · −1 = caiu à metade · +3 = 8×
padj	Chance de ser acaso, já corrigida	Abaixo de 0,05 = diferença confiável
lfcSE	Incerteza do log2FoldChange	Valor alto = estimativa frágil
baseMean	Expressão média do gene	Muito baixa = resultado frágil

PARA CONVERTER EM "VEZES"

Calcule 2 elevado ao log2FoldChange. Exemplo: **2 elevado a 4,57 ≈ 24 vezes**. Um p-valor menor não quer dizer gene mais importante, só mais certeza.

BLOCO 4 · DA CONTAGEM À DESCOBERTA

As ferramentas e os gráficos

PACOTE R · BIOCONDUCTOR

DESeq2

Normaliza, estima o ruído de cada gene e testa a mudança. Robusto com poucas réplicas.

É o que usaremos na prática.

PACOTE R · BIOCONDUCTOR

edgeR

Mesma finalidade e mesmo modelo de base, com outra normalização (TMM).

Resultados parecidos: escolha um e cite-o.

OS GRÁFICOS DA PRÁTICA

PCA
Cada ponto é uma amostra. Réplicas devem ficar juntas.

MA plot
Cada ponto é um gene: expressão média × mudança.

Volcano plot
Cada ponto é um gene: tamanho da mudança × certeza.

INTERVALO · 0:55 – 1:05

10 min

Ao voltar, tenha pronto:

- O notebook da prática aberto no Colab, em R
- A **Seção 1** executada: a instalação leva de 5 a 10 minutos

MOMENTO 2 · 1:05 – 1:50

Prática

Parte A · 5 min

Demonstração: leituras empilhadas sobre os éxons no IGV e a tabela de contagens.

Parte B · 40 min

DESeq2 no Google Colab com o conjunto airway, Seções 2 a 8 do notebook.

Não é preciso escrever código: o objetivo é **executar e interpretar** cada resultado.

MOMENTO 2 · OS DADOS DA PRÁTICA

O experimento airway: corticoide em células humanas

As células

Músculo liso das vias aéreas, que envolve os brônquios.

O tratamento

Dexametasona, um corticoide usado na asma: 1 μM por 18 horas.

O processamento

Leituras mapeadas com o STAR, anotação do Ensembl, contagem por gene.

Himes et al., PLoS One, 2014 · GEO GSE52778

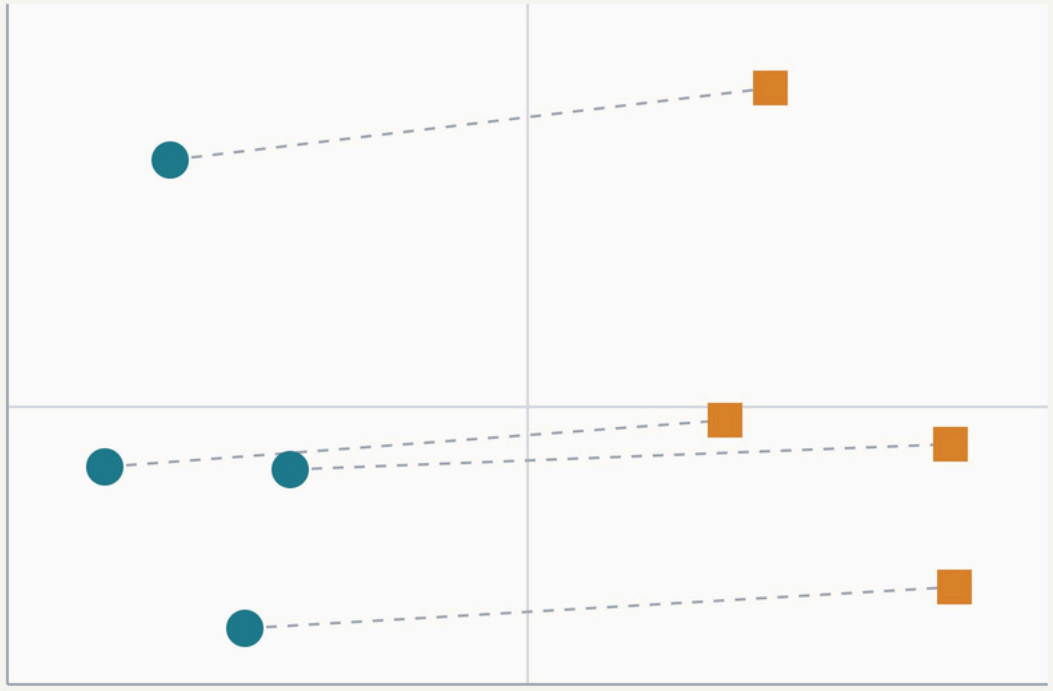
DESENHO PAREADO · 4 DOADORES

Doador	Controle	Tratado
N61311	SRR1039508	SRR1039509
N052611	SRR1039512	SRR1039513
N080611	SRR1039516	SRR1039517
N061011	SRR1039520	SRR1039521

Cada doador dá uma amostra controle e uma tratada. Por isso o desenho é **~ cell + dex**: desconta a diferença entre pessoas.

MOMENTO 2 · NOTEBOOK, SEÇÃO 4

Controle de qualidade: o tratamento domina a PCA



Não tratado (círculo)

Tratado (quadrado)

Mesmo doador

PC1 (41%) separa tratados e não tratados.

PC2 (26%) separa os quatro doadores.

Nenhuma amostra fora do seu grupo.

PESOS DO PC1

Entre os genes que mais pesam estão **FKBP5** e **TSC22D3 (GILZ)**, marcadores clássicos da resposta a corticoides.

Horizontal: PC1, 41% da variância · Vertical: PC2, 26%

MOMENTO 2 · NOTEBOOK, SEÇÃO 5

O placar do DESeq2: uma resposta ampla

4.030

genes alterados pela dexametasona com padj < 0,05: **18% dos genes analisados**.

2.208

subiram com o tratamento (9,9%)

1.822

desceram com o tratamento (8,1%)

22.369

genes analisados após o filtro

5.204

com contagem baixa demais para o teste

0

genes descartados por valores discrepantes

MOMENTO 2 · NOTEBOOK, SEÇÃO 6

Uma lista de genes, três perguntas diferentes

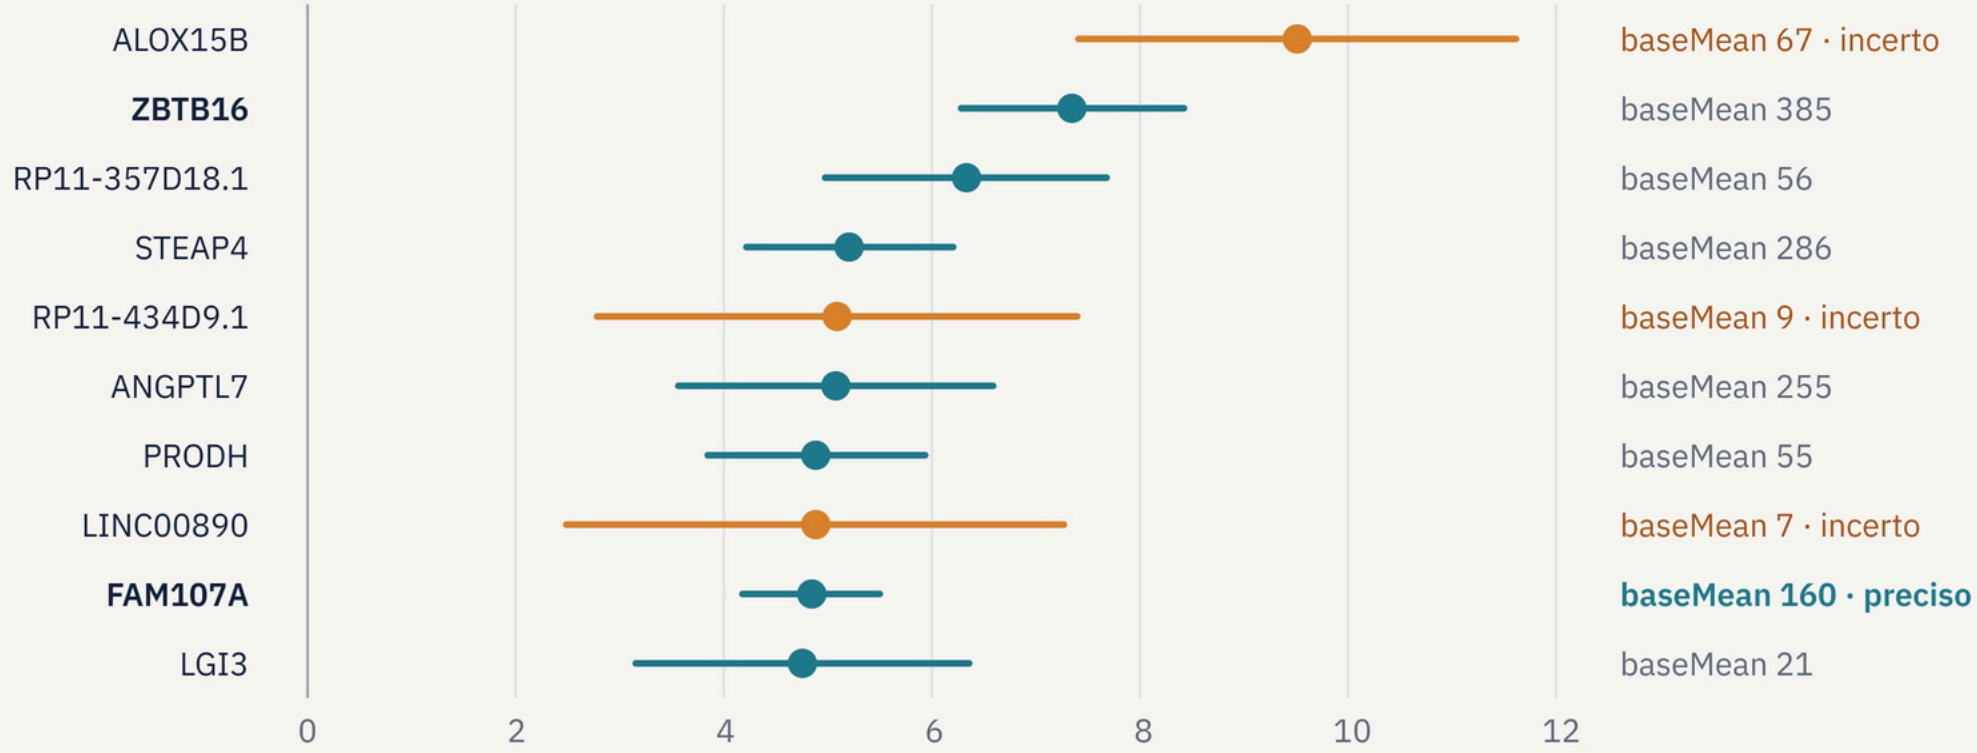
Ordenar por	Pergunta	Cuidado	Topo da lista
padj	Quais mudanças são mais certas?	Mistura mudanças grandes e pequenas	SPARCL1, CACNB2, DUSP1
log2FoldChange	Quais genes mudaram mais?	Favorece genes pouco expressos	ALOX15B, ZBTB16, STEAP4
log2FoldChange encolhido	Quais mudaram mais, de forma confiável?	A melhor para escolher candidatos	Conferir na Seção 6.3



Os melhores candidatos para um artigo aparecem bem em várias listas: **mudança grande, expressão razoável e alta certeza.**

MOMENTO 2 · SEÇÃO 6.2 ·PONTO = LOG2FOLDCHANGE · BARRA = ± 2 ERROS PADRÃO

As maiores mudanças nem sempre são as mais seguras



MOMENTO 3 · 1:50 – 2:00

Conexão

Cada célula, um conceito · para ir além · trabalho final · fechamento

MOMENTO 3 · TEORIA ↔ PRÁTICA

Cada célula, um conceito

O que você fez	O conceito por trás
Viu cada doador duas vezes na ficha	Réplicas biológicas e desenho pareado
Não comparou 679 com 448 diretamente	Profundidade e normalização
Definiu o desenho ~ cell + dex	Descontar a variação entre doadores
Viu o PC1 separar os tratados	Controle de qualidade do experimento
Reencontrou FKBP5 e GILZ nos pesos	O método redescobre a biologia conhecida
Leu 2.208 genes acima e 1.822 abaixo	padj e comparações múltiplas
Desconfiou de genes com baseMean 7	Incerteza (lfcSE) e encolhimento
Abriu o ZBTB16 no Ensembl	Identificadores estáveis e anotação

MOMENTO 3 · PARA IR ALÉM

Microarranjo × RNA-seq

Aspecto	Microarranjo	RNA-seq
O que mede	Brilho de fluorescência	Contagem de leituras
Genes medidos	Só os que têm sonda no chip	Qualquer RNA presente
Faixa de medição	Limitada: satura nos extremos	Muito ampla
Organismos	Só os que têm chip comercial	Qualquer um
Ferramentas	GEOquery, oligo (RMA), limma	HISAT2, STAR, DESeq2, edgeR
Situação hoje	Pouco usado em estudos novos	Padrão atual

Por que aprender: há milhares de estudos públicos de microarranjo no GEO, inclusive sobre radiação, toxinas e infecções. Na análise, o **limma** faz o papel do DESeq2.

MOMENTO 3 · PARA IR ALÉM

Outras técnicas de transcriptômica

Célula única (scRNA-seq)

O transcriptoma de cada célula. Útil em tecidos mistos e na resposta imune.

Transcriptômica espacial

Expressão e posição no tecido: onde cada gene está ativo.

Leituras longas

Transcritos inteiros, de ponta a ponta, com Nanopore ou PacBio.

Small RNA-seq

RNAs pequenos, como os microRNAs, que regulam outros genes.

Dual RNA-seq

Hospedeiro e patógeno na mesma amostra, durante a infecção.

Metatranscriptômica

O que uma comunidade de microrganismos está fazendo.

Validação com RT-qPCR: o RNA-seq aponta os candidatos, e o RT-qPCR confirma poucos genes com alta precisão.

TRABALHO FINAL · PELO MENOS DUAS TÉCNICAS

Três caminhos que partem desta aula

Reanálise

Um estudo público do **GEO** ligado à sua linha, de RNA-seq ou microarranjo, **+** as vias dos genes alterados (Aula 9).

RNA e proteína

Genes que mudaram no RNA-seq **+** as proteínas correspondentes em dados de proteômica (Aula 5).

Biomarcadores

Genes de resposta a uma exposição **+** a estrutura das proteínas (Aula 7) ou a evolução da família (Aula 8).

FECHAMENTO

Cinco ideias para levar

1. O transcriptoma mostra o que a célula está fazendo agora: **contar leituras é medir expressão**.
2. Com genoma de referência, **HISAT2 ou STAR**; sem ele, **Trinity + BLAST**. O Ensembl dá o mapa dos genes.
3. Comparar genes exige **normalização, réplicas biológicas e p-valor ajustado**.
4. Leia juntos o **tamanho** (log2FoldChange), a **certeza** (padj) e a **incerteza** (lfcSE).
5. A PCA é o controle de qualidade: **se as réplicas não se agrupam, desconfie antes de interpretar**.

AUTOAVALIAÇÃO E ATIVIDADE ASSÍNCRONA

Para responder em 2 – 3 linhas

1. Por que não podemos comparar contagens brutas entre amostras?
2. Quando usar HISAT2, STAR ou Trinity?
3. O que significa log2FoldChange = −2 com padj = 0,001?
4. Por que um gene com baseMean 7 e aumento de 30 vezes merece desconfiança?
5. Seu organismo não tem genoma de referência: qual caminho e quais ferramentas?

Para casa

Fazer os exercícios da Seção 9 do notebook.

Pesquisar um gene da Seção 6.3 no Ensembl e descrever sua função em 3 linhas.

Desafio opcional: repetir a análise com o edgeR e comparar os 10 primeiros genes.

PRÓXIMA AULA · UNIDADE 5

Proteômica

Hoje medimos o mRNA. Na próxima aula, medimos as proteínas por espectrometria de massas.

REFERÊNCIAS PRINCIPAIS

Himes et al., PLoS One 9:e99625 (2014) · Love, Huber & Anders, DESeq2, Genome Biology 15:550 (2014) · Robinson, McCarthy & Smyth, edgeR, Bioinformatics 26 (2010) · Kim et al., HISAT, Nature Methods 12 (2015) · Dobin et al., STAR, Bioinformatics 29 (2013) · Grabherr et al., Trinity, Nature Biotechnology 29 (2011)

Material de apoio: roteiro da Aula 4 e notebook Prática_de_Transcriptoma.ipynb