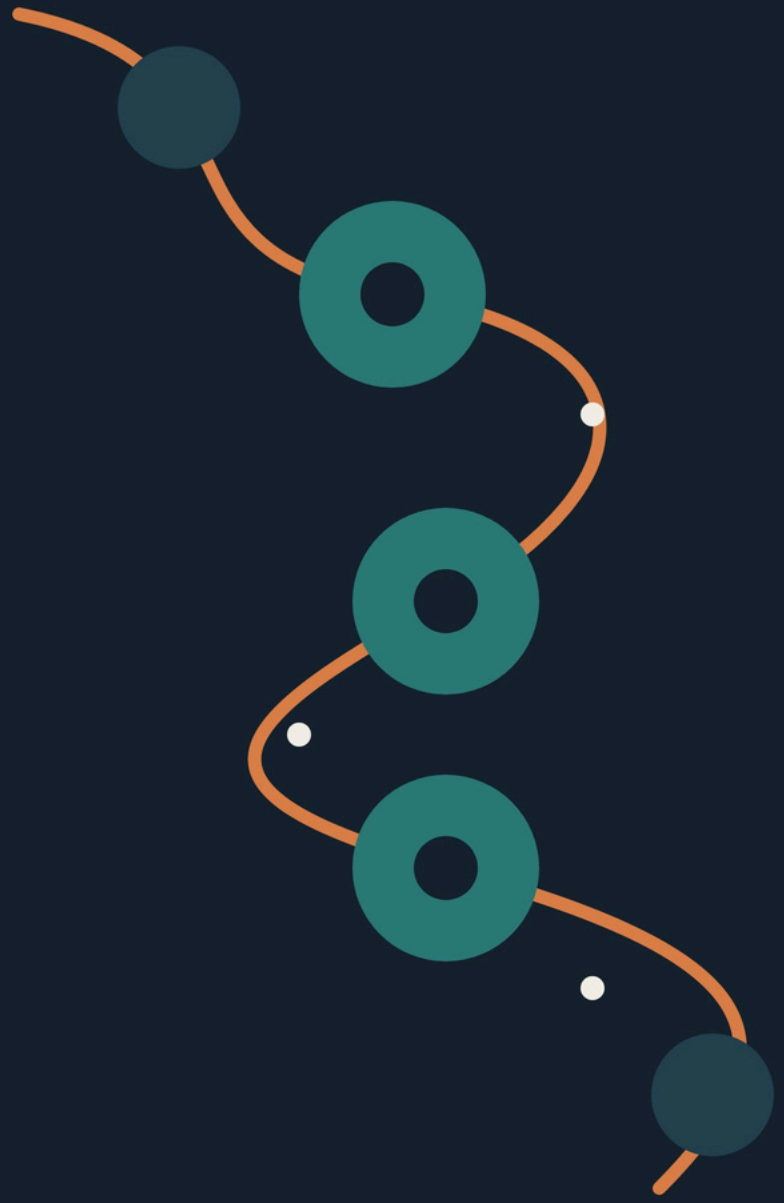
INTRODUÇÃO À BIOINFORMÁTICA · PPGED / IME · AULA 6

Epigenômica

Metilação do DNA, modificações de histonas e acessibilidade da cromatina



3 horas · Teoria → Intervalo → Prática → Conexão e fechamento

ABERTURA

Mapa da aula

Horário	Momento	O que faremos
0:00 – 0:05	Abertura	Objetivos e pergunta-guia
0:05 – 1:20	Momento 1 · Teoria	Conceitos, técnicas e ferramentas
1:20 – 1:30	Intervalo	10 minutos
1:30 – 2:35	Momento 2 · Prática	IGV-Web, MACS3 e metilação diferencial
2:35 – 3:00	Momento 3 · Conexão	Integração, aplicações e tarefas

PERGUNTA-GUIA DA AULA

Todas as suas células têm praticamente o mesmo DNA. Como um neurônio *sabe* que é neurônio e uma célula do fígado *sabe* que é fígado?

Guarde esta pergunta: voltaremos a ela no fechamento.

ABERTURA

Ao final da aula, você será capaz de...

Explicar

O que é epigenética e as três camadas: metilação, histonas e acessibilidade

Associar

Cada técnica à sua ferramenta: bissulfito → Bismark e methylKit; ChIP-seq e ATAC-seq → MACS

Analisar

Dados públicos do ENCODE: chamar picos, achar CpGs diferencialmente metilados e interpretar

1

Teoria

Conceitos, técnicas de laboratório e ferramentas de bioinformática

0:05 – 1:20 · cinco blocos: epigenética · metilação · histonas e ChIP-seq · ATAC-seq · bancos e visualização

BLOCO 1 · REVISÃO RELÂMPAGO

Como 2 metros de DNA cabem no núcleo

DNA

~2 m por célula, num núcleo de poucos micrômetros

→

Nucleossomo

8 histonas (H2A, H2B, H3, H4 ×2) com ~147 pb enrolados

→

Cromatina

DNA + histonas + outras proteínas

Aberta (eucromatina): frouxa, genes podem ser lidos

Fechada (heterocromatina): compacta, genes silenciados

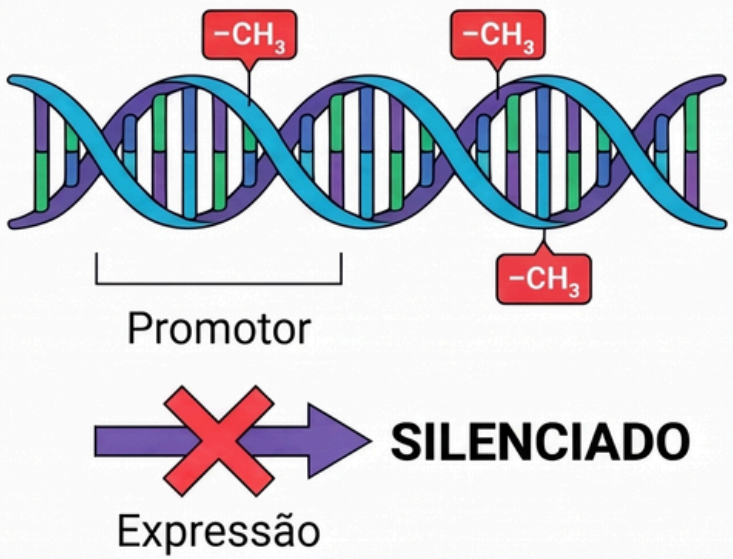
BLOCO 1 · VISÃO GERAL

As três camadas que estudaremos hoje

Camada	Efeito típico	Técnica	Ferramenta
Metilação do DNA $-CH_3$ na citosina	Em promotores, costuma silenciar genes	Bissulfito (WGBS, RRBS)	Bismark, methylKit
Histonas marcas nas caudas	Depende da marca: ativa ou reprime	ChIP-seq	MACS2 / MACS3
Acessibilidade DNA aberto ou fechado	Aberto = região regulatória ativa	ATAC-seq	MACS2 / MACS3

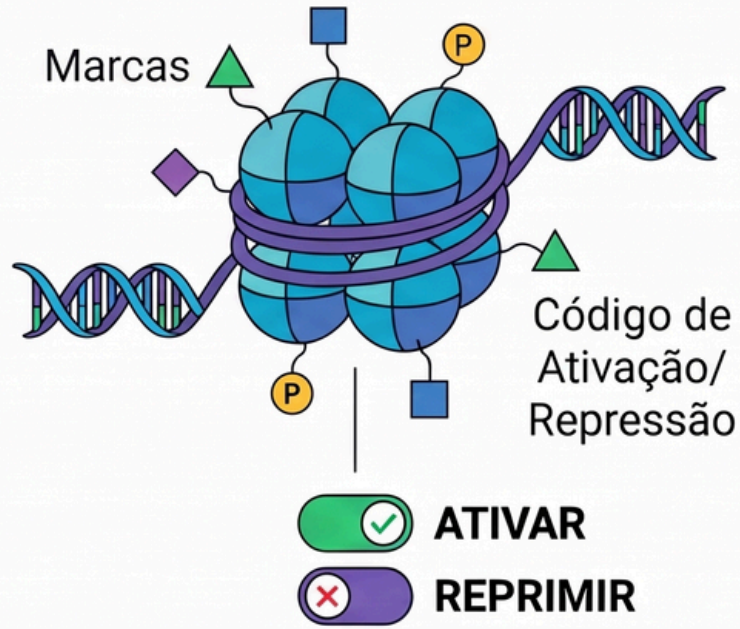
As 3 Camadas da Regulação Epigenética

Metilação do DNA:
Silenciamento de genes



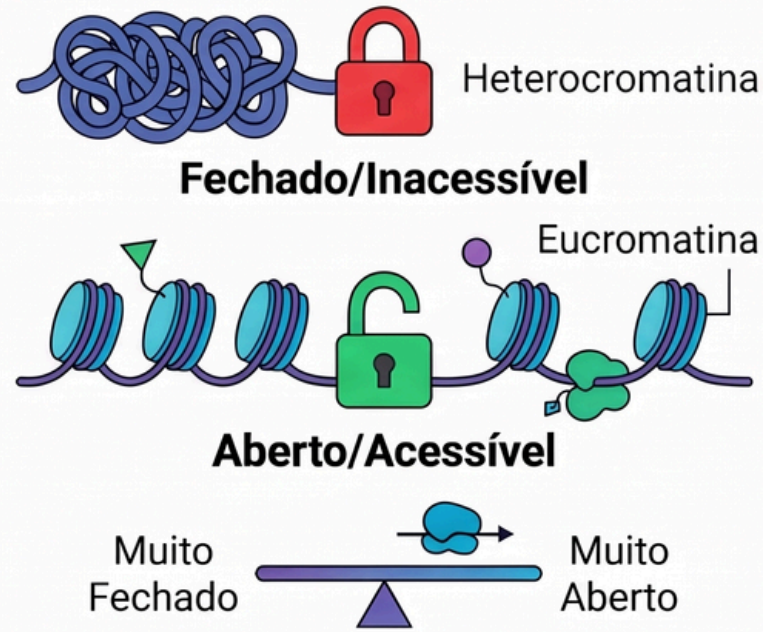
Ligação de um **grupo metil** ($-CH_3$) à citosina que, em regiões **promotoras**, costuma **silenciar** a leitura do gene.

Modificações de Histonas:
Marcas químicas nas proteínas



Alterações nas caudas das histonas que atuam como um **código** para **ativar** ou **reprimir** os genes.

Acessibilidade da Cromatina:
Grau de abertura do DNA



Quanto mais aberta a cromatina (eucromatina), mais **acessível** o DNA fica para a ligação da **maquinaria** de controle celular.

Gemini Notebook

BLOCO 1 · QUÍMICA DE PROTEÍNAS

Quem escreve, quem lê, quem apaga

Escritores

writers · colocam a marca

DNMT1, DNMT3A/B (metilam o DNA); HATs; EZH2

Leitores

readers · reconhecem a marca

Bromodomínios leem acetilação; cromodomínios leem metilação de lisina

Apagadores

erasers · removem a marca

TET (desmetilação do DNA); HDACs; KDMs

São enzimas, logo **alvos de fármacos**: inibidores de DNMT e de HDAC já são usados em alguns cânceres hematológicos.

Onde o DNA é metilado

5′ – C G –

3′

dinucleotídeo CpG (“p” = fosfato)

A citosina do CpG vira **5-metilcitosina (5mC)**.

O genoma humano tem **~28 milhões de CpGs**; a maioria está metilada.

Exceção: as **ilhas CpG** em promotores costumam ficar não metiladas quando o gene está ativo.

Ilha CpG de promotor **metilada** → gene tende a ser **silenciado**

BLOCO 2 · COMO MEDIR

O truque do bissulfito

C **não metilada** → vira U → lida como **T**

C **metilada** (5mC) → protegida → continua **C**

```
Ref. A CG T T CG A CG
Lida A CG T T TG A CG
```

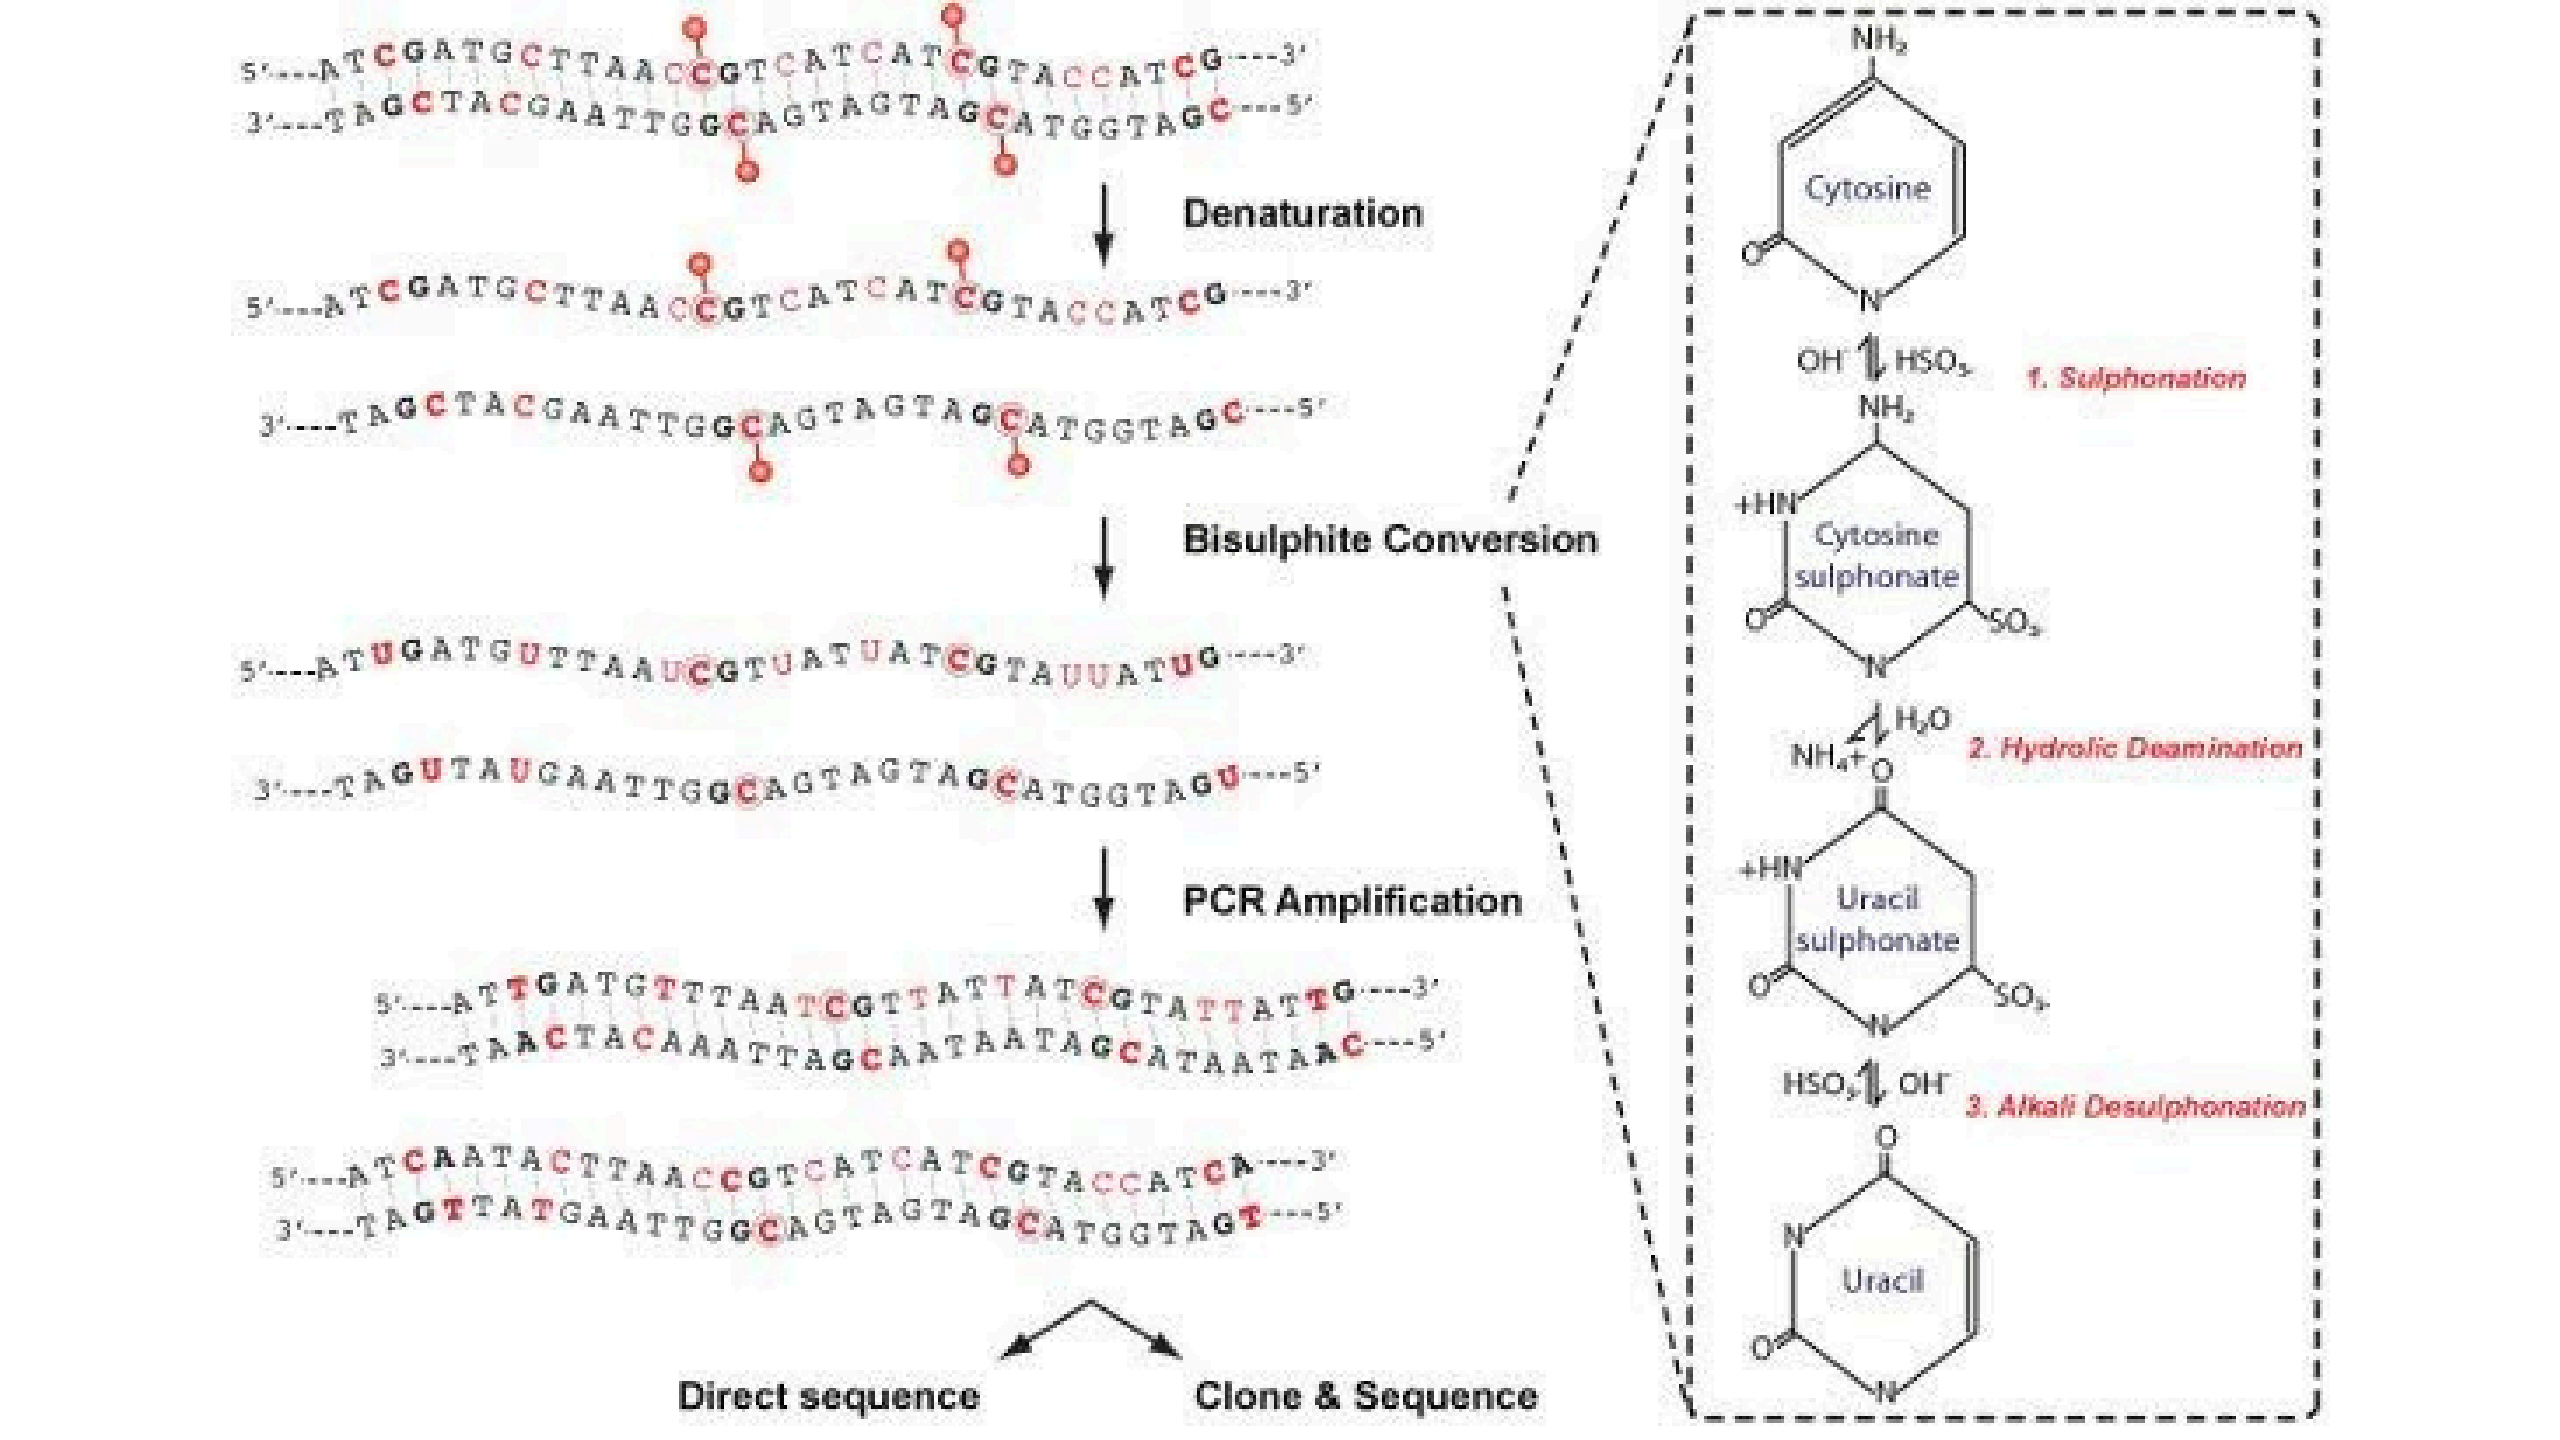
verde = metilado (C mantido) · laranja = não metilado (C→T)

Nível de metilação de um CpG

% = C ÷ (C + T) × 100

30 leituras: 24 com C e 6 com T →
80% metilado

Limitação: não distingue 5mC de 5hmC


Denaturation
Bisulphite Conversion
PCR Amplification
Direct sequence
Clone & Sequence
Cytosine
1. Sulphonation
Cytosine sulphonate
2. Hydrolic Deamination
Uracil sulphonate
3. Alkali Desulphonation
Uracil

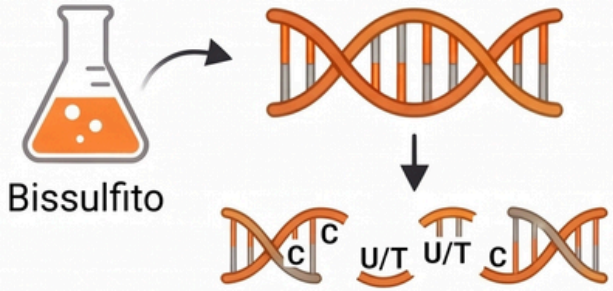
BLOCO 2 · VARIAÇÕES DA TÉCNICA

Qual técnica usar para medir metilação

Técnica	Cobertura	Custo	Quando usar
WGBS	Genoma inteiro (~28 mi CpGs)	Alto	Estudo completo, padrão-ouro
RRBS	Fração rica em ilhas CpG	Médio	Promotores, muitas amostras
Microarranjo EPIC	Centenas de milhares de CpGs	Baixo	Coortes com milhares de pessoas
EM-seq	Genoma inteiro, conversão enzimática	Alto	Danifica menos o DNA
Nanopore / PacBio	Lê a base modificada diretamente	Variável	Leituras longas, sem química

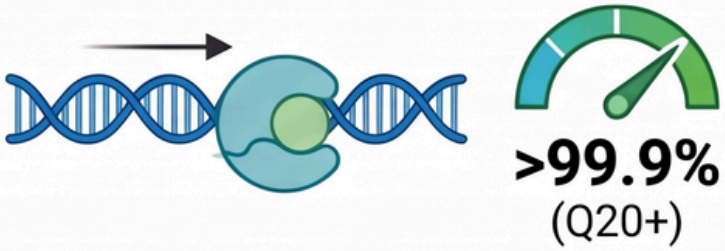
Comparativo de Metilação do DNA: WGBS vs. PacBio vs. Nanopore

WGBS: Padrão clássico por conversão química



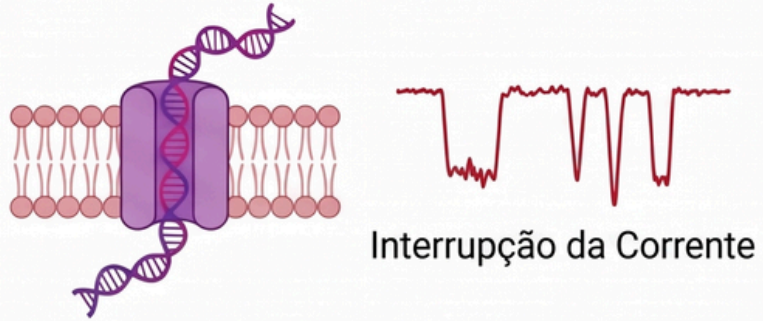
Converte citosinas não metiladas em uracila/timina via bissulfito, mas causa alta degradação do DNA e reduz a complexidade da sequência.

PacBio HiFi: Leitura longa com altíssima precisão



Detecta 5mC diretamente no DNA nativo ao medir a cinética da polimerase (IPD) com acurácia superior a 99,9% (Q20+).

Nanopore: Leituras ultra-longas em tempo real



Mede interrupções na corrente elétrica da passagem do DNA nativo pelo poro, alcançando leituras de tamanho megabase e distinguindo 5mC e 5hmC.

Leituras longas unem genômica e epigenômica



PacBio e Nanopore eliminam o bissulfito, permitindo identificar variantes estruturais, fases de haplótipos e metilação em um único ensaio.

Gemini Notebook

BLOCO 2 · FERRAMENTA

Bismark: alinhar leituras com bissulfito

O que é: programa de linha de comando, gratuito e de código aberto (Babraham Institute).

Problema: um alinhador comum vê os T convertidos como “erros” e falha.

Solução: converte leituras e genoma *in silico* (C→T, G→A), alinha com o **Bowtie2** (Aula 2) e decide, posição a posição, se o C estava metilado.

Controle de qualidade: taxa de conversão do bissulfito > 99%.

FLUXO TÍPICO (REFERÊNCIA)

```
# 1. preparar o genoma (uma vez)
bismark_genome_preparation genoma/
# 2. alinhar as leituras
bismark --genome genoma/ amostra.fq.gz
# 3. extrair a metilação por citosina
bismark_methylation_extractor --bedGraph
amostra_bismark_bt2.bam
```

BLOCO 2 · FERRAMENTA

methylKit: a estatística da metilação

Pacote para **R**, distribuído pelo **Bioconductor** (Aula 1). Recebe as tabelas do Bismark e compara grupos.

Descrever → Filtrar cobertura → Unir amostras → Correlação e PCA → **DMCs e DMRs**

Critério usual

Diferença ≥ 25 pontos percentuais **e** valor-q < 0,01. Teste: regressão logística (ou Fisher com 1 amostra por grupo).

Por que valor-q?

1 milhão de CpGs com p < 0,05 → ~50 mil falsos positivos. O valor-q controla a taxa de falsas descobertas (FDR), como no DESeq2.

BLOCO 3 · MODIFICAÇÕES DE HISTONAS

O “código das histonas”

As caudas das histonas recebem PTMs (Aula 5) em lisinas (K) e argininas (R). Como ler um nome:

H3K27me3

H3 = histona H3
K27 = lisina na posição 27
me3 = trimetilação

Marca	Onde	Significado
H3K4me3	Promotores	Ativo
H3K27ac	Promotores, enhancers	Regulação ativa
H3K4me1	Enhancers	Ativo ou em espera
H3K36me3	Corpo do gene	Sendo transcrito
H3K27me3	Grandes domínios	Repressão (Polycomb)
H3K9me3	Heterocromatina	Repressão estável

BLOCO 3 · PONTE COM A AULA 5 (PROTEÔMICA)

Por que a resolução do espectrômetro importa

0,036 Da

separam trimetilação de acetilação

Modificação	Δ massa
Metilação (me1)	+14,016 Da
Trimetilação (me3)	+42,047 Da
Acetilação (ac)	+42,011 Da

Só instrumentos de alta resolução (Orbitrap + MaxQuant) separam as duas. No ChIP-seq, o **anticorpo** distingue as marcas pela forma do epítopo, não pela massa.

BLOCO 3 · TÉCNICA

ChIP-seq: onde está a proteína X no genoma?

1 · Fixar
Formaldeído liga as proteínas ao DNA

2 · Fragmentar
Pedaços de ~200–500 pb

3 · Imunoprecipitar
Anticorpo “pesca” só o alvo

4 · Purificar
Libera o DNA pescado

5 · Sequenciar
Gera os arquivos FASTQ

6 · Bioinformática
Alinhar (Bowtie2/BWA) e achar os **picos**

Controle (input): mesma amostra sem anticorpo. Mostra o ruído de fundo; um pico verdadeiro precisa superá-lo com folga.

BLOCO 3 · FERRAMENTA

MACS: chamada de picos

Model-based Analysis of ChIP-Seq. Gratuito, código aberto, em Python. O **MACS3** sucede o MACS2 com o mesmo comando callpeak — é o que usaremos.

1

Estima o fragmento

Distância entre os montes das fitas + e −. Sem sinal suficiente, informamos à mão.

2

Modela o fundo

Distribuição de Poisson, ajustada localmente a partir do controle.

3

Testa cada região

“Há mais leituras aqui do que o acaso explicaria?” → valor-p e valor-q.

narrow (padrão): fatores de transcrição, H3K4me3, H3K27ac · **broad** (--broad): H3K27me3, H3K9me3, H3K36me3

BLOCO 3 · SAÍDA DO MACS

Lendo o arquivo .narrowPeak

Coluna	Conteúdo
1–3	Cromossomo, início, fim
4–6	Nome, pontuação, fita
7	Enriquecimento sobre o fundo (vezes)
8	$-\log_{10}$(valor-p)
9	$-\log_{10}$(valor-q): maior = mais confiável
10	Posição do cume (summit)

Como ler $-\log_{10}$

`q = 0,01` → 2

`q = 0,0001` → 4

Quanto **maior** o número, **mais significativo** o pico.

BLOCO 4 · ACESSIBILIDADE DA CROMATINA

ATAC-seq: onde o DNA está aberto?

A enzima **transposase Tn5** "corta e cola" adaptadores de sequenciamento **preferencialmente no DNA aberto**; o DNA enrolado nos nucleossomos fica protegido.

Picos = regiões regulatórias acessíveis (promotores, enhancers) de cada tipo celular.

Análise: QC → alinhamento → picos com o **MACS**, como no ChIP-seq.

Vantagens

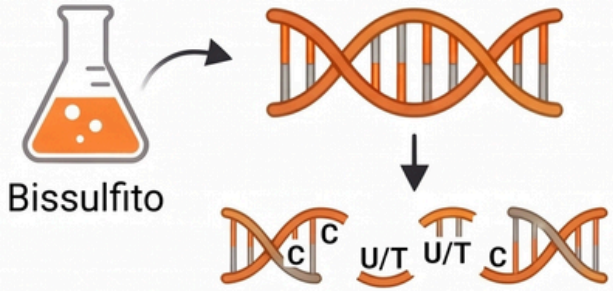
Rápido, sem anticorpo, poucas células; existe em célula única (scATAC-seq)

Assinatura de qualidade

Tamanhos em "escada": < 100 pb (livre), ~200 pb (1 nucleossomo), ~400 pb (2)

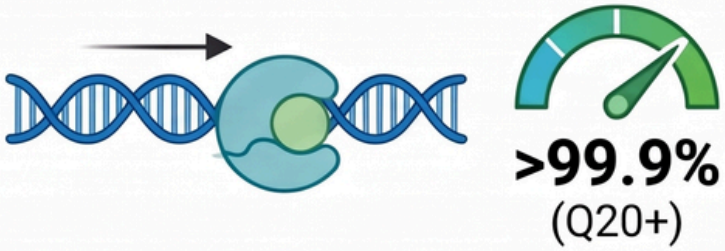
Comparativo de Metilação do DNA: WGBS vs. PacBio vs. Nanopore

WGBS: Padrão clássico por conversão química



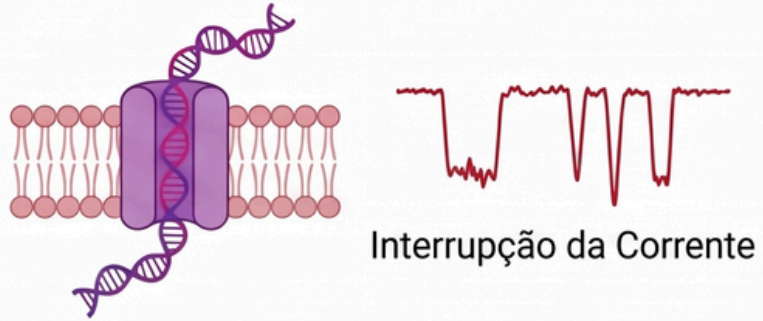
Converte citosinas não metiladas em uracila/timina via bissulfito, mas causa alta degradação do DNA e reduz a complexidade da sequência.

PacBio HiFi: Leitura longa com altíssima precisão



Detecta 5mC diretamente no DNA nativo ao medir a cinética da polimerase (IPD) com acurácia superior a 99,9% (Q20+).

Nanopore: Leituras ultra-longas em tempo real



Mede interrupções na corrente elétrica da passagem do DNA nativo pelo poro, alcançando leituras de tamanho megabase e distinguindo 5mC e 5hmC.

Leituras longas unem genômica e epigenômica



PacBio e Nanopore eliminam o bissulfito, permitindo identificar variantes estruturais, fases de haplótipos e metilação em um único ensaio.

Gemini Notebook

BLOCO 4 · SÍNTESE

Juntando as três camadas

Estado do gene	Metilação do promotor	Histonas	Cromatina (ATAC)	Expressão (Aula 4)
Ativo	Baixa	H3K4me3, H3K27ac	Aberta (pico)	Alta
Reprimido (Polycomb)	Baixa a variável	H3K27me3	Fechada	Baixa
Silenciado estável	Alta	H3K9me3	Fechada	Nenhuma

Nenhuma camada sozinha conta a história toda: a conclusão vem da **concordância** entre elas e com o RNA-seq.

BLOCO 5 · BANCOS DE DADOS

Onde encontrar dados epigenômicos públicos

ENCODE

Milhares de experimentos (ChIP-seq, ATAC, DNase, WGBS, RNA-seq) já processados, com QC padronizado

encodeproject.org

Roadmap

Mais de 100 epigenomas de referência de tecidos humanos; famoso pelos “estados de cromatina”

Roadmap Epigenomics

GEO

Repositório do NCBI com os dados de quase todo estudo publicado; brutos ficam no SRA (Aula 2)

ncbi.nlm.nih.gov/geo

BLOCO 5 · VISUALIZAÇÃO

Navegadores genômicos e formatos

IGV (Broad Institute): o genoma como uma régua horizontal com **trilhas** empilhadas embaixo. Usaremos o **IGV-Web**, que roda no navegador e já acessa trilhas do ENCODE.

UCSC Genome Browser: centenas de trilhas prontas (genes, conservação, regulação). Nosso plano B.

Atenção: hg19 (GRCh37) ≠ hg38 (GRCh38). Dados e navegador na mesma versão!

Formato	Contém
BED / narrowPeak	Lista de regiões (picos do MACS)
bedGraph / bigWig	Valor contínuo: sinal, % metilação
BAM	Leituras alinhadas (Bowtie2, Bismark)

1:20 – 1:30

Intervalo

10 minutos. Na volta: Colab e IGV-Web abertos.

2 Prática

1:30 – 2:35 · dados públicos e ferramentas de código aberto

P1 · 15 min

Epigenoma no navegador

IGV-Web + ENCODE (GM12878)

P2 · 25 min

Picos de ChIP-seq

Colab + MACS3 · CTCF no chr22

P3 · 25 min

Metilação diferencial

Colab + Python · dados do methylKit

O código completo e comentado está no roteiro: copie cada célula, execute com ► e interprete

P1 · 1:30 – 1:45 · IGV-WEB

A assinatura de um gene ativo e de um reprimido

1. Abra igv.org/app → Genome: **Human hg19**
2. Tracks → **ENCODE Signals** → busque **GM12878**
3. Marque H3K4me3, H3K27ac, H3K27me3, CTCF e DNase
4. Digite **GAPDH** (gene de manutenção, sempre ativo)
5. Digite **HOXD13** (gene do desenvolvimento embrionário)
6. Compare e anote na tabela do roteiro

Esperado em GAPDH

H3K4me3 e H3K27ac altos, DNase aberta, H3K27me3 baixo

Esperado em HOXD

Um “tapete” de H3K27me3: repressão por Polycomb

Plano B: genome.ucsc.edu (hg19) → seção Regulation → ENCODE Regulation · não feche o IGV-Web: voltaremos na P2

P2 · 1:45 – 2:10 · COLAB + MACS3

Encontrando os picos da CTCF

Dados: ChIP-seq da proteína **CTCF** + controle, trecho do chr22 (hg19), ~50 mil leituras cada. Dados de teste oficiais do MACS, derivados do ENCODE.

CTCF é um “isolador”: organiza o genoma em alças e gera picos estreitos e nítidos.

Formato BED: o alinhamento já foi feito.

```
# Célula 1 — instalar
!pip install -q macs3
# Célula 2 — baixar ChIP e controle
!wget -q {url}CTCF_SE_ChIP_chr22_50k.bed.gz
!wget -q {url}CTCF_SE_CTRL_chr22_50k.bed.gz
# Célula 3 — chamar os picos
!macs3 callpeak -t ChIP.bed.gz -c CTRL.bed.gz -f BED -g hs -n
ctcf -q 0.05
```

Comandos resumidos — copie as versões completas e comentadas do roteiro (células 1 a 7)

P2 · UM AVISO ESPERADO

O MACS3 vai reclamar — e dizer como corrigir

```
WARNING … MACS3 needs at least 100 paired peaks at + and - strand to build the model, but can only find 0! … we suggest to use --nomodel and --extsize 147 or other fixed number instead.
```

Por quê?

Com 50 mil leituras não há sinal para estimar o tamanho do fragmento (passo 1 do MACS). Nenhum pico é gerado.

Célula 4: a correção

… `--nomodel --extsize 200`

Informamos ~200 pb, valor típico de ChIP-seq.

Lição para a vida real: leia as mensagens de aviso antes de pedir ajuda

P2 · RESULTADO (CÉLULAS 5 A 7)

O que você deve encontrar

802

picos com valor-q < 0,05

~390

pb de largura média: picos estreitos, típicos de CTCF

58×

enriquecimento do pico mais forte sobre o fundo

Célula 7: baixe ctcf_peaks.narrowPeak, abra no IGV-Web (Tracks → Local File) e vá a chr22:37,250,000-37,256,000

Seus picos coincidem com a trilha de CTCF do ENCODE?

Valores obtidos no teste desta aula com o MACS3 3.0.5 · pico mais forte: chr22:37.252.291–37.252.808

P3 · 2:10 – 2:35 · COLAB + PYTHON

Metilação diferencial passo a passo

Dados: exemplos oficiais do methylKit — 2 amostras teste e 2 controle, chr21. Cada linha é um CpG com cobertura e % de C (metilado) e de T. É a saída do Bismark.

Célula	O que faz	Equivale no methylKit a
8	Carrega as 4 amostras	methRead
9	Histograma da % de metilação	getMethylationStats
10	Cobertura ≥ 10, une amostras, correlação	filterByCoverage, unite, getCorrelation
11	Teste de Fisher + valor-q (Benjamini-Hochberg)	calculateDiffMeth
12	DMCs e gráfico de vulcão	getMethylDiff

Por que Python? Instalar o methylKit no Colab leva mais de 15 min · o script em R está no Apêndice A do roteiro

P3 · RESULTADO

O que você deve encontrar

963

CpGs presentes nas 4 amostras após o filtro

0,93

correlação mínima entre réplicas, contra ~0,88 entre grupos

127

DMCs: 72 hipermetilados e 55 hipometilados no grupo teste

Histograma em "U": em cada célula, um CpG está metilado ou não.

Vulcão: canto superior direito = hipermetilado e muito significativo.

Critério: |diferença| ≥ 25 pontos percentuais e valor-q < 0,01 · valores obtidos no teste desta aula

3

Conexão e fechamento

Da tabela teórica ao que você viu na tela

2:35 – 3:00 · integração · discussão · aplicações em defesa · revisão · tarefas

MOMENTO 3 · 2:35 – 2:45

O que cada prática mostrou

Prática	Conceito teórico	O que você viu
P1	Marcas ativas × repressivas	GAPDH com H3K4me3 e H3K27ac; HOXD coberto por H3K27me3
P2	ChIP-seq, controle, Poisson, valor-q	802 picos estreitos de CTCF que coincidem com o ENCODE; o ajuste do tamanho do fragmento
P3	Bissulfito, cobertura, FDR	Distribuição bimodal, réplicas concordantes, 127 DMCs

Pergunta-guia respondida: neurônio e hepatócito diferem nas marcas que abrem ou trancam cada gene, não na sequência do DNA.

MOMENTO 3 · VISÃO DO FLUXO

Do laboratório ao resultado

Aula 2

Qualidade

FastQC, Trimmomatic, Cutadapt

→

Aula 2 + hoje

Alinhamento

Bowtie2, BWA; Bismark para bissulfito

→

Hoje

Quantificação

MACS para picos; methylKit para metilação

→

Hoje + Aula 4

Interpretação

IGV, UCSC e integração com RNA-seq

Amostra → técnica de laboratório (bissulfito, ChIP-seq, ATAC-seq) → sequenciamento → FASTQ → as quatro etapas acima.

MOMENTO 3 · DISCUSSÃO EM GRUPO

Duas perguntas para a turma

1

Um gene tem promotor **muito metilado**, **H3K27me3 baixo** e **nenhum pico de ATAC-seq**. Qual é o provável estado dele?

Que dado da Aula 4 confirmaria a hipótese?

2

Na P2, se não tivéssemos o arquivo de **controle (input)**, que tipo de erro poderíamos cometer?

MOMENTO 3 · 2:45 – 2:52

Por que isso interessa à Engenharia de Defesa

Forense e identificação

“Relógios epigenéticos” estimam a idade a partir de uma amostra biológica

Biomarcadores de exposição

Tabagismo altera a metilação de AHRR; busca análoga para poluentes e radiação

Saúde do combatente

Coortes militares estudam metilação, estresse pós-traumático e resiliência

Biodefesa

Patógenos manipulam a cromatina do hospedeiro; metilação bacteriana ajuda a caracterizar linhagens

Química de proteínas: DNMTs, HDACs e EZH2 são alvos de fármacos — tema da Aula 7 (docking).

MOMENTO 3 · 2:52 – 2:57

Revisão rápida

1. O bissulfito converte em uracila a citosina **metilada** ou a **não metilada**?
2. Qual marca indica um **promotor ativo**: H3K4me3 ou H3K27me3?
3. Para que serve o **controle (input)** num ChIP-seq?
4. No .narrowPeak, $-\log_{10}(q) = \mathbf{5}$ é mais ou menos significativo que **2**?
5. Qual técnica usa a enzima **Tn5** para medir acessibilidade?

As respostas estão no final do roteiro

MOMENTO 3 · 2:57 – 3:00

Tarefas para a lista de exercícios

Tarefa	O que fazer
P1 estendida	Descreva a assinatura epigenética de um gene da sua pesquisa em GM12878, com captura de tela
P2 estendida	Rode o MACS3 com -q 0.01 e com --extsize 150. Quantos picos? Por que muda?
P3 estendida	Exija cobertura mínima de 20 leituras. Os DMCs aumentam ou diminuem? Por quê?
Opcional	Rode o methylKit em R (Apêndice A) e compare com o resultado em Python

Ideia de trabalho final: o estado epigenético do gene de uma proteína do seu interesse + sua estrutura (Aula 7) ou proteômica (Aula 5).

Entrega conforme o cronograma da disciplina