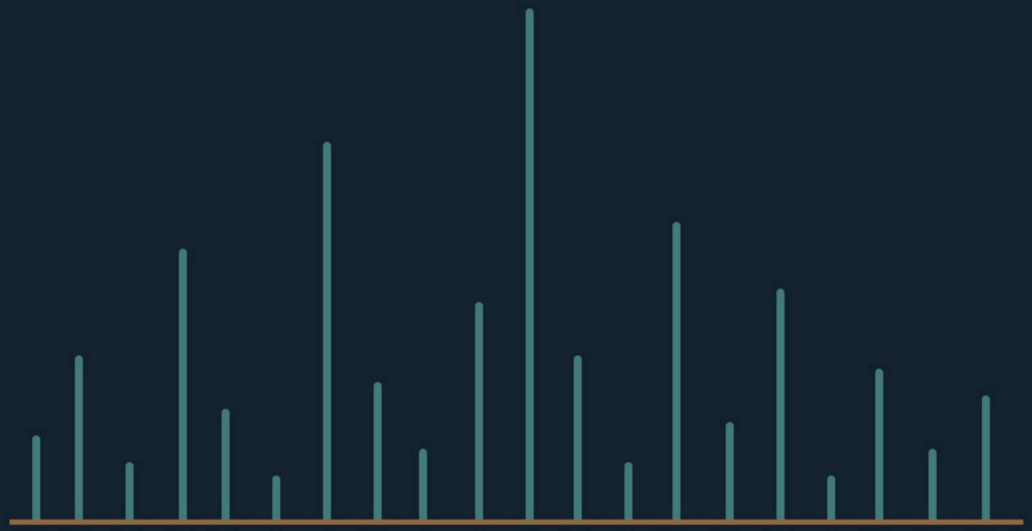


INTRODUÇÃO À BIOINFORMÁTICA · PPGED / IME

Proteômica

Identificação e quantificação de proteínas por espectrometria de massas

Aula 5 · 3 horas · teoria → intervalo → prática → conexão e fechamento

MAPA DA AULA · 3 HORAS

Três momentos e um intervalo

0:05 – 1:10

Teoria

Conceitos, técnicas e ferramentas em seis blocos curtos

1:10 – 1:20

Intervalo

Volte já logado no Galaxy Europe

1:20 – 2:30

Prática

Dados públicos de câncer de pele, só no navegador

2:30 – 3:00

Conexão

Cada clique ligado a um conceito, e fechamento

Ferramentas de hoje: **UniProt · Expasy PeptideMass · PRIDE · Galaxy · MSstats** — tudo gratuito, nada para instalar.

FIO CONDUTOR DA AULA

“Como sair de um tubo com milhares de proteínas misturadas e chegar a uma lista confiável de quais estão lá — e de quais mudaram de quantidade?”

Cada bloco da teoria responde a um pedaço desta pergunta. A prática percorre o caminho inteiro.

MOMENTO 1 · 0:05 – 1:10

Teoria

1 · Por que proteômica?
2 · A balança de moléculas
3 · O fluxo bottom-up
4 · Identificação e FDR
5 · Quantificação
6 · Ferramentas e bancos

BLOCO 1 · POR QUE PROTEÔMICA?

Do genoma ao proteoma: a fábrica

DNA

Genoma

As **plantas de projeto**. Praticamente iguais em todas as células.

RNA

Transcriptoma

As **ordens de produção** emitidas naquele momento.

PROTEÍNAS

Proteoma

As **máquinas** que estão de fato funcionando no chão de fábrica.

A quantidade de RNA nem sempre prevê a de proteína (tradução, degradação). E as **modificações pós-traducionais** — fosforilação, glicosilação, acetilação — só aparecem na proteína.

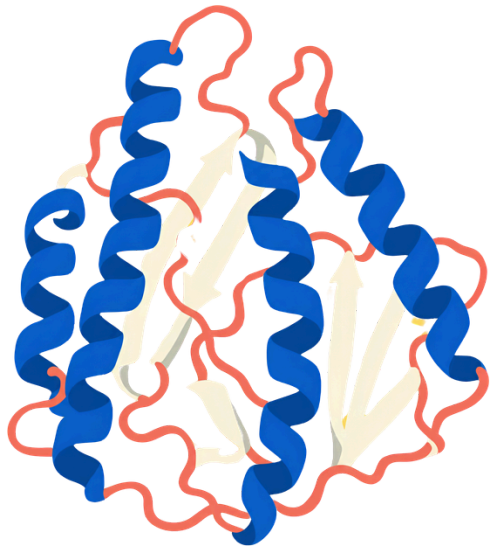


Adenine (A)
Uracil (U)
Cytosine (C)
Guanine (G)

SEGUNDA LETRA

PRIMEIRA LETRA (5')	U	C	A	G	TERCEIRA LETRA (3')
U	UUU Phe (F)	UCU Ser (S)	UAU Tyr (Y)	UGU Cys (C)	U
	UUC	UCC	UAC	UGC	C
	UUA Leu (L)	UCA	UAA Parada (terminador)	UGA Parada (terminador)	A
	UUG	UCG	UAG Parada (Terminador)	UGG Trp (W)	G
C	CUU Leu (L)	CCU Pro (P)	CAU His (H)	CGU Arg (R)	U
	CUC	CCC	CAC	CGC	C
	CUA	CCA	CAA Gln (Q)	CGA	A
	CUG	CCG	CAG	CGG	G
A	AUU Ile (I)	ACU Thr (T)	AAU Asn (N)	AGU Ser (S)	U
	AUC	ACC	AAC	AGC	C
	AUA	ACA	AAA Lys (K)	AGA Arg (R)	A
	AUG Met (M) (iniciador)	ACG	AAG	AGG	G
G	GUU Val (V)	GCU Ala (A)	GAU Asp (D)	GGU Gly (G)	U
	GUC	GCC	GAC	GGC	C
	GUA	GCA	GAA Glu (E)	GGA	A
	GUG	GCG	GAG	GGG	G

= Códon de iniciação da cadeia polipeptídica
= Códon de término da cadeia polipeptídica



BLOCO 1 · POR QUE PROTEÔMICA?

E para a Engenharia de Defesa?

Toxinas proteicas

Detectar e identificar ricina e toxinas botulínicas com alta especificidade.

Marcadores de exposição

Agentes neurotóxicos deixam “registro” em proteínas do sangue.

Biodetecção

Identificar microrganismos pelo seu perfil de proteínas.

Biomateriais

Adesivos, fibras e enzimas de descontaminação.

BLOCO 2 · ESPECTROMETRIA DE MASSAS

Uma balança de altíssima precisão para moléculas

m/z

Só “pesa” moléculas **com carga** e em **fase gasosa**.
Por isso mede a razão **massa ÷ carga**, não a massa.

Da (Dalton) ≈ massa de um átomo de hidrogênio.

EXEMPLO · PEPTÍDEO DA ALBUMINA

LVNEVTEFAK

Massa neutra: **1148,61 Da**

1 carga (+1) → m/z ≈ **1149,6**

2 cargas (+2) → m/z ≈ **575,3**

Cada carga = 1 próton (≈ 1,007 Da)

BLOCO 2 · ESPECTROMETRIA DE MASSAS

As três partes de todo espectrômetro

A PORTA DE ENTRADA

Fonte de ionização

Dá carga às moléculas sem destruí-las.

ESI — borrifo sob alta tensão
MALDI — laser sobre uma matriz

→

A PISTA DE CORRIDA

Analisador de massas

Separa os íons pela razão m/z.

Quadrupolo — filtro elétrico
TOF — leves chegam antes
Orbitrap — frequência da órbita

→

O PLACAR

Detector

Conta quantos íons chegam em cada m/z.

Resultado: o **espectro de massas** — m/z no eixo x, intensidade no eixo y.

BLOCO 2 · ESPECTROMETRIA DE MASSAS

Duas palavras que voltarão o tempo todo

MS1

O espectro dos **peptídeos inteiros**: quais massas chegam e com que intensidade.

Serve para QUANTIFICAR

MS2

O instrumento **escolhe** um íon, **quebra** por colisão com gás (CID / HCD) e mede os **pedaços**.

Serve para IDENTIFICAR

BLOCO 3 · O FLUXO BOTTOM-UP (SHOTGUN)

Da amostra ao arquivo bruto, em seis etapas

1 Extração

Proteínas de células, tecido, plasma ou cultura bacteriana.

2 Digestão

A tripsina corta as proteínas em peptídeos.

3 Cromatografia (LC)

Os peptídeos saem da coluna aos poucos: o tempo de retenção.

4 Ionização (ESI)

Cada peptídeo ganha carga ao sair da coluna.

5 MS1 + MS2

Aquisição alternada, em DDA ou DIA. Juntos: LC-MS/MS.

6 Arquivos brutos

Centenas de MB a GB por corrida. Formato aberto: mzML.

Bottom-up: quebrar em peptídeos antes de medir. **Top-down:** medir a proteína inteira (preserva proteoformas, mas é mais difícil).

BLOCO 3 · O FLUXO BOTTOM-UP

Tripsina: uma tesoura com regra fixa

Corta logo **depois** de **K** (lisina) ou **R** (arginina)… **exceto** se o próximo for **P** (prolina).

SEQUÊNCIA ILUSTRATIVA

AGK | LVNEVTEFAK | DLRPEVYK | W

Em “DL**RP**EV” não há corte: o R vem antes de um P.

Regra previsível → o computador simula o corte: **digestão *in silico***.

Todo peptídeo termina em K ou R, que têm **carga positiva**: ótimo para ionizar.

BLOCO 3 · AQUISIÇÃO DE DADOS

Quem o instrumento escolhe fragmentar?

DDA

DATA-DEPENDENT ACQUISITION

A cada ciclo, fragmenta os **~10–20 picos mais intensos** do MS1, um por vez.

+ Espectros limpos, simples de interpretar
– Peptídeos fracos são “esquecidos”: **valores ausentes**

DIA

DATA-INDEPENDENT ACQUISITION

Fragmenta **todos os íons** em janelas largas de m/z, de forma sistemática.

+ Mais completo e reprodutível
– Espectros misturados: exige software sofisticado

BLOCO 4 · IDENTIFICAÇÃO

O espectro MS2 é uma escada

#	íon b	m/z	íon y	m/z
1	L	114,09	VNEVTEFAK	1036,53
2	LV	213,16	NEVTEFAK	937,46
3	LVN	327,20	EVTEFAK	823,42
4	LVNE	456,25	VTEFAK	694,38
5	LVNEV	555,31	TEFAK	595,31
6	LVNEVT	656,36	EFAK	494,26
7	LVNEVTE	785,40	FAK	365,22
8	LVNEVTEF	932,47	AK	218,15
9	LVNEVTEFA	1003,51	K	147,11

Íons b: o início do peptídeo.
Íons y: o final.

UM DEGRAU

213,16 − 114,09

= 99,07

a massa da **valina (V)**

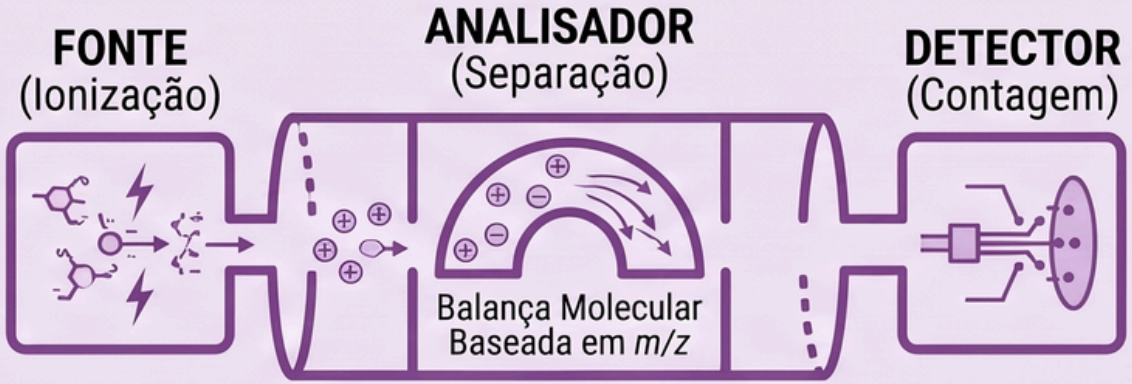
Espectrometria de Massas & Fluxo Bottom-Up

Digestão de Proteínas com Tripsina



A tripsina corta as proteínas em peptídeos logo após os aminoácidos Lisina (K) e Arginina (R).

Três Etapas do Espectrômetro de Massas



Ioniza as moléculas.

Separa os íons. Mede a razão massa/carga de moléculas eletricamente carregadas em fase gasosa.

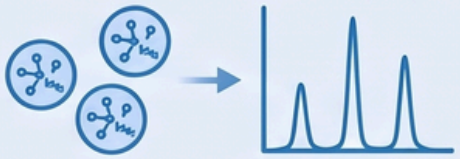
Conta o resultado.

Separação Líquida e Aquisição LC-MS/MS

Peptídeos são separados por hidrofobicidade na cromatografia antes de sofrerem ionização e fragmentação.



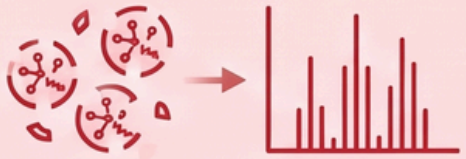
Espectros MS1



Quantificação

O MS1 quantifica peptídeos inteiros.

Espectros MS2



Sequenciamento

O MS2 fragmenta os íons para determinar a sequência.

Gemini Notebook

BLOCO 4 · IDENTIFICAÇÃO

Busca em banco de dados: comparar com o que já se sabe

1

FASTA

Todas as proteínas conhecidas do organismo, baixadas do UniProt.

→

2

Digestão *in silico*

A regra da tripsina gera milhões de peptídeos teóricos.

→

3

Comparar e pontuar

Mesma massa (tolerância de poucos ppm) e espectro teórico parecido.

→

4

PSM

Peptide-spectrum match: o melhor par espectro–peptídeo.

MOTORES DE BUSCA (SEARCH ENGINES)

Andromeda · no MaxQuant

Comet · no PatternLab

MSFragger · no FragPipe

Mascot · comercial

BLOCO 4 · IDENTIFICAÇÃO

Target-decoy: como saber se não estamos nos enganando

1%

FDR: no máximo 1 erro a cada 100 identificações aceitas

Target — o banco verdadeiro de proteínas.

Decoy — um banco falso, com as sequências **invertidas**. Nenhum peptídeo real deveria combinar com ele.

Cada acerto num decoy é um falso positivo conhecido → estima-se quantos há entre os targets e ajusta-se o limiar.

Como testar um radar com **alvos fictícios conhecidos**: contando quantas vezes ele "trava" neles, estima-se a taxa de falsos alarmes.

BLOCO 4 · IDENTIFICAÇÃO

Medimos peptídeos, queremos proteínas

Um mesmo peptídeo pode existir em várias proteínas parecidas (isoformas, famílias de genes). É um quebra-cabeça com peças repetidas.

Protein group

Proteínas que os peptídeos observados **não conseguem distinguir**. É a unidade reportada.

Peptídeo único

Existe em uma só proteína ou grupo. A **evidência mais forte**.

Peptídeo *razor*

Compartilhado, mas atribuído ao grupo com mais evidências (navalha de Occam).

BLOCO 5 · QUANTIFICAÇÃO

Quatro formas de medir “quanto”

Estratégia	Como funciona	Vantagem	Limitação
Sem marcação (LFQ)	Uma corrida por amostra; compara-se a intensidade do MS1 (MaxLFQ)	Barato, sem limite de amostras	Mais valores ausentes
SILAC	Células crescem com aminoácidos “pesados” (^{13}C, ^{15}N): pares leve/pesado	Muito preciso	Só células em cultura
TMT / iTRAQ	Etiquetas químicas que liberam íons repórter ao fragmentar	16–18 amostras numa corrida	Custo; distorção de razões
Direcionada (SRM / PRM)	Monitora só uma lista de peptídeos escolhidos antes	Sensibilidade máxima: validar, detectar alvos	Só mede o que já se procura

Na prática de hoje: **LFQ**, aquisição **DDA**, processado no **MaxQuant**.

BLOCO 5 · QUANTIFICAÇÃO

Dos números brutos à resposta

1 $\log_2$

Dobrar = somar 1. $\log_2$FC +1 = dobro; −1 = metade; +0,58 ≈ 1,5×.

2 Normalização

Corrige diferenças técnicas entre corridas, por exemplo igualando as medianas.

3 Valores ausentes

Muitas vezes abaixo do limite de detecção: imputados com valores baixos.

4 Teste por proteína

Teste t ou modelo linear → um valor-p para cada proteína.

5 Testes múltiplos

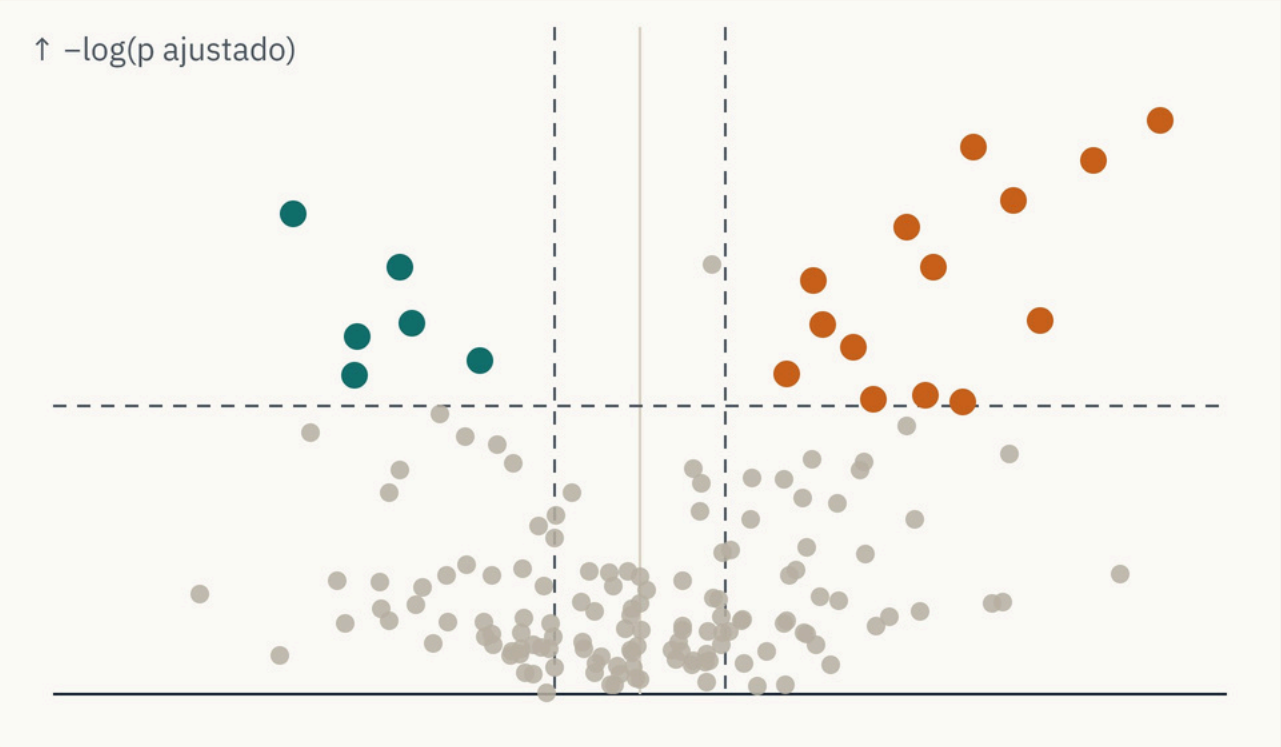
2.000 testes com p < 0,05 → ~100 falsos achados. Use o valor-p **ajustado** (Benjamini–Hochberg).

6 Volcano plot

Efeito (x) contra confiança (y), tudo num só gráfico.

BLOCO 5 · QUANTIFICAÇÃO

Como ler um volcano plot



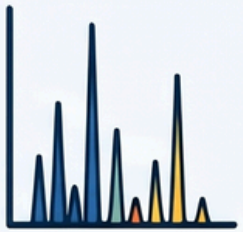
- **Aumentou**, com confiança
- **Diminuiu**, com confiança
- Sem mudança relevante

Tracejados: p ajustado = 0,05 (horizontal) e fold change 1,5× (verticais, ±0,58 em $\log_2$). Interessa o que está **acima e para fora**.

Gráfico ilustrativo.

DO ESPECTRO AO DADO BIOLÓGICO: IDENTIFICAÇÃO E QUANTIFICAÇÃO DE PROTEÍNAS

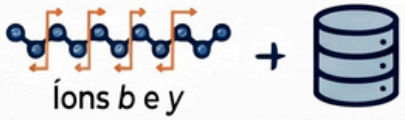
Compreender como a bioinformática identifica sequências de peptídeos e calcula a abundância de proteínas a partir da espectrometria de massas.



DADOS BRUTOS DE ESPECTROMETRIA DE MASSAS

1. IDENTIFICAÇÃO E CONTROLE

IDENTIFICAÇÃO POR FRAGMENTAÇÃO E BUSCA FASTA



Os espectros MS2 revelam degraus de aminoácidos (íons b e y) comparados *in silico* com bancos de dados.

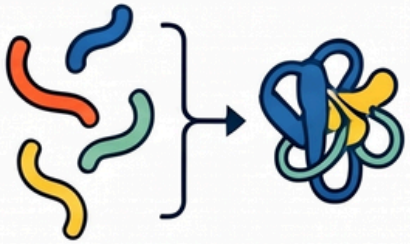
CONTROLE DE ERRO COM TARGET-DECOY



O uso de um banco falso (sequências invertidas) garante a filtragem dos resultados com FDR de no máximo 1%.

2. AGRUPAMENTO E INFERÊNCIA

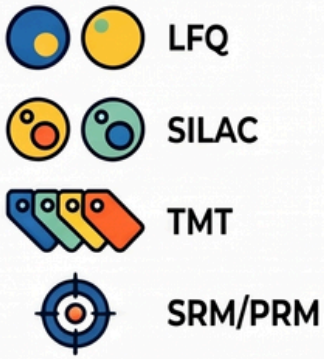
AGRUPAMENTO POR INFERÊNCIA DE PROTEÍNAS



Peptídeos únicos e *razor* agrupam proteínas indistinguíveis pelo principio da parcimônia.

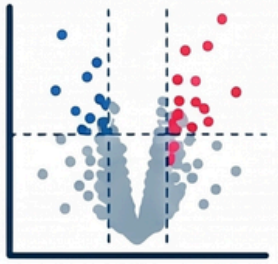
3. QUANTIFICAÇÃO E ESTATÍSTICA

ESTRATÉGIAS DE QUANTIFICAÇÃO DE ABUNDÂNCIA



O cálculo utiliza métodos sem marcação (LFQ), marcação metabólica (SILAC), marcação isobárica (TMT) ou análise direcionada (SRM/PRM).

ANÁLISE ESTATÍSTICA E VOLCANO PLOT



Aplica-se escala $\log_2$, normalização e valor-p ajustado para destacar proteínas com diferenças relevantes entre condições.

Gemini Notebook

BLOCO 6 · FERRAMENTAS E BANCOS DE DADOS

Cada ferramenta tem o seu lugar no fluxo

Sequências
UniProt
o FASTA da busca

→

Medida
LC-MS/MS
os arquivos brutos

→

Identificar
MaxQuant
PatternLab
lista com FDR 1%

→

Estatística
Perseus
MSstats
o que mudou

→

Validar
Skyline
ensaio direcionado

PRIDE / ProteomeXchange — guarda arquivos brutos e resultados com um código PXD, para qualquer um reproduzir.

Galaxy — roda MaxQuant e MSstats no navegador, com histórico reprodutível.

BLOCO 6 · FERRAMENTAS E BANCOS DE DADOS

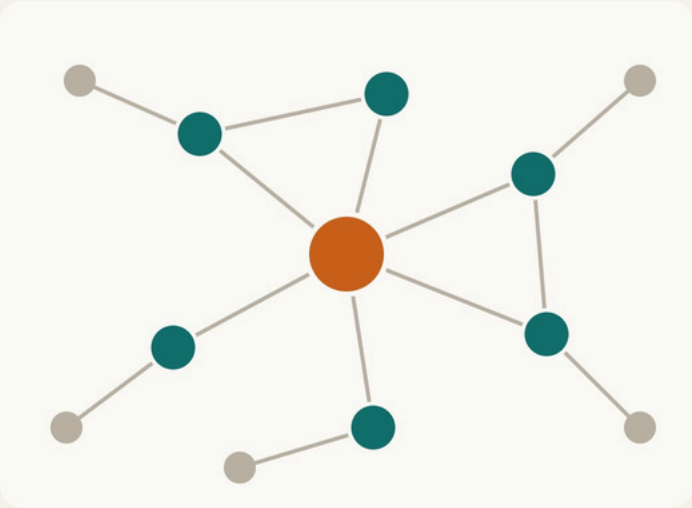
Ficha rápida das ferramentas

Ferramenta	O que faz	Licença	Onde roda
MaxQuant + Andromeda	Brutos + FASTA → peptídeos e proteínas	Gratuito, fechado	Win, Linux, Galaxy
PatternLab (Fiocruz)	Fluxo completo, com motor Comet	Gratuito	Windows
Skyline	Planeja e quantifica alvos (SRM/PRM, DIA)	Código aberto	Windows
Perseus	Estatística por cliques sobre o MaxQuant	Gratuito, fechado	Windows
MSstats	Modelos estatísticos em R (Bioconductor)	Código aberto	R, Galaxy
Galaxy	Ferramentas por formulários, com histórico	Código aberto	Navegador
Expasy PeptideMass	Digestão in silico de uma proteína	Gratuito	Navegador

Destaque nacional: o PatternLab é desenvolvido no Brasil (Fiocruz Paraná, com raízes na COPPE/UFRJ).

BLOCO 6 · INTERATOMA

Interatoma: quem interage com quem



Isca (laranja), seus **parceiros** (verde) e os parceiros deles. Cada linha é uma interação.

O **organograma** da célula — mapeado com o mesmo **bottom-up** de hoje:

AP-MS

"Pesca" a isca e identifica por MS tudo o que veio preso a ela.

BioID / APEX

Uma enzima na isca "carimba" as proteínas vizinhas, na célula viva.

XL-MS

Um reagente "grampeia" proteínas que se tocam; o MS acha os pares.

Sem MS: duplo-híbrido em levedura (Y2H), testando par a par.

STRING — associações com escore de 0 a 1; por padrão, "trabalham juntas", **não necessariamente se tocam**. **BioGRID** e **IntAct** — interações curadas de artigos.

INTERVALO · 1:10 – 1:20

10 min

Ao voltar, tenha pronto:

- Login feito em **usegalaxy.eu**
- Uma aba aberta em **web.expasy.org/peptide_mass**

MOMENTO 2 · 1:20 – 2:30

Prática

Parte A · 20 min

Da proteína ao peptídeo: pensar como o motor de busca. UniProt, PeptideMass e PRIDE.

Parte B · 50 min

Estatística em dados reais de câncer de pele com MSstats, no Galaxy.

ESTUDO DE CASO · FÖLL ET AL., MATRIX BIOLOGY (2018)

Dois cânceres de pele, uma pergunta

cSCC — carcinoma espinocelular cutâneo. Comum e quase sempre curável, mas grave quando **metastatiza**.

RDEB — doença genética sem colágeno VII: a pele forma bolhas e desenvolve um cSCC muito agressivo.

Bottom-up · LFQ · DDA · MaxQuant · PRIDE PXD006914

19	13	6
pacientes	cSCC metastático	cSCC-RDEB

Tecido em formol e parafina, como nos arquivos de patologia. Partimos dos resultados do MaxQuant já prontos (Galaxy Training Network, Zenodo): rodar os 19 brutos levaria horas.

PARTE A · 20 MIN · NAVEGADOR

Pensando como o motor de busca

A1 · 5 min

UniProt

Busque **P02768** (albumina). Veja tamanho e massa em *Sequence*.

Em *PTM/Processing*: peptídeo-sinal e propeptídeo são removidos.

A2 · 10 min

PeptideMass

P02768 · **Trypsin** · 0 missed cleavages · monoisotópica $[M+H]^+$ · > 500 Da

Ache LVNEVTEFAK. Calcule o m/z com 2 cargas. Repita com 1 missed cleavage.

A3 · 5 min

PRIDE

Abra o projeto **PXD006914**: instrumento, espécie, artigo, arquivos.

Tamanho de um .raw × 19 amostras = ?

`uniprot.org · web.expasy.org/peptide_mass · ebi.ac.uk/pride/archive/projects/PXD006914`

PARTE B · 50 MIN · GALAXY EUROPE

Preparar os dados (B1 – B3)

B1 Crie o histórico **Aula5_Proteomica_cSCC** — o “caderno de laboratório” do Galaxy.

B2 Upload → Paste/Fetch: os **6 links do Zenodo** do roteiro. Espere ficarem verdes e renomeie.

B3 **Select** só linhas humanas: (HUMAN)|(Majority) e (HUMAN)|(Sequence). **Replace Text**: apague o “+” de contaminante (colunas 138 e 50).

A amostra é pele!

O MaxQuant marca queratinas como “contaminantes” (vêm da pele de quem manipula). Aqui elas são biologia real.

O software não pensa por você.

PARTE B · B4 E B5

Rodar o MSstats — e não ficar esperando

Parâmetro	Valor
input source	MaxQuant
evidence / proteinGroups	as versões “input for MSstats”
Protein ID in evidence.txt	Leading razor protein
Remove proteins with 1 peptide	Yes
Compare Groups	Yes · comparison matrix
Outputs	log, QCPlot, ComparisonResult, VolcanoPlot
Fold change cutoff	1.5
log of adjusted p-value	2

Enquanto roda: PTXQC

B.1 Quantas linhas tem o Protein Groups?

B.2 Quanto da intensidade vem de “contaminantes”? Por que isso não é sujeira aqui?

B.3 Alguma amostra destoa nas intensidades?

PARTE B · B6 · INTERPRETAR

O funil: de milhares de proteínas a algumas centenas

~2.500

grupos de proteínas identificados (FDR 1%)

→

~1.700

entram na estatística (humanas, 2+ peptídeos)

→

~200

com p ajustado < 0,05 — a maioria maior no metastático

Colágeno XIV (Q05707) maior no cSCC-RDEB — talvez compensando a falta de colágeno VII. A proteômica gerou a hipótese; anticorpos a confirmaram.

MOMENTO 3 · 2:30 – 3:00

Conexão

Cada clique, um conceito · da descoberta ao campo · trabalho final · fechamento

TEORIA ↔ PRÁTICA

Cada clique, um conceito

O que você fez	O conceito por trás
Viu o peptídeo-sinal removido no UniProt	Por que medir proteínas, não só genes
Digeriu a albumina no PeptideMass	Regra da tripsina, digestão in silico
Calculou m/z com carga +2	Ionização e a razão m/z
Testou missed cleavages	Tamanho do espaço de busca
Partiu do Protein Groups do MaxQuant	FDR 1% e inferência de proteínas
Manteve os “contaminantes” humanos	Conhecer a amostra muda a análise
Viu medianas alinhadas no QCPlot	Normalização
Filtrou pelo p ajustado	Testes múltiplos (Benjamini–Hochberg)
Interpretou o colágeno XIV	Da estatística à hipótese, que exige validação

E NO MUNDO REAL?

Do volcano plot ao ensaio de campo

Hoje

Descoberta

Shotgun + LFQ: milhares de proteínas, uma lista de candidatos.

→

Depois

Direcionado

SRM/PRM montado no Skyline: só os alvos, com máxima sensibilidade.

→

Aplicação

Teste confirmatório

Toxina proteica, marcador de exposição a agente químico, microrganismo.

A LISTA DE PROTEÍNAS ALIMENTA AS PRÓXIMAS AULAS

Unidade 7 · estrutura (PDB, AlphaFold)

Unidade 8 · filogenia

Unidade 9 · vias e redes (KEGG, Reactome, STRING)

TRABALHO FINAL · PELO MENOS DUAS TÉCNICAS

Três caminhos que partem desta aula

Reanálise

Um conjunto **PXD** público da sua linha (Galaxy/MSstats) **+** vias e redes das proteínas alteradas (KEGG, STRING).

Ensaio-alvo

Peptídeos trípticos de uma proteína-alvo (PeptideMass) **+** estrutura (AlphaFold, SWISS-MODEL).

Evolução

Proteínas diferenciais **+** homólogos (BLAST) e filogenia de uma família de interesse.

FECHAMENTO

Cinco ideias para levar

1. O espectrômetro mede **m/z**: MS1 serve para **quantificar**, MS2 para **identificar**.
2. No **bottom-up**: tripsina → cromatografia → ESI → fragmentos **b** e **y**.
3. A busca compara espectros com um banco; o **target-decoy** mantém a **FDR em 1%**.
4. Quantificar exige **$\log_2$, normalização, valores ausentes e p ajustado** — e réplicas biológicas.
5. A ferramenta faz a conta; **a interpretação depende de conhecer a amostra** e a pergunta.

AUTOAVALIAÇÃO E ATIVIDADE ASSÍNCRONA

Para responder em 2 – 3 linhas

1. Por que a tripsina é a enzima preferida no bottom-up?
2. Explique o target-decoy a um colega de engenharia.
3. DDA × DIA: qual gera mais valores ausentes?
4. No volcano, onde ficam as proteínas que mudaram muito, mas sem significância?
5. Para detectar uma toxina específica numa amostra ambiental: qual estratégia e qual ferramenta?

Para casa

Terminar a Parte B e salvar o volcano.

Separar as significativas por grupo (c3>0.58 e c3<-0.58) e pesquisar 5 de cada no UniProt.

Desafio opcional: digestão *in silico* em Python no Google Colab (código no roteiro).

PRÓXIMA AULA · UNIDADE 6

Epigenômica

Metilação do DNA, modificações de histonas e acessibilidade da cromatina

REFERÊNCIAS PRINCIPAIS

Aebersold & Mann, Nature 422 (2003) · Cox & Mann, Nat. Biotechnol. 26 (2008) · Santos et al., PatternLab V, Nat. Protoc. (2022) · Choi et al., MSstats, Bioinformatics 30 (2014) · Föll et al., Matrix Biology 66 (2018)

Tutorial-base: Galaxy Training Network, “MaxQuant and MSstats for the analysis of label-free data” — gxy.io/GTN:T00219