

PPGED · IME — INTRODUÇÃO À BIOINFORMÁTICA

Aula 2


Qualidade e Processamento de Dados de NGS

Identificação e comparação de sequências biológicas


Prof. Dr^a. Mariana Quezado · Prof. Dr. Roberto Filho

Carga horária: 3h · Modalidade online síncrona

PROCESSAMENTO E SEQUENCIAMENTO INICIAL



O material isolado segue para purificação e estudo de proteínas e funções celulares.



Escolha de modelos evolutivos para reconstruir a história e o parentesco entre organismos.

Uso de modelagem estrutural para prever como as moléculas se comportam e interagem.

Sequenciamento de primeira geração

Fluorescently labeled ddNTPs

T

ddTTP

A

ddATP


G

ddGTP

C



ddCTP

DNA template




Separate with a gel

Use a sequencing machine




Sequenciamento de segunda geração



Sequenciamento de terceira geração

Nanopore Sequencing Principle



Na tecnologia Nanopore os fragmentos de DNA ou RNA atravessam um nanoporo proteico incorporado em uma membrana e, conforme as bases passam pelo poro, elas alteram o fluxo de corrente elétrica, que então é decodificada em tempo real por algoritmos de basecalling.

Por que isso importa para Engenharia de Defesa

BV

Biovigilância e biodefesa

Identificar rapidamente um patógeno (vírus, bactéria) a partir de amostras ambientais ou clínicas.

ID

Identificação forense biológica

Comparar material genético encontrado em campo com bancos de dados de referência.

VA

Verificação de agentes biológicos

Distinguir uma cepa natural de uma manipulada, comparando sequências.

QP

Química de proteínas e macromoléculas

Entender a sequência é o primeiro passo antes de qualquer análise estrutural (Unidade 7).

O genoma como um “livro despedaçado”

O sequenciador não lê o “livro” (o DNA) inteiro de uma vez. **Ele produz milhões de pedacinhos de texto — as reads — com erros de leitura aqui e ali.**

1

Checar

a qualidade de cada pedacinho

2

Aparar

o que está ruim (limpeza)

3

Remontar

comparando com um genoma
de referência

4

Buscar


trechos parecidos em bancos
mundiais

Cada ferramenta desta aula resolve uma dessas quatro etapas.

O que é uma “read”?

NGS (Next Generation Sequencing) — sequenciadores modernos não leem uma molécula de DNA inteira.

Eles quebram o material genético em milhões de fragmentos pequenos e leem cada um separadamente. Cada fragmento lido é uma read.




Formato de arquivo: cada read lida é salva em um arquivo de texto no formato FASTQ, que veremos a seguir.

Basecalling


Os sequenciadores não leem as sequências de DNA diretamente, mas sim grandezas físicas e/ou químicas, gerando assim dados brutos de sinais. Posteriormente, estes sinais são processados a partir de algoritmos que nomeiam as bases (basecalling), podendo estes estarem implementados no próprio sequenciador, em um servidor ou na nuvem.

Formatos



AB1

Formatos




SFF

Formatos

```
>9_62_1919_F3
```

```
T01231033313313303131110311003330000
```

$T_0 = T \Rightarrow T_1 = G \Rightarrow G_2 = A \Rightarrow \dots$



CSFASTA

```
>9_62_1919_F3
```

```
TGATGGCGCATACGCCGTACACCGTGGGCGCCCCC
```

Formatos

SAM

```
coord 12345678901234 5678901234567890123456789012345
ref    AGCATGTTAGATAA**GATAGCTGTGCTAGTAGGCAGTCAGCGCCAT
```

```
r001+      TTAGATAAAGGATA*CTG
r002+      aaaAGATAA*GGATA
r003+      gcttaAGCTAA
r004+      ATAGCT.....TCAGC
r003-      tttagctTAGGC
r001-      CAGCGCCAT
```

```
@SQ SN:ref LN:45
r001 163 ref 7 30 8M2I4M1D3M = 37 39 TTAGATAAAGGATACTA *
r002 0 ref 9 30 3S6M1P1I4M * 0 0 AAAAGATAAGGATA *
r003 0 ref 9 30 5H6M * 0 0 AGCTAA * NM:i:1
r004 0 ref 16 30 6M14N5M * 0 0 ATAGCTTCAGC *
r003 16 ref 29 30 6H5M * 0 0 TAGGC * NM:i:0
r001 83 ref 37 30 9M = 7 -39 CAGCGCCAT *
```

Formatos

```
>Taxon1
CCTGCGGAAGATCGGCACTAGAATAGCCAGAACCGTTTCTCTGAGGCTTCCGGCCTTCCC
>Taxon2
CCATCGGTAGCGCATCCTTAGTCCAATTAAGTCCCTATCCAGGCGCTCCGCCGAAGGTCT
>Taxon3
CCACCCTCGTGGTATGGCTAGGCATTCAAGGAACCGGAGAACGCTTCAGACCAGCCCGGAC
```

FASTA

Identifier —● @SRR566546.970 HWUSI-EAS1673_11067_FC7070M:4:1:2299:1109 length=50
Sequence —● TTGCCTGCCTATCATTTTAGTGCCTGTGAGGTGGAGATGTGAGGATCAGT
'+' sign —● +
Quality scores —● hhhhhhhhhhhghghghhhhhfhhhhhfffffe'ee['X]b[d[ed'[Y[~Y
Identifier —● @SRR566546.971 HWUSI-EAS1673_11067_FC7070M:4:1:2374:1108 length=50
Sequence —● GATTTGTATGAAAGTATACAACATAAACTGCAGGTGGATCAGAGTAAGTC
'+' sign —● +
Quality scores —● hhhhghfhcghghggfcffdhfehhhhcehdchhdhahehffffde'bVd

FASTQ

Phred quality scores are logarithmically linked to error probabilities

Phred Quality Score	Probability of incorrect base call	Base call accuracy
10	1 in 10	90%
20	1 in 100	99%
30	1 in 1000	99.9%
40	1 in 10,000	99.99%
50	1 in 100,000	99.999%
60	1 in 1,000,000	99.9999%

Phred Score: cada caractere da linha 4 representa uma nota de confiança (0 a ~40) de que aquela base foi lida corretamente.

ASCII Table

Dec	Hex	Oct	Char	Dec	Hex	Oct	Char	Dec	Hex	Oct	Char	Dec	Hex	Oct	Char
0	0	0		32	20	40	[space]	64	40	100	@	96	60	140	`
1	1	1		33	21	41	!	65	41	101	A	97	61	141	a
2	2	2		34	22	42	"	66	42	102	B	98	62	142	b
3	3	3		35	23	43	#	67	43	103	C	99	63	143	c
4	4	4		36	24	44	\$	68	44	104	D	100	64	144	d
5	5	5		37	25	45	%	69	45	105	E	101	65	145	e
6	6	6		38	26	46	&	70	46	106	F	102	66	146	f
7	7	7		39	27	47	'	71	47	107	G	103	67	147	g
8	8	10		40	28	50	(	72	48	110	H	104	68	150	h
9	9	11		41	29	51	)	73	49	111	I	105	69	151	i
10	A	12		42	2A	52	*	74	4A	112	J	106	6A	152	j
11	B	13		43	2B	53	+	75	4B	113	K	107	6B	153	k
12	C	14		44	2C	54	,	76	4C	114	L	108	6C	154	l
13	D	15		45	2D	55	-	77	4D	115	M	109	6D	155	m
14	E	16		46	2E	56	.	78	4E	116	N	110	6E	156	n
15	F	17		47	2F	57	/	79	4F	117	O	111	6F	157	o
16	10	20		48	30	60	0	80	50	120	P	112	70	160	p
17	11	21		49	31	61	1	81	51	121	Q	113	71	161	q
18	12	22		50	32	62	2	82	52	122	R	114	72	162	r
19	13	23		51	33	63	3	83	53	123	S	115	73	163	s
20	14	24		52	34	64	4	84	54	124	T	116	74	164	t
21	15	25		53	35	65	5	85	55	125	U	117	75	165	u
22	16	26		54	36	66	6	86	56	126	V	118	76	166	v
23	17	27		55	37	67	7	87	57	127	W	119	77	167	w
24	18	30		56	38	70	8	88	58	130	X	120	78	170	x
25	19	31		57	39	71	9	89	59	131	Y	121	79	171	y
26	1A	32		58	3A	72	:	90	5A	132	Z	122	7A	172	z
27	1B	33		59	3B	73	;	91	5B	133	[	123	7B	173	{
28	1C	34		60	3C	74	<	92	5C	134	\	124	7C	174	
29	1D	35		61	3D	75	=	93	5D	135	]	125	7D	175	}
30	1E	36		62	3E	76	>	94	5E	136	^	126	7E	176	~
31	1F	37		63	3F	77	?	95	5F	137	_	127	7F	177	

Phred Score: uma escala logarítmica

$$Q = -10 \times \log_{10}(P \text{ erro})$$

Phred Score (Q)	Probabilidade de erro	Em palavras
Q10	1 em 10	90% de acerto
Q20	1 em 100	99% de acerto
Q30	1 em 1.000	99,9% de acerto
Q40	1 em 10.000	99,99% de acerto

Por que o “teto” fica perto de 40?

Não é uma limitação matemática (a escala poderia seguir subindo) — é uma limitação **física/tecnológica** dos sequenciadores atuais: eles não sustentam, na prática, confiança maior que “1 erro a cada 10.000 bases”.

Escala parecida com decibéis ou a escala Richter: pequenos aumentos no número representam grandes saltos de confiança.

Por que aparecem letras como “I”?

Cada Phred Score é convertido em um único caractere ASCII, para ocupar menos espaço no arquivo — padrão Phred+33 (“Sanger”).

código ASCII do caractere = Q + 33

Caractere	ASCII	Phred (Q)	Qualidade
!	33	0	Péssima
#	35	2	Muito baixa
5	53	20	Razoável (99%)
?	63	30	Boa (99,9%)
I	73	40	Excelente (máxima)

Exemplo da linha de qualidade

```
IIIIIIIIIIIIIIIIII!!!!IIIIIIII
```

I = qualidade máxima (Q40) · ! = qualidade péssima (Q0) no meio da read

É exatamente esse tipo de padrão que o FastQC detecta em seus gráficos — e que o Trimmomatic depois corta.

Controle de qualidade: FastQC e MultiQC



FastQC

O que é

Faz um “raio-X” de um arquivo FASTQ inteiro e gera um relatório visual (HTML) com gráficos prontos: qualidade por posição, conteúdo de GC, adaptadores, duplicatas.

Por que importa

Aponta-se o arquivo, clica em “rodar” — não é necessário programar.



MultiQC

O que é


Agrega os relatórios de várias amostras (ex.: 50 relatórios do FastQC) em um único painel comparativo.

Por que importa

Essencial quando se processam dezenas ou centenas de amostras — como em vigilância epidemiológica.

Limpeza dos dados: Trimmomatic e Cutadapt

Depois do diagnóstico (FastQC), muitas vezes descobrimos pontas de baixa qualidade ou resíduo de adaptadores de sequenciamento.




Trimmomatic e Cutadapt: funcionam como uma “tesoura de aparar bordas” — cortam as partes de baixa qualidade nas extremidades das reads e removem sequências de adaptador contaminantes.

ANTES



Qualidade caindo nas pontas + resíduo de adaptador

DEPOIS



Reads aparadas, sem adaptador, prontas para o alinhamento


Alinhamento contra um genoma de referência

As reads limpas precisam ser “encaixadas” de volta em um genoma de referência — como resolver um quebra-cabeça enorme, comparando cada peça com a imagem da caixa.



BWA

Burrows-Wheeler Aligner. Muito usado em genômica humana/clínica; bom para reads mais longas e indels maiores.



Bowtie2

Muito usado em RNA-seq e metagenômica; referência para reads curtas de Illumina — nossa escolha na prática desta aula.



SAMtools

O “canivete suíço” para manipular arquivos SAM/BAM: ordenar, filtrar, indexar e converter.

O que é alinhamento?

Processo de comparação de duas ou mais sequências (de ácidos nucleicos ou proteínas) de forma a se observar seu nível de identidade, ajustando as posições equivalentes de cada monômero (nucleotídeos ou aminoácidos) das sequências analisadas.

Aplicações do alinhamento

Montar genomas

Mapear genes

Analisar motivos

Atribuir funções

Estabelecer relações
de similaridade

Predizer mutações

Matrizes de substituição

- Atribui uma pontuação para alinhar qualquer possível par de resíduos.
- Diferentes matrizes de substituição são adaptadas para detectar semelhanças entre sequências que divergiram em diferentes graus.
- Uma única matriz pode, no entanto, ser razoavelmente eficiente em uma faixa relativamente ampla de mudança evolutiva.

Matriz BLOSUM

BLOSUM - *Blocks of Aminoacids Substitution Matrix*

Ala	4																			
Arg	-1	5																		
Asn	-2	0	6																	
Asp	-2	-2	1	6																
Cys	0	-3	-3	-3	9															
Gln	-1	1	0	0	-3	5														
Glu	-1	0	0	2	-4	2	5													
Gly	0	-2	0	-1	-3	-2	-2	6												
His	-2	0	1	-1	-3	0	0	-2	8											
Ile	-1	-3	-3	-3	-1	-3	-3	-4	-3	4										
Leu	-1	-2	-3	-4	-1	-2	-3	-4	-3	2	4									
Lys	-1	2	0	-1	-3	1	1	-2	-1	-3	-2	5								
Met	-1	-1	-2	-3	-1	0	-2	-3	-2	1	2	-1	5							
Phe	-2	-3	-3	-3	-2	-3	-3	-3	-1	0	0	-3	0	6						
Pro	-1	-2	-2	-1	-3	-1	-1	-2	-2	-3	-3	-1	-2	-4	7					
Ser	1	-1	1	0	-1	0	0	0	-1	-2	-2	0	-1	-2	-1	4				
Thr	0	-1	0	-1	-1	-1	-1	-2	-2	-1	-1	-1	-1	-2	-1	1	5			
Trp	-3	-3	-4	-4	-2	-2	-3	-2	-2	-3	-2	-3	-1	1	-4	-3	-2	11		
Tyr	-2	-2	-2	-3	-2	-1	-2	-3	2	-1	-1	-2	-1	3	-3	-2	-2	2	7	
Val	0	-3	-3	-3	-1	-2	-2	-3	-3	3	1	-2	1	-1	-2	-2	0	-3	-1	4
Ala	Arg	Asn	Asp	Cys	Gln	Glu	Gly	His	Ile	Leu	Lys	Met	Phe	Pro	Ser	Thr	Trp	Tyr	Val	

Baseadas em alinhamentos observados.

Criadas pela fusão de todas as sequências mais semelhantes do que uma determinada percentagem em uma única sequência e depois comparando somente estas sequências.

Matriz PAM

PAM - Point Accepted Mutations


Apresenta a probabilidade da substituição de um aminoácido por outro, calculada observando-se diferenças nas proteínas que estão muito próximas evolutivamente (com pelo menos 85% de similaridade), as substituições em questão não têm efeito sobre a função da proteína, portanto trata-se de mutações aceitas no processo evolutivo

Alinhamento global

O alinhamento global é feito quando comparamos uma sequência de aminoácidos ou nucleotídeos com outra, ao longo de toda sua extensão. O algoritmo Needleman-Wunsch é o mais conhecido para realizar esse tipo de alinhamento.

Antes do alinhamento

```
>test1
ATGAGTCTCTCTGATAAGGACAAGGCTGCTGTGAAAGCCCTATGG
>test2
CTGTCTCCTGCCGACAAGACCAACGTCAAGGCCGCCTGGGGTAAG
```



Depois do alinhamento

```
>test1
ATGAGTCTCTCTGATAAGGACAAGGCTGCTGTGAAAGC--CCTATGG----
>test2
-----CTGTCTCCTGCCGACAAGACCAACGTCAAGGCCGCCTGGGGTAAG
```

Alinhamento local

O alinhamento local acontece quando a comparação entre duas sequências é feita através de pequenas regiões.

Realiza buscas mais rápidas, pois utiliza uma heurística que quebra as sequências de entrada e das bases de dados em fragmentos e procura, inicialmente, similaridades entre elas.

Antes do alinhamento

```
>test1
ATGAGTCTCTCTGATAAGGACAAGGCTGCTGTGAAAGCCCTATGG
>test2
CTGTCTCCTGCCGACAAGACCAACGTCAAGGCCGCTGGGGTAAG
```




Depois do alinhamento

```
>test1
GTCTCTCTGATAAGGACAAGGCTGCTGTGAAAGC--CCTATGG
>test2
GTCTC-CTGCC--GACAAGACCAACGTCAAGGCCGCTGGGG
```

Mudando de escala: busca e comparação

Em vez de alinhar milhões de reads contra um genoma, agora buscamos: dada UMA sequência, quais sequências parecidas já existem no mundo?



BLAST (*Basic Local Alignment Search Tool*)

A ferramenta mais usada em bioinformática para comparar uma sequência de interesse contra bancos mundiais (GenBank, UniProt, RefSeq), retornando os “parentes” mais parecidos com um escore de similaridade.



Clustal Omega e MUSCLE

Enquanto o BLAST compara uma sequência contra um banco gigante, essas ferramentas alinham várias sequências ao mesmo tempo, lado a lado, destacando regiões conservadas e variáveis entre elas — útil para comparar a mesma proteína entre espécies.

Série BLAST

BLASTn: Promove o alinhamento entre uma sequência (ou grupo de sequências) de nucleotídeos do usuário com sequências depositadas no GeneBank

BLASTx: Promove o alinhamento entre uma sequência (ou grupo de sequências) traduzida de nucleotídeos do usuário e proteínas anotadas.

tBLASTx: Promove o alinhamento entre uma sequência (ou grupo de sequências) traduzida de nucleotídeos do usuário e traduções de sequências depositadas no GenBank.

Série BLAST


BLAST-Primer: Promove o alinhamento entre iniciadores do usuário e sequências depositadas no GenBank, de forma isolada ou simultânea.


tBLASTn: Promove o alinhamento entre sua proteína e traduções de sequências depositadas no GenBank.

BLASTp: Promove o alinhamento entre a sua proteína e proteínas do PDB.


Alinhamento múltiplo de sequências

- Comparação de duas ou mais sequências de nucleotídeos ou aminoácidos de forma a observar seu nível de similaridade.





O fluxo completo da Unidade 2



Na prática (2h a seguir): vamos rodar exatamente esse fluxo no Galaxy, usando amostras reais de procarioto (E. coli, SRR957824) e eucarioto (levedura, SRR453566) do SRA.

Vamos para a prática

Galaxy · fastq-dump · FastQC · Trimmomatic · Bowtie2 · SAMtools · BLAST · Clustal Omega

Dúvidas antes de começarmos?