

INTRODUÇÃO À BIOINFORMÁTICA — PPGED/IME

Genômica: Estrutura, Organização e Anotação do Material Genético

Aula 3 — Parte Teórica • Procariotos x Eucariotos • Ferramentas para a prática em Galaxy



Roteiro da aula

1

Elementos gênicos e genômicos

DNA, RNA, nucleotídeo, empacotamento da cromatina

2

Genes: procariotos x eucariotos

Promotor, terminador, splicing, óperons

3

Genomas: procariotos x eucariotos

Tamanho, forma, plasmídeos, organelas

4

Ferramentas da prática

Galaxy, SPAdes, Quast, Prokka, NCBI/Ensembl

Genômica na Engenharia de Defesa



Biodefesa e biovigilância

Identificar rapidamente um patógeno desconhecido a partir de amostra ambiental ou clínica.



Identificação forense biológica

Diferenciar uma cepa natural de uma cepa manipulada em laboratório.




Base para química de proteínas

Saber qual gene codifica uma proteína de interesse é o primeiro passo antes de estudar sua estrutura.

A DANÇA DAS VARIANTES NO BRASIL

Como mudou a distribuição das seis principais linhagens em circulação entre fevereiro de 2020 e fevereiro de 2021



PARTE 1

Biologia Molecular dos Elementos Gênicos

DNA, RNA e a arquitetura física do material genético — a base para entender o que a bioinformática processa.

O nucleotídeo: a unidade básica

Todo ácido nucleico (DNA ou RNA) é formado por unidades repetidas chamadas **nucleotídeos**, cada um formado por três partes:

Fosfato

Radical do ácido fosfórico — forma o "esqueleto" da cadeia.


Pentose

Açúcar de 5 carbonos: ribose (RNA) ou desoxirribose (DNA).


Base nitrogenada

Composto cíclico: A, T, G, C (DNA) ou A, U, G, C (RNA).


NUCLEOTÍDEO



PENTOSES




Ribose



Desoxirribose

DNA → DNA → RNA (replicação → transcrição, no núcleo/nucleoide)
RNA → proteína (tradução, no citoplasma)


Ligação entre duas fitas de DNA




Esquemas de molécula de DNA, no plano e retorcida

P = Fosfato


D = Desoxirribose



Cadeia de nucleotídeos



Duas cadeias pareadas, no plano






Dupla-hélice



Dupla-hélice

Mudanças na conformação do DNA





0.2 μm

RNA: o intermediário funcional

Fita simples, com ribose e uracila (U) no lugar da timina (T). Três tipos participam da síntese de proteínas:

RNA-m

Mensageiro

Leva o código genético do DNA até o citoplasma; organizado em códons (trincas de bases).

RNA-t

Transportador

Transporta os aminoácidos até o ribossomo, no local da síntese proteica.

RNA-r

Ribossomal

Compõe a estrutura dos ribossomos, onde a proteína é montada.






Figura 7-6 A transcrição produz uma molécula de RNA complementar a uma das fitas do DNA. A fita de DNA não molde (a fita *superior* neste exemplo) é algumas vezes denominada *fita codificadora*, pois sua sequência é equivalente à sequência do RNA produzido.

Estrutura do RNA

Figura 7-3 A estrutura química do RNA se diferencia ligeiramente da estrutura do DNA. (A) O RNA contém o açúcar ribose, o qual difere da desoxirribose, o açúcar utilizado no DNA pela presença de um grupo $-OH$ adicional. (B) O RNA contém a base uracila, a qual difere da timina, a base equivalente no DNA, pela ausência de um grupo $-CH_3$. (C) Um pequeno fragmento de RNA. A ligação química entre nucleotídeos no RNA é a mesma que ocorre no DNA.



Estrutura do RNA




Figura 7-4 A uracila forma pares de bases com a adenina. Apesar da ausência de um grupo metila, a uracila apresenta as mesmas propriedades de pareamento da timina. Assim, pares de bases U-A se assemelham bastante a pares de bases T-A (ver Figura 5-6A).






Figura 7-5 O RNA pode formar pares de bases intramolecularmente e se dobrar em estruturas específicas. O RNA é uma fita simples, mas frequentemente contém pequenos segmentos de nucleotídeos que podem sofrer pareamento com sequências complementares encontradas em outras regiões da mesma molécula. Tais interações, em adição a pareamentos "não convencionais", permitem que uma molécula de RNA se dobre, adquirindo uma estrutura tridimensional, a qual é determinada por sua sequência de nucleotídeos. (A) Diagrama de uma estrutura hipotética de RNA dobrada, ilustrando somente interações convencionais (ou seja, Watson-Crick) entre pares de bases; (B) a mesma estrutura hipotética com ambos os tipos de pareamento, convencionais (vermelho) e não convencionais (p. ex., A-G) (verde); (C) estrutura de um RNA real, uma molécula envolvida no *splicing* de RNA. Cada pareamento convencional está indicado por um "traço" na dupla-hélice. Bases em outras configurações estão indicadas por traços quebrados. Para visualização adicional da estrutura do RNA, ver [Animação 7.1](#).

O que são genes?

Figura 7-2 Os genes podem ser expressos sob diferentes taxas. O gene A é transcrito e traduzido muito mais eficientemente do que o gene B. Isso permite que a quantidade de proteína A na célula seja muito maior do que a quantidade de proteína B. Nesta figura, e em figuras posteriores, as regiões não transcritas do DNA são representadas em cinza.




Regulação da expressão gênica




Genoma







Conjunto de todo o material genético de uma espécie.

Serve como repositório replicativo da informação genética, mas seu tamanho não segue a complexidade do organismo.



Número de Genes





- Presumed common progenitor of all extant organisms
- Presumed common progenitor of archaeobacteria and eukaryotes

PARTE 2

Genomas: Procariotos x Eucariotos

Como o mesmo tipo de molécula — o DNA — é embalado e organizado de formas radicalmente diferentes.

Nucleoide x Núcleo

PROCARIOTO

(bactérias, arqueias)



- Sem núcleo delimitado — DNA livre no citoplasma, na região do nucleoide
- Cromossomo único, geralmente circular
- Frequentemente possui plasmídeos
- Sem organelas membranosas

EUCARIOTO

(do fungo ao ser humano)

- Núcleo verdadeiro, delimitado por envoltório nuclear
- Múltiplos cromossomos lineares
- DNA também em mitocôndrias e cloroplastos
- Organelas membranosas especializadas


Cromossomo circular + plasmídeos



- Cromossomo único, circular, de fita dupla (dsDNA) — exceções lineares existem (ex.: Streptomyces, Borrelia)
- Genes compactados, quase sem DNA "não-codificante" entre eles
- Plasmídeos: moléculas de DNA circular acessórias, replicam-se independentemente
- **Transferência horizontal de genes entre bactérias:**
 - Conjugação — contato célula a célula
 - Transformação — captação de DNA livre do ambiente
 - Transdução — transferência mediada por vírus (bacteriófagos)


Núcleo, mitocôndrias e cloroplastos

A maior parte do DNA fica no núcleo, organizada em cromossomos lineares — mas duas organelas mantêm genomas próprios, circulares, herdados de bactérias ancestrais (teoria endossimbiótica):




Núcleo

Cromossomos lineares, DNA associado a histonas (cromatina).



Mitocôndria

DNA circular próprio: genes de RNAs e subunidades da cadeia respiratória (ex.: citocromo b, ATP sintase).




Cloroplasto



DNA circular próprio: genes do metabolismo fotossintético (só em plantas e algas).

Do DNA nu ao cromossomo: empacotamento hierárquico

Nos eucariotos, cerca de 2 metros de DNA por célula precisam caber num núcleo de poucos micrômetros. A solução é um empacotamento em vários níveis:



DNA linker: o trecho de DNA entre um nucleossomo e outro varia de 15 a 55 pares de bases. **Arcabouço (scaffold):** formado principalmente pela enzima Topoisomerase II, ancora as alças de cromatina pelas SARs (Scaffold Associated Regions).



Histonas: empacotam e também regulam

O octâmero de histonas (2 cópias de H3, H4, H2A e H2B) forma o núcleo do nucleossomo; a histona H1 auxilia a compactação em fibra de 30 nm.

Caudas das histonas recebem marcas químicas reguladoras



Metilação (M)

Pode silenciar (heterocromatina) ou ativar, dependendo da posição



Acetilação (A)

Geralmente associada à expressão gênica ativa



Fosforilação (P)

Associada à condensação/segregação de cromossomos

Código de histonas


K9 metilada (H3) → formação de heterocromatina, silenciamento gênico

K4 metilada + K9 acetilada (H3) → expressão gênica ativa

S10 fosforilada + K14 acetilada (H3) → expressão gênica ativa


Combinações de marcas nas caudas funcionam quase como um "código" que decide se aquele trecho de cromatina fica acessível ou silenciado.

Centrômero, telômero e origem de replicação



A maior parte do genoma humano não codifica proteínas

● Transposons (45%) ● Íntrons (24%) ● DNA intergênico (22%) ● Grandes duplicações (5%)
● Repetições simples (3%) ● Éxons (1%)



Apenas ~1% do genoma humano corresponde a éxons

(regiões que efetivamente codificam proteína). O restante inclui íntrons, DNA repetitivo e transposons — elementos móveis que se copiam e se inserem pelo genoma.

Contraste com procariotos: genomas bacterianos são muito mais "enxutos", com pouquíssimo DNA não-codificante — daí a anotação ser mais simples e rápida.

Promotor, operador, códons e terminador


→ Sentido da transcrição



- **Promotor:**
onde a RNA polimerase se liga para iniciar a transcrição (caixas -10 e -35).
- **Operador:**
sequência onde proteínas regulatórias se ligam, funcionando como uma "trava".
- **Sequência Shine-Dalgarno (SD):**
sinaliza ao ribossomo onde encaixar para iniciar a tradução.
- **Terminador:**
sinal que encerra a transcrição — em bactérias, frequentemente uma estrutura em grampo.

Óperons: um promotor, vários genes

Em procariotos, genes relacionados costumam ser transcritos juntos, a partir de um único promotor — uma "linha de produção" controlada por um único interruptor.



Exemplo clássico: operon lac (E. coli). Na ausência de lactose, uma proteína repressora se liga ao operador e bloqueia a transcrição. Na presença de lactose, o repressor se solta e os genes Z (β -galactosidase), Y (permease) e A (transacetilase) são transcritos juntos.

Contraste com eucariotos: cada gene eucariótico geralmente tem seu próprio promotor — a transcrição é monocistrônica (um mRNA, um gene).

Éxons, íntrons e sítios de splicing

→ Sentido da transcrição



- **Éxons (teal):**
trechos que permanecem no RNA maduro e efetivamente codificam a proteína.
- **Íntrons (cinza):**
trechos removidos pelo spliceossomo antes da tradução — reconhecidos por sítios doador e acceptor nas suas bordas.
- **UTRs (5' e 3'):**
regiões transcritas mas não traduzidas, com papel regulatório (estabilidade, velocidade de tradução).

Prever corretamente os sítios de splicing é o que torna a anotação eucariótica muito mais complexa que a procariótica.

Procariotos x Eucariotos — quadro-resumo

Característica	Procariotos	Eucariotos
Núcleo	Ausente (nucleoide)	Presente, com envoltório nuclear
Cromossomo	Único, geralmente circular	Múltiplos, lineares
DNA em organelas	Não se aplica	Mitocôndrias e cloroplastos (circular)
Densidade gênica	Alta — genes compactados	Baixa — muito DNA não-codificante
Íntrons/splicing	Raros/ausentes	Comuns — exigem spliceossomo
Organização gênica	Frequentemente em óperons	Um promotor por gene (geral)
Empacotamento	Superenrolamento simples	Nucleossomos, histonas, cromatina
Anotação (bioinformática)	Mais simples e rápida (ex.: Prokka)	Mais complexa (ex.: MAKER, AUGUSTUS)

PARTE 3

Montagem, Anotação e Ferramentas

Como tudo isso se traduz no fluxo prático de hoje, 100% conduzido na plataforma Galaxy.

Montagem: remontando o "livro rasgado"

O sequenciador não lê o genoma inteiro de uma vez — gera milhões de fragmentos curtos (reads). Montar é juntar os pedaços que se sobrepõem.



De novo x referência: montar do zero (sem mapa) ou usar um genoma parecido como guia. Hoje faremos *de novo* — o cenário mais realista para um organismo desconhecido.

N50: tamanho de contig tal que metade do genoma montado está em pedaços iguais ou maiores que ele. Quanto maior o N50, menos fragmentada (melhor) é a montagem.

Montagem genômica: de fragmentos curtos a estruturas maiores

Como leituras curtas são sobrepostas, montadas em contigs e organizadas em scaffolds



Fragmentos curtos

Estruturas maiores



Do DNA sequenciado
ao genoma montado


Montagem e avaliação de qualidade



SPAdes

Montagem de novo

Remonta o genoma a partir das reads, usando um método matemático (grafo de De Bruijn) para resolver as sobreposições. Muito usado para genomas bacterianos e virais. Saída: contigs.fasta.




Quast

Avaliação da montagem

Roda sobre os contigs gerados pelo SPAdes e produz métricas de qualidade: número de contigs, tamanho total da montagem e o N50. Ajuda a decidir se a montagem ficou boa ou fragmentada.

SPAdes: remontagem do genoma a partir de reads

Como o SPAdes usa o grafo de De Bruijn para reconstruir contigs a partir de leituras curtas



Muito usado para genomas bacterianos e virais.

Reads



Genoma remontado (parcial)

Prokka: anotação automática de genoma bacteriano



Recebe o genoma montado (contigs) e devolve uma lista de genes encontrados, com nome e função provável, por comparação com bancos de referência.

O que o Prokka procura

- Códon de início (ATG) e códons de parada
- Sequência Shine-Dalgarno (RBS)
- Padrões característicos de promotor
- RNAs ribossômicos e transportadores

Não faz: predição de promotor exato, terminador ou sítios de splicing (não se aplica a procariotos).

Anotação: o que uma ferramenta como o Prokka identifica

✓ O Prokka identifica

- Fronteiras da região codificante (onde começa/termina o CDS)
- RNAs ribossômicos e transportadores
- Função provável, por comparação com bancos de dados

✗ O Prokka NÃO prevê

- Promotor (ferramenta separada: ex. BPROM)
- Terminador (ferramenta separada: ex. ARNold)
- Sítios de splicing — não se aplica a procariotos

E em eucariontes?

O processo é bem mais complexo por causa dos íntrons/éxons.

As ferramentas de referência são:

- **MAKER / MAKER2:** equivalente conceitual ao Prokka, mas para eucariontes — combina várias fontes de evidência (similaridade com proteínas conhecidas, dados de RNA-seq, previsão estatística) para decidir onde estão os genes.
- **AUGUSTUS:** prediz genes com base em modelos estatísticos treinados para reconhecer padrões de éxon/íntron específicos de cada espécie (tem versão web, sem precisar instalar nada).
- **BRAKER:** combina o AUGUSTUS com dados reais de RNA-seq para melhorar a precisão — em vez de só "prever" onde estão os genes, usa evidência real de que aquele trecho é de fato expresso.

Na prática do dia a dia, poucas vezes alguém anota um genoma eucarioto do zero: para a maioria dos organismos já estudados (humano, camundongo, etc.), a anotação já existe pronta em bancos como

Ensembl e NCBI Genome — usa-se a referência publicada.

Bancos de referência: NCBI Genome e Ensembl

NCBI Genome

ncbi.nlm.nih.gov/genome

Repositório com genomas de milhares de organismos, procariotos e eucariotos, já montados e anotados.

Ensembl

ensembl.org

Foco em genomas eucarióticos com anotação detalhada — genes, transcritos, éxons/íntrons, variantes.

Uso na prática de hoje

Ao final da anotação com Prokka, abrimos rapidamente um genoma eucarioto já anotado no Ensembl (ex.: um gene humano) para contrastar visualmente a escala e a complexidade — essa anotação não é feita "na hora": é fruto de anos de curadoria (MAKER, AUGUSTUS, BRAKER + revisão manual).